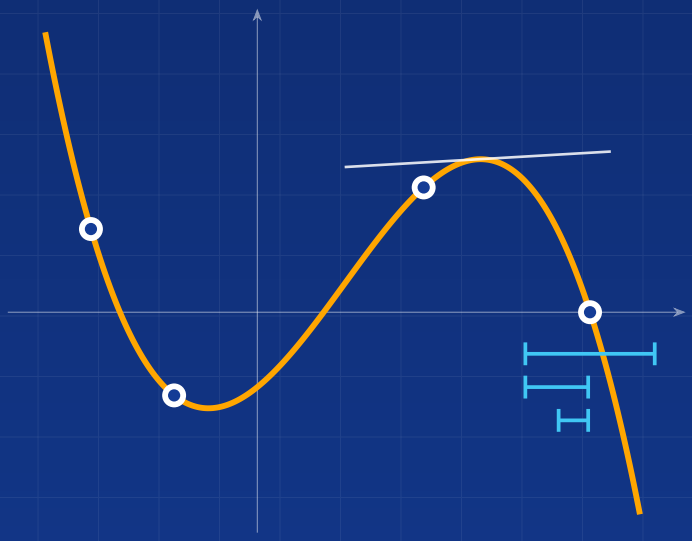
Universidade Federal do Triângulo Mineiro
Licenciatura em Matemática – ICENE

Cálculo Numérico Interativo

Aritmética de ponto flutuante, zeros de funções,
sistemas lineares, interpolação, ajuste de curvas
e integração numérica com aplicativos no GeoGebra



$$\left(\begin{array}{cccc|c} 1 & -4 & 16 & -64 & 2 \\ 0 & 2 & -12 & 56 & -4 \\ 0 & 0 & 48 & -96 & 17 \\ 0 & 0 & 0 & 480 & -\frac{41}{2} \end{array}\right)$$

Osmar Alessio

Uberaba – MG • 2026

Livro com aplicativos interativos:
clique nos links para abrir no GeoGebra

Universidade Federal do Triângulo Mineiro
Licenciatura em Matemática – ICENE

Cálculo Numérico Interativo

Aritmética de ponto flutuante, zeros de funções,
sistemas lineares, interpolação, ajuste de curvas
e integração numérica com aplicativos no GeoGebra

Osmar Alessio

Uberaba – MG
2026

Sumário

Apresentação **iv**

1 Mudança de base e aritmética de ponto flutuante **1**

1.1 Por que estudar a representação dos números 1
1.2 Sistemas de numeração posicionais 2
1.3 Da base β para a base 10 3
1.4 Da base 10 para a base β 3
1.4.1 Parte inteira: divisões sucessivas 3
1.4.2 Parte fracionária: multiplicações sucessivas 4
1.4.3 Entre as bases 2, 8 e 16 5
1.5 Representação em ponto flutuante 5
1.6 O padrão IEEE 754 6
1.6.1 Valores especiais e números subnormais 6
1.7 As máquinas de 8, 16, 32 e 64 bits 7
1.7.1 A máquina de 8 bits 8
1.7.2 As máquinas de 16, 32 e 64 bits 8
1.8 Arredondamento e truncamento 9
1.9 Erros absoluto e relativo 10
1.10 Operações em ponto flutuante e propagação de erros 10
1.10.1 Fórmulas de propagação 11
1.10.2 Cancelamento 11
1.11 Exercícios 12

2 Zeros de funções **14**

2.1 O problema 14
2.2 Isolamento das raízes 15
2.3 Critérios de parada e laços de repetição 15
2.4 Método da bisseção 16
2.5 Método da posição falsa 18
2.6 Método do ponto fixo 19
2.7 Método de Newton-Raphson 21

2.8 Método da secante . . . 22
2.9 Comparação dos métodos . . . 22
2.10 Exercícios . . . 23

3 Sistemas lineares: métodos diretos e iterativos 25
3.1 Introdução . . . 25
3.2 Sistemas triangulares . . . 26
3.3 Eliminação de Gauss . . . 26
3.4 Fatoração LU . . . 28
3.5 Custo computacional dos métodos diretos . . . 30
3.6 Métodos iterativos: a ideia . . . 31
3.7 Método de Gauss-Jacobi . . . 31
3.8 Método de Gauss-Seidel . . . 33
3.9 Métodos diretos ou iterativos? . . . 34
3.10 Exercícios . . . 35

4 Interpolação polinomial 37
4.1 O problema da interpolação . . . 37
4.2 Existência e unicidade . . . 38
4.3 Método 1: sistema linear e eliminação de Gauss . . . 39
4.4 Método 2: forma de Lagrange . . . 40
4.5 Método 3: forma de Newton e diferenças divididas . . . 42
4.6 Comparação dos três métodos . . . 44
4.7 O erro da interpolação . . . 44
4.8 Exercícios . . . 45

5 Ajuste de curvas 47
5.1 Interpolar ou ajustar? . . . 47
5.2 O método dos mínimos quadrados (caso discreto) . . . 48
5.2.1 O sistema normal . . . 48
5.2.2 Ajuste por uma reta . . . 49
5.2.3 Ajuste por uma parábola . . . 50
5.2.4 Combinação de outras funções . . . 50
5.2.5 Casos não lineares: linearização . . . 51
5.3 O método iterativo: gradiente descendente . . . 51
5.3.1 A função custo e o seu gradiente . . . 52
5.3.2 Gradiente descendente para a reta . . . 52
5.3.3 A escolha do passo e a convergência . . . 53
5.3.4 Padronização das variáveis . . . 54
5.4 Método direto × método iterativo . . . 56

5.5 Exercícios 56

6 Integração numérica **58**

6.1 O problema da integração numérica 58
6.2 Regra dos trapézios 59
6.2.1 Regra simples 59
6.2.2 Regra repetida 60
6.3 Regra 1/3 de Simpson 61
6.3.1 Regra simples 61
6.3.2 Regra repetida 62
6.4 Regra 3/8 de Simpson 64
6.5 Fórmulas de Newton-Cotes: resumo 64
6.6 Quantos subintervalos usar? 65
6.7 Extrapolação de Richardson e método de Romberg 65
6.7.1 A ideia de Richardson 65
6.7.2 O método de Romberg 66
6.8 Quadratura de Gauss-Legendre 67
6.8.1 A ideia 67
6.8.2 Mudança de intervalo 68
6.9 Comparação dos métodos 69
6.10 Exercícios 70

Apresentação

Este livro reúne textos de Cálculo Numérico preparados para a Licenciatura em Matemática, com uma característica central: cada método é acompanhado de um ou mais aplicativos no GeoGebra, em que o aluno executa o método passo a passo, confere as contas e observa a construção geométrica.

Como usar os links. Os quadros laranja *Atividade no GeoGebra* trazem o link [**abrir o aplicativo**], que abre o arquivo correspondente no GeoGebra Classic. Os quadros verdes *Leitura complementar* abrem textos de apoio em PDF. Para que os links funcionem:

- mantenha o arquivo `livro.pdf` e as pastas `ggb` e `complementos` juntos, na mesma pasta;
- abra o PDF num leitor que permita abrir arquivos externos (Adobe Acrobat Reader, Okular, SumatraPDF, Foxit). Os leitores de PDF dos navegadores costumam bloquear esses links; nesse caso, abra os arquivos diretamente das pastas.

Organização. O Capítulo 1 trata da mudança de base e da representação dos números em ponto flutuante (padrão IEEE 754), com máquinas de 8, 16, 32 e 64 bits no GeoGebra, e dos erros de arredondamento e truncamento que acompanham todos os métodos seguintes. O Capítulo 2 apresenta os métodos para zeros de funções (bisseção, posição falsa, ponto fixo, Newton-Raphson e secante) e sua relação com os laços de repetição. O Capítulo 3 trata dos sistemas lineares, com métodos diretos (eliminação de Gauss e fatoração LU) e iterativos (Gauss-Jacobi e Gauss-Seidel). O Capítulo 4 trata da interpolação polinomial por três caminhos (sistema linear, Lagrange e Newton), que levam ao mesmo polinômio. O Capítulo 5 trata do ajuste de curvas pelo método dos mínimos quadrados, resolvido de forma direta (sistema normal) e iterativa (gradiente descendente). O Capítulo 6 trata da integração numérica: regras dos trapézios e de Simpson (simples e repetidas), extrapolação de Richardson e método de Romberg, e quadratura de Gauss-Legendre. Cada capítulo termina com exercícios e respostas.

Capítulo 1

Mudança de base e aritmética de ponto flutuante

Como usar os aplicativos e os textos deste capítulo

Os quadros laranja *Atividade no GeoGebra* trazem o link [**abrir o aplicativo**]. São seis aplicativos. Os quatro primeiros substituem as planilhas de Excel das *máquinas* de 8, 16, 32 e 64 bits:

- máquinas de ponto flutuante: 8 bits, 16 bits, 32 bits (*float*) e 64 bits (*double*). Cada bit é uma caixa de seleção; o aplicativo decodifica a palavra, codifica um número digitado (por arredondamento ou truncamento) e calcula os erros;
- mudança de base, com as divisões e as multiplicações sucessivas passo a passo;
- sistema $F(\beta, t, m, M)$ na reta, que mostra todos os números de uma máquina pequena e o valor $fl(x)$ de qualquer x.

1.1 Por que estudar a representação dos números

A resolução de um problema por métodos numéricos passa por várias fases: o problema real, o levantamento de dados, a construção do modelo matemático, a escolha do método, a implementação computacional e a análise dos resultados. Não é raro que o resultado final fique distante do esperado, mesmo com todas as fases feitas corretamente. Os resultados dependem também

- da precisão dos dados de entrada;
- da forma como esses dados são representados no computador;
- das operações numéricas efetuadas.

Exemplo: a área de um círculo

A área de um círculo de raio 100 m, calculada com $\pi \approx 3{,}14$, $\pi \approx 3{,}1416$ e $\pi \approx 3{,}141592654$, dá

$$A = 31\,400 \text{ m}^2, \qquad A = 31\,416 \text{ m}^2, \qquad A = 31\,415{,}9265 \text{ m}^2.$$

As diferenças vêm da aproximação usada para π, que é irracional. Nenhum computador obtém a área "exatamente".

Exemplo: um somatório

Calcule $S = \sum_{i=1}^{30\,000} x_i$ com $x_i = 0{,}5$ e com $x_i = 0{,}11$. As respostas exatas são 15 000 e 3 300. Somando num programa:

	$x_i = 0{,}5$	$x_i = 0{,}11$
precisão simples (32 bits)	15 000	3 300,985
precisão dupla (64 bits)	15 000	3 300,000 000 000 628 5

Com 0,5 o resultado é exato; com 0,11, não. A explicação está neste capítulo: $0{,}5 = (0{,}1)_2$ tem representação binária finita, mas 0,11 não tem. Cada parcela já entra com um pequeno erro, e cada soma acrescenta outro.

Há três fontes de erro num cálculo numérico:

1. **incerteza dos dados**: os dados vêm de medidas com instrumentos de precisão finita;
2. **erros de arredondamento**: vêm da forma finita de representar números na máquina;
3. **erros de truncamento**: aparecem quando um processo infinito (uma série, um limite, uma integral) é substituído por um processo finito.

Este capítulo trata do segundo tipo.

1.2 Sistemas de numeração posicionais

A *base* de um sistema de numeração é a quantidade de símbolos usados para escrever os números.

Base	Nome	Símbolos
2	binário	0, 1
8	octal	0, 1, 2, 3, 4, 5, 6, 7
10	decimal	0, 1, . . . , 9
16	hexadecimal	0, 1, . . . , 9, A, B, C, D, E, F

A base 10 é a do nosso dia a dia. A base 2 é natural nos circuitos lógicos: 0 e 1 correspondem a dois níveis de tensão (*low* e *high*), a falso e verdadeiro, a desligado e ligado. As bases 8 e 16 servem para escrever números binários de forma compacta. Quando a base não é 10, ela vem indicada no índice: $(1010001011)_2$, $(453234)_8$, $(23A0D)_{16}$.

Definição 1.1 (notação posicional)**.** Num sistema posicional de base β, o número $(d_{p-1}d_{p-2}\ldots d_1d_0\,,\,d_{-1}\ldots d_{-n})_\beta$, com $0 \le d_i \le \beta - 1$, vale

$$D = \sum_{i=-n}^{p-1} d_i\,\beta^i = d_{p-1}\beta^{p-1} + \cdots + d_1\beta + d_0 + d_{-1}\beta^{-1} + \cdots + d_{-n}\beta^{-n},$$

em que p é o número de dígitos à esquerda da vírgula e n o número de dígitos à direita. O valor de cada símbolo depende da sua posição.

Em base 2, cada dígito é um *bit*. O bit mais à esquerda é o MSB (*most significant bit*) e o mais à direita é o LSB (*least significant bit*).

hex	dec	bin	hex	dec	bin
0	0	0000	8	8	1000
1	1	0001	9	9	1001
2	2	0010	A	10	1010
3	3	0011	B	11	1011
4	4	0100	C	12	1100
5	5	0101	D	13	1101
6	6	0110	E	14	1110
7	7	0111	F	15	1111

1.3 Da base β para a base 10

Basta somar os dígitos multiplicados pelos pesos β^i.

Exemplo

$$
\begin{aligned}
(11011)_2 &= 1\cdot 2^4 + 1\cdot 2^3 + 0\cdot 2^2 + 1\cdot 2^1 + 1\cdot 2^0 = 16+8+2+1 = 27,\\
(372)_8 &= 3\cdot 8^2 + 7\cdot 8 + 2 = 192+56+2 = 250,\\
(24{,}6)_8 &= 2\cdot 8 + 4 + 6\cdot 8^{-1} = 16+4+0{,}75 = 20{,}75,\\
(356)_{16} &= 3\cdot 16^2 + 5\cdot 16 + 6 = 768+80+6 = 854,\\
(2AF)_{16} &= 2\cdot 16^2 + 10\cdot 16 + 15 = 512+160+15 = 687,\\
(1000{,}011)_2 &= 8 + 0\cdot 2^{-1} + 1\cdot 2^{-2} + 1\cdot 2^{-3} = 8+0{,}25+0{,}125 = 8{,}375.
\end{aligned}
$$

1.4 Da base 10 para a base β

O número é separado em parte inteira e parte fracionária, que são convertidas por processos diferentes.

1.4.1 Parte inteira: divisões sucessivas

Seja N inteiro com $(N)_{10} = (c_k \ldots c_2 c_1 c_0)_\beta$. Então

$$N = c_k\beta^k + \cdots + c_2\beta^2 + c_1\beta + c_0 = \beta \underbrace{(c_k\beta^{k-1} + \cdots + c_2\beta + c_1)}_{q_1} + c_0.$$

Logo c_0 é o *resto* da divisão de N por β e q_1 é o quociente. Repetindo o raciocínio com q_1, obtemos c_1, e assim por diante, até o quociente ser zero.

Algoritmo: inteiro decimal $\to$ base β

Passo 0: $k = 0$, $N_0 = N$.
Passo 1: obtenha q_k e r_k tais que $N_k = \beta\, q_k + r_k$, $0 \le r_k < \beta$; faça $c_k = r_k$.
Passo 2: se $q_k = 0$, pare. Caso contrário, faça $N_{k+1} = q_k$, $k = k+1$ e volte ao passo 1.
Os restos, lidos **de baixo para cima** (do último para o primeiro), formam o número na base β.

Exemplo

$$\begin{aligned} 25 &= 2\cdot 12 + \mathbf{1} \\ 12 &= 2\cdot 6 + \mathbf{0} \\ 6 &= 2\cdot 3 + \mathbf{0} \\ 3 &= 2\cdot 1 + \mathbf{1} \\ 1 &= 2\cdot 0 + \mathbf{1} \end{aligned} \quad \Rightarrow \; 25 = (11001)_2, \qquad \begin{aligned} 2834 &= 8\cdot 354 + \mathbf{2} \\ 354 &= 8\cdot 44 + \mathbf{2} \\ 44 &= 8\cdot 5 + \mathbf{4} \\ 5 &= 8\cdot 0 + \mathbf{5} \end{aligned} \quad \Rightarrow \; 2834 = (5422)_8.$$

Da mesma forma, $37 = (100101)_2$ e $2834 = 16\cdot 177 + 2$, $177 = 16\cdot 11 + 1$, $11 = 16\cdot 0 + 11$, logo $2834 = (B12)_{16}$.

1.4.2 Parte fracionária: multiplicações sucessivas

Seja $0 < r < 1$ com $(r)_{10} = (0{,}d_1d_2d_3\ldots)_\beta$. Multiplicando por β:

$$\beta\, r = d_1 + \underbrace{(0{,}d_2d_3\ldots)_\beta}_{\text{parte fracionária}}.$$

A parte inteira de βr é d_1. Repetindo com a parte fracionária, obtemos d_2, d_3,...

Algoritmo: fração decimal → base β

Passo 0: $r_1 = r$, $k = 1$.
Passo 1: calcule βr_k; faça $d_k = \lfloor \beta r_k \rfloor$ (parte inteira).
Passo 2: faça $r_{k+1} = \beta r_k - d_k$. Se $r_{k+1} = 0$, pare.
Passo 3: faça $k = k + 1$ e volte ao passo 1.
As partes inteiras, lidas **de cima para baixo**, formam $0{,}d_1d_2d_3\ldots$ Se o processo não terminar, paramos depois do número de dígitos desejado.

Exemplo: 8,375 e 4,8 em binário

Parte inteira: $8 = (1000)_2$ e $4 = (100)_2$. Partes fracionárias:

$$\begin{aligned} 0{,}375\times 2 &= \mathbf{0}{,}75 \\ 0{,}75\times 2 &= \mathbf{1}{,}5 \\ 0{,}5\times 2 &= \mathbf{1}{,}0 \quad \text{(fim)} \end{aligned} \qquad \begin{aligned} 0{,}8\times 2 &= \mathbf{1}{,}6 \\ 0{,}6\times 2 &= \mathbf{1}{,}2 \\ 0{,}2\times 2 &= \mathbf{0}{,}4 \\ 0{,}4\times 2 &= \mathbf{0}{,}8 \quad \text{(volta ao início)} \end{aligned}$$

Logo $8{,}375 = (1000{,}011)_2$, uma expansão finita, e $4{,}8 = (100{,}\overline{1100})_2 = (100{,}110011001100\ldots)_2$, uma expansão infinita e periódica.

Exemplo: 3,38 e 57,3 (Aula 01)

Para 0,38, as multiplicações dão 0,76; 1,52; 1,04; 0,08; 0,16; 0,32; 0,64; 1,28;..., e então $0{,}38 \approx (0{,}01100001)_2 = 0{,}37890625$ com 8 dígitos. Portanto $3{,}38 \approx (11{,}01100001)_2$. Quanto mais dígitos, melhor a aproximação.
Para 57,3: $57 = (111001)_2$ e $0{,}3 = (0{,}0\overline{1001})_2$, logo $57{,}3 = (111001{,}0100110011001\ldots)_2$.

Observação

Uma fração p/q irredutível tem expansão finita na base β se, e somente se, todo fator primo de q divide β. Em base 2, só têm expansão finita os racionais com denominador potência de 2: $1/8 = (0{,}001)_2$, $1/16 = (0{,}0001)_2$, $5{,}625 = (101{,}101)_2$. Já 1/3, 1/5 e 1/10 são periódicos:

$$\tfrac{1}{3} = (0{,}\overline{01})_2, \qquad \tfrac{1}{5} = (0{,}\overline{0011})_2, \qquad \tfrac{1}{10} = (0{,}0\overline{0011})_2.$$

Um número com expansão decimal finita, como 0,1, pode ter expansão binária infinita.

1.4.3 Entre as bases 2, 8 e 16

Como $8 = 2^3$ e $16 = 2^4$, basta agrupar os bits de 3 em 3 (octal) ou de 4 em 4 (hexadecimal) a partir da vírgula:

$$(101101{,}101)_2 = (\underbrace{101}_{5}\,\underbrace{101}_{5}{,}\underbrace{101}_{5})_2 = (55{,}5)_8, \qquad (0010\,1101{,}1010)_2 = (2D{,}A)_{16}.$$

É por isso que as palavras de máquina são escritas em hexadecimal.

Atividade no GeoGebra: mudança de base passo a passo [abrir o aplicativo]

Digite um número decimal (até 9 casas decimais), escolha a base β (de 2 a 16) e o número de dígitos fracionários. O aplicativo mostra:

- à esquerda, as divisões sucessivas da parte inteira, com os restos em vermelho;
- no centro, as multiplicações sucessivas da parte fracionária;
- à direita, o resultado, a verificação pela notação posicional, o erro cometido ao parar e a conferência com o comando `ToBase` do GeoGebra;
- no quadro de baixo, a conversão de um inteiro de uma base qualquer para decimal (`FromBase`).

Tarefas. (a) Reproduza os exemplos 25, 37, 2834 (bases 8 e 16), 8,375, 4,8, 3,38 e 57,3. (b) Converta 0,1 para a base 2 com 4, 8, 16 e 24 dígitos e anote o erro em cada caso. Quantos dígitos binários são necessários para que o erro fique abaixo de 10^{-6}? (c) Ache três números com expansão finita em base 2 e infinita em base 3.

Arquivo:
`ggb/MudancaDeBase.ggb`

1.5 Representação em ponto flutuante

Um número real $x \neq 0$ pode ser escrito em *ponto flutuante normalizado* na base β:

$$x = \pm\,(0{,}d_1 d_2 \ldots d_t)_\beta \times \beta^{\,e}, \qquad d_1 \neq 0, \qquad -m \leq e \leq M,$$

em que $0{,}d_1 \ldots d_t$ é a *mantissa*, t é o número de dígitos da mantissa e e é o *expoente*, limitado por $-m$ e M. Esse conjunto de números é indicado por $F(\beta, t, m, M)$. O zero é representado à parte, com mantissa nula.

Como a mantissa e o expoente têm tamanho finito:

- F é um conjunto *finito*, com $2(\beta-1)\beta^{t-1}(M+m+1)+1$ elementos;
- o menor positivo é $(0{,}10\ldots0)_\beta \times \beta^{-m} = \beta^{-m-1}$, e o maior é $(0{,}(\beta{-}1)\ldots(\beta{-}1))_\beta \times \beta^M = (1-\beta^{-t})\beta^M$;

- se $0 < |x| < \beta^{-m-1}$, ocorre **underflow**; se $|x| > (1-\beta^{-t})\beta^{M}$, ocorre **overflow**;
- os números de F **não são igualmente espaçados**: entre β^{e-1} e β^{e} o espaçamento é β^{e-t}, que cresce com e.

Exemplo: $F(10,3,5,5)$

Com $t=3$ dígitos decimais e $-5 \le e \le 5$, o menor positivo é $0{,}100\times10^{-5} = 10^{-6}$ e o maior é $0{,}999\times10^{5} = 99\,900$. Então $x = 235{,}89 = 0{,}23589\times10^{3}$ fica $0{,}236\times10^{3}$ (arredondado) ou $0{,}235\times10^{3}$ (truncado); $x = 0{,}345\times10^{-7}$ dá underflow; $x = 0{,}875\times10^{9}$ dá overflow.

Atividade no GeoGebra: o sistema $F(\beta,t,m,M)$ na reta [abrir o aplicativo]

Os controles deslizantes escolhem β, t, m e M; os pontos azuis do eixo são *todos* os números do sistema. Arraste o ponto P: o ponto vermelho é $fl(x)$, por arredondamento ou, desmarcando a caixa, por truncamento. O quadro mostra a quantidade de números, o maior, o menor positivo, os erros absoluto e relativo e os avisos de underflow e overflow. **Tarefas.** (a) Em $F(2,3,1,2)$, confira que há 33 números, que o maior é 3,5 e o menor positivo é 0,25. (b) Amplie a região perto do zero (roda do mouse) e observe o "buraco" entre 0 e 0,25. (c) Compare o espaçamento entre 0,5 e 1 com o espaçamento entre 2 e 3,5. (d) Mova P por vários pontos e verifique que $|ER|$ nunca passa de $\frac{1}{2}\beta^{1-t}$ com arredondamento, enquanto $|EA|$ cresce com $|x|$.

Arquivo:
`ggb/SistemaPontoFlutuante_reta.ggb`

1.6 O padrão IEEE 754

As mais diversas representações em ponto flutuante já foram usadas. O padrão IEEE 754, criado em 1985 e revisto em 2008 e 2019, é hoje implementado na grande maioria dos processadores. Em base 2, a mantissa normalizada começa sempre com o bit 1, que por isso não precisa ser guardado (*bit escondido*). O padrão usa a forma $1,f$ e guarda três campos:

$$\underbrace{s}_{\text{sinal}} \;\Big|\; \underbrace{E}_{\text{expoente com bias}} \;\Big|\; \underbrace{f}_{\text{fração}} \qquad\qquad x = (-1)^{s}\times(1,f)_2\times 2^{E-\text{bias}}.$$

- $s=0$ para positivo e $s=1$ para negativo;
- E é um inteiro sem sinal; o expoente verdadeiro é $E-\text{bias}$, com $\text{bias} = 2^{k-1}-1$ para um campo de k bits (assim não é preciso guardar expoentes negativos);
- $f = (0{,}b_1b_2\ldots b_p)_2$ é a fração; a mantissa é $1,f$, com $p+1$ bits de precisão.

formato	total	expoente	fração	bias	faixa aproximada
meia (*binary16*)	16	5	10	15	$6{,}1\times10^{-5}$ a 65 504
simples (`float`)	32	8	23	127	$1{,}2\times10^{-38}$ a $3{,}4\times10^{38}$
dupla (`double`)	64	11	52	1023	$2{,}2\times10^{-308}$ a $1{,}8\times10^{308}$
estendida (Intel)	80	15	63	16383	$3{,}4\times10^{-4932}$ a $1{,}2\times10^{4932}$
quádrupla (*binary128*)	128	15	112	16383	idem

1.6.1 Valores especiais e números subnormais

Os valores extremos do campo E são reservados:

campo E	fração f	significado
$00\ldots0$	$f=0$	±0
$00\ldots0$	$f\neq0$	subnormal: $x=(-1)^s\times(0{,}f)_2\times2^{1-\text{bias}}$
$1\le E\le 2^k-2$	qualquer	normalizado: $x=(-1)^s\times(1{,}f)_2\times2^{E-\text{bias}}$
$11\ldots1$	$f=0$	$\pm\infty$ (overflow, divisão por zero)
$11\ldots1$	$f\neq0$	NaN, *not a number* (por exemplo, $0/0$ ou $\sqrt{-1}$)

Os **subnormais** (ou desnormalizados) preenchem o intervalo entre 0 e o menor normalizado $2^{1-\text{bias}}$ com números igualmente espaçados. O underflow fica "gradual", em vez de saltar direto para zero.

Exemplo: 15 213 em precisão simples

$15\,213=(11101101101101)_2=(1{,}1101101101101)_2\times2^{13}$. Então

- $s=0$;
- $E=13+127=140=(10001100)_2$;
- $f=$ `11011011011010000000000` (os 13 bits depois da vírgula, completados com zeros até 23).

A palavra é `0 10001100 11011011011010000000000`, ou $466DB400_{16}$.

Exemplo: 178,125 em precisão dupla

$178{,}125=128+32+16+2+0{,}125=(10110010{,}001)_2=(1{,}0110010001)_2\times2^7$. Então $s=0$, $E=7+1023=1030=(10000000110)_2$ e $f=$ `01100100010`$\ldots0$ (52 bits). A palavra é 4066440000000000_{16}.

Exemplo: 0,2 em todos os formatos (as planilhas das máquinas)

$0{,}2=(0{,}\overline{0011})_2=(1{,}\overline{1001})_2\times2^{-3}$. O expoente é -3 e a fração $1001\,1001\,1001\ldots$ precisa ser cortada. Arredondando para o mais próximo:

formato	palavra (hex)	valor guardado	erro relativo
8 bits (bias 3)	$0D$	0,203125	$-1{,}6\times10^{-2}$
16 bits	3266	0,199951171875	$2{,}4\times10^{-4}$
32 bits	$3E4CCCCD$	0,20000000298023224	$-1{,}5\times10^{-8}$
64 bits	$3FC999999999999A$	0,20000000000000001110	$-5{,}6\times10^{-17}$

Na máquina de 8 bits, o expoente -3 é menor que o mínimo $1-3=-2$, e 0,2 cai na faixa subnormal: $0{,}2\approx(0{,}1101)_2\times2^{-2}=13/64$. Nas planilhas de Excel o campo $E=0$ era tratado como normalizado. No padrão IEEE (e nos aplicativos) ele é reservado para o zero e os subnormais.

1.7 As máquinas de 8, 16, 32 e 64 bits

As planilhas usadas em aula montavam um número bit a bit e calculavam $(-1)^s(1+\text{fração})\,2^{E-\text{bias}}$. Os aplicativos a seguir fazem o mesmo e mais:

- cada bit é uma caixa de seleção (marcada = 1), agrupada em sinal, expoente e fração, com o peso de cada bit indicado acima da caixa;

- a palavra aparece em binário e em hexadecimal;
- a *decodificação* mostra s, E, $E-$ bias, a fração, o tipo do número (zero, subnormal, normalizado, infinito ou NaN), o valor com 15 algarismos significativos e o espaçamento local (ulp, *unit in the last place*);
- na *codificação*, você digita o número exato e escolhe **arredondamento** (para o mais próximo, empate para o par, como no padrão) ou **truncamento** (corte, em direção ao zero). O aplicativo marca os bits e calcula os erros absoluto e relativo;
- o quadro *Faixa* mostra o maior número, o menor normalizado e o menor subnormal.

1.7.1 A máquina de 8 bits

O formato didático de 8 bits de W. T. Verts tem 1 bit de sinal, 3 de expoente (bias = 3) e 4 de fração. Ele segue todas as regras do IEEE 754 e é pequeno o bastante para listar os seus 256 padrões:

- $E=0$: zero e subnormais $(0{,}f)_2\times 2^{-2}$, de $1/64=0{,}015625$ a $15/64$, com passo $1/64$;
- $1\le E\le 6$: normalizados $(1{,}f)_2\times 2^{E-3}$, de 0,25 a $(1{,}1111)_2\times 2^3=15{,}5$;
- $E=7$: $\pm\infty$ e NaN.

São $2\times(16+6\times 16)=224$ padrões finitos (com $+0$ e -0). Entre 1 e 2 o passo é $1/16$; entre 8 e 15,5 é $1/2$.

E	expoente	intervalo	passo
0 (sub.)	-2	[0, 0,234375]	1/64
1	-2	[0,25, 0,484375]	1/64
2	-1	[0,5, 0,96875]	1/32
3	0	[1, 1,9375]	1/16
4	1	[2, 3,875]	1/8
5	2	[4, 7,75]	1/4
6	3	[8, 15,5]	1/2

Atividade no GeoGebra: máquina de 8 bits **[abrir o aplicativo]**

O aplicativo abre com 0,2 arredondado: `0 000 1101`, um subnormal que vale 0,203125. **Tarefas.** (a) Clique no bit de expoente de peso 2^0 e veja o número passar a $(1{,}1101)_2\times 2^{-2}=0{,}453125$. (b) Monte o maior número (15,5), o menor normalizado (0,25), o menor subnormal (1/64), $+\infty$ e um NaN. (c) Digite $x=2{,}7$ e codifique por arredondamento e por truncamento: os resultados são 2,75 e 2,625. (d) Codifique 15,75 por arredondamento (overflow, $+\infty$) e por truncamento (fica o maior finito, 15,5). (e) Codifique 0,007, que é menor que metade do menor subnormal: o resultado é zero (underflow).

Arquivo:
ggb/Maquina_PontoFlutuante_8bits.ggb

1.7.2 As máquinas de 16, 32 e 64 bits

Atividade no GeoGebra: máquina de 16 bits (meia precisão) **[abrir o aplicativo]**

Formato 1 + 5 + 10, bias = 15. O aplicativo abre com 0,2 arredondado (3266_{16}, 0,199951171875).
Tarefas. (a) Monte 1, 2, $-1{,}5$ e o maior número finito (65 504). (b) Codifique 65 519 e

65 520 por arredondamento: o primeiro vira 65 504 e o segundo, $+\infty$. (c) Codifique 2049: o resultado é 2048, porque com 11 bits de mantissa os inteiros acima de 2^{11} não são todos representáveis. (d) Compare o erro relativo de 0,2 com $\varepsilon_{\text{máq}} = 2^{-10}$.

Arquivo:
ggb/Maquina_PontoFlutuante_16bits.ggb

Atividade no GeoGebra: máquina de 32 bits (precisão simples) [abrir o aplicativo]

Formato $1 + 8 + 23$, bias $= 127$, o `float` das linguagens de programação.
Tarefas. (a) Codifique 15 213 e confira a palavra $466DB400_{16}$. (b) Codifique 0,1 e 0,2 e anote os erros relativos; compare com $2^{-24} \approx 5{,}96 \times 10^{-8}$. (c) Codifique $16\,777\,217 = 2^{24}+1$ e explique o resultado. (d) Codifique 10^{-40}: o número é subnormal e o erro relativo cresce, porque sobram menos bits significativos.

Arquivo:
ggb/Maquina_PontoFlutuante_32bits.ggb

Atividade no GeoGebra: máquina de 64 bits (precisão dupla) [abrir o aplicativo]

Formato $1 + 11 + 52$, bias $= 1023$, o `double`. Os 52 bits da fração estão em duas linhas (use as barras de rolagem se a tela for pequena). Em hexadecimal, a palavra tem 16 dígitos e a fração 13.
Tarefas. (a) Codifique 178,125 e confira 4066440000000000_{16}. (b) Codifique 0,1: a fração é $999999999999A_{16}$; o último dígito "A" (em vez de 9) vem do arredondamento para cima. (c) Compare a palavra de 0,1 com a de 0,2: só muda o expoente. Por quê? (d) O GeoGebra calcula em precisão dupla, então o número digitado já entra como `double`: aqui o erro aparece como 0. Use o ulp e $\varepsilon_{\text{máq}} = 2^{-52}$ para estimar o erro, ou faça a mesma conta na máquina de 32 bits.

Arquivo:
ggb/Maquina_PontoFlutuante_64bits.ggb

1.8 Arredondamento e truncamento

Considere um sistema que opera em aritmética de ponto flutuante de t dígitos na base 10, e escreva

$$x = f_x \times 10^e + g_x \times 10^{e-t}, \qquad 0{,}1 \le f_x < 1, \quad 0 \le g_x < 1.$$

Por exemplo, com $t = 4$ e $x = 234{,}57$: $x = 0{,}2345 \times 10^3 + 0{,}7 \times 10^{-1}$, logo $f_x = 0{,}2345$ e $g_x = 0{,}7$. A parcela $g_x \times 10^{e-t}$ não cabe na mantissa. Há dois critérios:

Truncamento: g_x é desprezado e $\bar{x} = f_x \times 10^e$. Então

$$|EA_x| = |g_x| \times 10^{e-t} < 10^{e-t}, \qquad |ER_x| = \frac{|g_x| \times 10^{e-t}}{|f_x| \times 10^e} < \frac{10^{e-t}}{0{,}1 \times 10^e} = 10^{-t+1}.$$

Arredondamento: se $|g_x| < \frac{1}{2}$, despreza-se g_x; caso contrário, soma-se 1 ao último dígito de f_x. Então

$$|EA_x| \le \tfrac{1}{2} \times 10^{e-t}, \qquad |ER_x| < \tfrac{1}{2} \times 10^{-t+1}.$$

O arredondamento comete erros menores, mas exige mais operações; por isso algumas máquinas antigas truncavam. O IEEE 754 adota como padrão o **arredondamento para o mais**

próximo, com empate para o par (o último bit fica 0). Ele também oferece arredondamento em direção a 0 (truncamento), a $+\infty$ e a $-\infty$, úteis na análise por intervalos.

Na base 2 com p bits de fração, os mesmos argumentos dão o **épsilon da máquina** $\varepsilon_{\text{máq}} = 2^{-p}$, a distância de 1 ao número seguinte da máquina, e

$$\frac{|x - fl(x)|}{|x|} \le \tfrac{1}{2}\varepsilon_{\text{máq}} = 2^{-(p+1)} \quad \text{(arredondamento)}, \qquad \frac{|x - fl(x)|}{|x|} < \varepsilon_{\text{máq}} \quad \text{(truncamento)},$$

para x na faixa dos normalizados. Em precisão dupla, $\varepsilon_{\text{máq}} = 2^{-52} \approx 2{,}2 \times 10^{-16}$, ou seja, cerca de 16 algarismos decimais significativos. Em precisão simples, $\varepsilon_{\text{máq}} = 2^{-23} \approx 1{,}2 \times 10^{-7}$, cerca de 7 algarismos.

1.9 Erros absoluto e relativo

Definição 1.2. Seja $\bar{x}$ uma aproximação de x. O *erro absoluto* é $EA_x = x - \bar{x}$ e o *erro relativo* é

$$ER_x = \frac{EA_x}{\bar{x}} = \frac{x - \bar{x}}{\bar{x}}$$

(na prática, divide-se pelo valor aproximado, que é o conhecido; quando x é conhecido, como nos aplicativos, pode-se dividir por x).

Em geral só $\bar{x}$ é conhecido, e o que se obtém é um limitante do erro. Se $\pi \in (3{,}14;\ 3{,}15)$ e tomamos $\bar{\pi}$ nesse intervalo, então $|EA_\pi| < 0{,}01$.

Exemplo: o erro relativo compara melhor

Seja $\bar{x} = 2112{,}9$ com $|EA_x| < 0{,}1$, isto é, $x \in (2112{,}8;\ 2113)$, e $\bar{y} = 5{,}3$ com $|EA_y| < 0{,}1$, isto é, $y \in (5{,}2;\ 5{,}4)$. Os erros absolutos têm o mesmo limitante, mas

$$|ER_x| < \frac{0{,}1}{2112{,}9} \approx 4{,}7 \times 10^{-5}, \qquad |ER_y| < \frac{0{,}1}{5{,}3} \approx 0{,}02.$$

O número x está representado com precisão muito maior que y.

1.10 Operações em ponto flutuante e propagação de erros

Mesmo quando as parcelas são exatas, o resultado de uma operação precisa ser normalizado e arredondado (ou truncado) para t dígitos. O resultado aproximado $\overline{OP}$ é o que fica na memória.

Exemplo: adição e multiplicação com $t = 4$

Sejam $x = 0{,}937 \times 10^4$ e $y = 0{,}1272 \times 10^2$.
Adição. É preciso alinhar as vírgulas: a mantissa do número de menor expoente é deslocada para a direita tantas casas quanto a diferença dos expoentes:

$$x + y = (0{,}937 + 0{,}001272) \times 10^4 = 0{,}938272 \times 10^4.$$

Com $t = 4$: $\overline{x + y} = 0{,}9383 \times 10^4$ (arredondamento) ou $0{,}9382 \times 10^4$ (truncamento).
Multiplicação. $xy = (0{,}937 \times 0{,}1272) \times 10^6 = 0{,}1191864 \times 10^6$, logo $\overline{xy} = 0{,}1192 \times 10^6$ (arredondamento) ou $0{,}1191 \times 10^6$ (truncamento).

Supondo as parcelas representadas exatamente, o erro relativo de uma operação é $|ER_{OP}| < 10^{-t+1}$ no truncamento e $|ER_{OP}| < \frac{1}{2} \times 10^{-t+1}$ no arredondamento.

1.10.1 Fórmulas de propagação

Sejam $x = \bar{x} + EA_x$ e $y = \bar{y} + EA_y$. Desprezando os produtos de erros, que são muito pequenos:

operação	erro absoluto	erro relativo
$x + y$	$EA_{x+y} = EA_x + EA_y$	$ER_{x+y} = ER_x \dfrac{\bar{x}}{\bar{x}+\bar{y}} + ER_y \dfrac{\bar{y}}{\bar{x}+\bar{y}}$
$x - y$	$EA_{x-y} = EA_x - EA_y$	$ER_{x-y} = ER_x \dfrac{\bar{x}}{\bar{x}-\bar{y}} - ER_y \dfrac{\bar{y}}{\bar{x}-\bar{y}}$
xy	$EA_{xy} \approx \bar{x}\,EA_y + \bar{y}\,EA_x$	$ER_{xy} \approx ER_x + ER_y$
x/y	$EA_{x/y} \approx \dfrac{\bar{y}\,EA_x - \bar{x}\,EA_y}{\bar{y}^{\,2}}$	$ER_{x/y} \approx ER_x - ER_y$

Na divisão, usa-se $\dfrac{1}{1+EA_y/\bar{y}} = 1 - \dfrac{EA_y}{\bar{y}} + \left(\dfrac{EA_y}{\bar{y}}\right)^2 - \cdots$ e desprezam-se as potências maiores que 1. A cada operação soma-se ainda o erro de arredondamento do próprio resultado, limitado por $\frac{1}{2}\varepsilon_{\text{máq}}$.

1.10.2 Cancelamento

Na subtração, os fatores $\bar{x}/(\bar{x}-\bar{y})$ e $\bar{y}/(\bar{x}-\bar{y})$ ficam enormes quando $\bar{x} \approx \bar{y}$. Os algarismos iniciais iguais se cancelam e sobram os finais, justamente os contaminados por erro. É o **cancelamento**.

Exemplo: reescrever para evitar o cancelamento

Com $t = 6$ dígitos decimais, calcule $\sqrt{x+1} - \sqrt{x}$ para $x = 10^8$: $\sqrt{100\,000\,001} = 10\,000{,}000\,05 \approx 0{,}100000 \times 10^5$ e $\sqrt{10^8} = 0{,}100000 \times 10^5$, cuja diferença é 0. Racionalizando,

$$\sqrt{x+1} - \sqrt{x} = \frac{1}{\sqrt{x+1}+\sqrt{x}} \approx \frac{1}{0{,}200000 \times 10^5} = 0{,}500000 \times 10^{-4},$$

que é o valor correto ($4{,}9999999875 \times 10^{-5}$) com 6 algarismos.

Exemplo: derivada numérica de $\sin x$ em $x = 1$

A derivada é aproximada por $\dfrac{\sin(1+h) - \sin 1}{h}$; o valor exato é $\cos 1 \approx 0{,}5403023$. Em precisão dupla:

h	aproximação	erro
10^{-1}	0,4973637525	$4{,}3 \times 10^{-2}$
10^{-4}	0,5402602314	$4{,}2 \times 10^{-5}$
10^{-8}	0,5403023029	$3{,}0 \times 10^{-9}$
10^{-12}	0,5403455461	$4{,}3 \times 10^{-5}$
10^{-15}	0,5551115123	$1{,}5 \times 10^{-2}$
10^{-16}	0	$5{,}4 \times 10^{-1}$

Até $h \approx 10^{-8} \approx \sqrt{\varepsilon_{\text{máq}}}$, o erro cai junto com h (erro de truncamento da fórmula). Depois, $\sin(1+h)$ e $\sin 1$ ficam tão próximos que o cancelamento domina. Com $h = 10^{-16}$, $1+h$ é arredondado para 1 e a diferença é zero. A diferença central $\frac{\sin(1+h)-\sin(1-h)}{2h}$ atinge erro de 10^{-11} com $h \approx 10^{-5}$.

Observação

Outros cuidados que vêm da aritmética finita:

- a adição não é associativa: $(x+y)+z$ pode ser diferente de $x+(y+z)$;
- somar um número muito pequeno a um muito grande pode não mudar nada: em precisão dupla, $1 + 2^{-53} = 1$;
- não teste igualdade de números reais (`if x == 0.3`); use uma tolerância, $|x - 0{,}3| < \varepsilon$. Em Python, `0.1 + 0.2` mostra `0.30000000000000004`.

1.11 Exercícios

1. Converta para a base 10: (a) $(101101)_2$; (b) $(0{,}1011)_2$; (c) $(157)_8$; (d) $(3A{,}8)_{16}$.
2. Converta 45,625 para as bases 2, 8 e 16.
3. Mostre que $0{,}1 = (0{,}0\overline{0011})_2$. Quantos bits seriam necessários para guardar 0,1 exatamente?
4. Represente 13,25 em precisão simples (32 bits) e dê a palavra em hexadecimal.
5. Decodifique a palavra de 32 bits `0 10000001 01000000000000000000000`.
6. Na máquina de 8 bits ($1+3+4$, bias 3), decodifique: (a) `0 101 0110`; (b) `1 001 1000`; (c) `0 000 0011`; (d) `0 111 0000`.
7. Na máquina de 8 bits, codifique $x = 2{,}7$ por arredondamento e por truncamento e calcule os erros absoluto e relativo.
8. Em $F(2, 3, 1, 2)$, quantos números existem? Qual o maior e qual o menor positivo?
9. Com $t = 4$ e arredondamento, calcule $(x+y) - x$ para $x = 0{,}3491 \times 10^4$ e $y = 0{,}2345 \times 10^0$. Compare com y.
10. Explique por que, em precisão dupla, $1 + 2^{-53} = 1$, mas $1 + 2^{-52} \neq 1$.
11. Calcule $\sqrt{x+1} - \sqrt{x}$ para $x = 10^8$ com $t = 6$ dígitos, diretamente e após racionalizar.

Respostas

1. (a) 45; (b) 0,6875; (c) 111; (d) 58,5.
2. $(101101{,}101)_2 = (55{,}5)_8 = (2D{,}A)_{16}$.
3. As multiplicações dão a sequência $0{,}2 \to 0{,}4 \to 0{,}8 \to 0{,}6 \to 0{,}2$, que se repete. Nenhuma quantidade finita de bits basta.
4. $13{,}25 = (1101{,}01)_2 = (1{,}10101)_2 \times 2^3$: $s = 0$, $E = 130 = (10000010)_2$, $f =$ `10101`$\ldots 0$; palavra 41540000_{16}.
5. $(1{,}01)_2 \times 2^{129-127} = 1{,}25 \times 4 = 5$.
6. (a) $(1{,}0110)_2 \times 2^2 = 5{,}5$; (b) $-(1{,}1)_2 \times 2^{-2} = -0{,}375$; (c) subnormal $3/64 = 0{,}046875$; (d) $+\infty$.
7. $2{,}7 = (1{,}0101\,1001\ldots)_2 \times 2^1$. Arredondamento: `0 100 0110`$= 2{,}75$, $EA = -0{,}05$, $ER \approx -1{,}85 \times 10^{-2}$. Truncamento: `0 100 0101`$= 2{,}625$, $EA = 0{,}075$, $ER \approx 2{,}78 \times 10^{-2}$.
8. $2 \cdot 1 \cdot 4 \cdot 4 + 1 = 33$ números; maior $(0{,}111)_2 \times 2^2 = 3{,}5$; menor positivo $(0{,}100)_2 \times 2^{-1} = 0{,}25$.
9. $x + y = 3491{,}2345 \to 0{,}3491 \times 10^4$, logo $(x + y) - x = 0$, embora $y \neq 0$: o y foi "absorvido".
10. O número seguinte a 1 em precisão dupla é $1 + 2^{-52}$. O valor $1 + 2^{-53}$ está exatamente no meio e, pelo empate para o par, é arredondado para 1.
11. Diretamente: 0. Racionalizando: $0{,}500000 \times 10^{-4}$ (exato: $4{,}9999999875 \times 10^{-5}$).

Referências

- M. A. G. Ruggiero e V. L. R. Lopes, *Cálculo Numérico: aspectos teóricos e computacionais*, 2.ª ed., Makron Books.
- M. L. Overton, *Numerical Computing with IEEE Floating Point Arithmetic*, SIAM, 2001.
- IEEE Std 754-2019, *IEEE Standard for Floating-Point Arithmetic*.

Capítulo 2

Zeros de funções

Como usar os aplicativos e os textos deste capítulo

Os quadros laranja *Atividade no GeoGebra* trazem o link **[abrir o aplicativo]**. São nove aplicativos:

- bisseção: versão 1, em [1,6; 1,8] e versão 2, em [1,2; 2];
- posição falsa: versão 1 e versão 2, com tolerâncias;
- ponto fixo: $\varphi(x) = \frac{2(1+x)}{x+2}$, exemplo que converge e exemplo que diverge;
- Newton-Raphson e secante.

Em todos eles há três botões: **INICIAR** (restaura os dados iniciais), **Xk** (faz uma iteração por clique, mostrando no gráfico a construção do método) e **JAVASCRIPT** (executa o laço completo e mostra a tabela das iterações numa janela).
Os quadros verdes *Leitura complementar* abrem dois textos de apoio: laços de repetição e fluxogramas.
Para que os links funcionem, mantenha este PDF e as pastas `ggb` e `complementos` juntos e abra o PDF num leitor que permita abrir arquivos externos (Adobe Acrobat Reader, Okular, SumatraPDF, Foxit). Os leitores de PDF dos navegadores costumam bloquear esses links; nesse caso, abra os arquivos diretamente das pastas.

2.1 O problema

Queremos encontrar $\bar{x}$ tal que $f(\bar{x}) = 0$, isto é, um *zero* (ou *raiz*) de f. Para polinômios de grau até 4 há fórmulas, mas para equações como

$$x \ln x - 1 = 0, \qquad x^5 - x^3 + x^2 - 3 = 0, \qquad \cos x = x$$

não há expressão fechada para a solução. Os métodos numéricos produzem uma sequência de aproximações $x_0, x_1, x_2, \ldots$ que converge para $\bar{x}$, e param quando a aproximação é boa o bastante.

O trabalho tem duas fases:

1. **isolamento**: encontrar um intervalo $[a, b]$ que contenha uma única raiz (ou uma boa aproximação inicial);
2. **refinamento**: melhorar a aproximação até a precisão desejada.

Ao longo do capítulo, usaremos a função $f(x) = x^2 - 2$, cujo zero positivo é $\sqrt{2} \approx 1{,}414214$, para comparar os métodos. Como sabemos a resposta, fica fácil observar a velocidade de cada um.

2.2 Isolamento das raízes

Teorema 2.1 (Bolzano). *Se f é contínua em $[a,b]$ e $f(a)\,f(b) < 0$, então existe pelo menos um $\bar{x} \in (a,b)$ com $f(\bar{x}) = 0$. Se, além disso, f' existe e não muda de sinal em (a,b), a raiz é única.*

Exemplo: tabela de sinais

Para $f(x) = x^3 - 9x + 3$:

x	-4	-3	-2	-1	0	1	2	3	4
$f(x)$	-25	3	13	11	3	-5	-7	3	31
sinal	$-$	$+$	$+$	$+$	$+$	$-$	$-$	$+$	$+$

Há mudanças de sinal em $[-4,-3]$, $[0,1]$ e $[2,3]$. Como f tem grau 3, essas são as três raízes.

Exemplo: a função dos aplicativos de bisseção

Para $f(x) = x\ln x - 1$ (com $x > 0$), temos $f(1) = -1 < 0$ e $f(2) = 2\ln 2 - 1 \approx 0{,}386 > 0$. Como $f'(x) = \ln x + 1 > 0$ em $[1,2]$, há uma única raiz nesse intervalo: $\bar{x} \approx 1{,}763223$. Graficamente, ela é a abscissa do ponto em que $\ln x = \frac{1}{x}$.

Observação

Mudança de sinal é condição suficiente, não necessária: uma raiz de multiplicidade par não troca o sinal de f. Por exemplo, $f(x) = x^3 - 5x^2 + 8x - 4 = (x-1)(x-2)^2$ (a função dos aplicativos de posição falsa) tem uma raiz dupla em $x = 2$, onde o gráfico só tangencia o eixo. Os métodos de intervalo (bisseção e posição falsa) não conseguem "cercar" essa raiz.

2.3 Critérios de parada e laços de repetição

Todos os métodos deste capítulo são *iterativos*: repetem o mesmo cálculo até que um critério de parada seja satisfeito. Dada uma tolerância ε, os critérios mais usados são

$$\text{(i) } |x_k - x_{k-1}| < \varepsilon, \qquad \text{(ii) } |f(x_k)| < \varepsilon, \qquad \text{(iii) } \frac{|x_k - x_{k-1}|}{|x_k|} < \varepsilon,$$

$$\text{(iv) } |b_k - a_k| < \varepsilon \text{ (métodos de intervalo)},$$

sempre acompanhados de um número máximo de iterações, para evitar um laço infinito quando o método não converge.

Nenhum critério isolado é perfeito: $|f(x_k)|$ pode ser pequeno longe da raiz (função muito "achatada") e $|x_k - x_{k-1}|$ pode ser pequeno sem que se esteja perto dela (convergência muito lenta). Por isso, é comum combinar dois critérios, e a escolha entre *e* e *ou* importa:

- **continuar enquanto** $|b-a| > \varepsilon_1$ **ou** $|f(x_k)| > \varepsilon_2$: só para quando *os dois* critérios forem satisfeitos (mais exigente). É o que fazem os aplicativos de bisseção, com as tolerâncias tol_1 e tol_2;
- **continuar enquanto** $|x_k - x_{k-1}| > \varepsilon$ **e** $|f(x_k)| > \varepsilon$: para quando *um* deles for satisfeito (menos exigente). É o que fazem os botões JAVASCRIPT dos aplicativos de posição falsa, secante, Newton e ponto fixo.

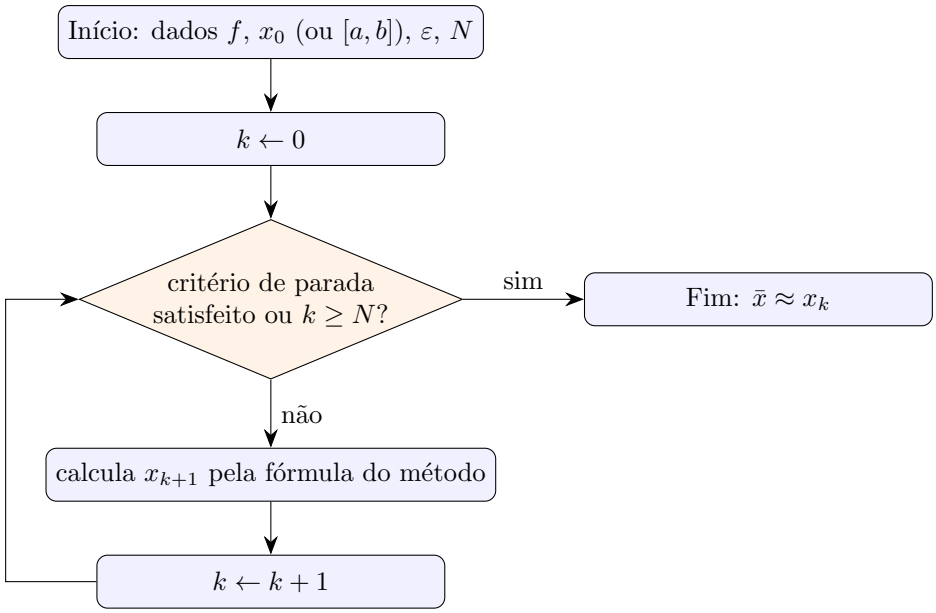


Figura 2.1: Fluxograma comum a todos os métodos iterativos: um laço `while`.

Em linguagem de programação, esse fluxograma é um laço `while`. O botão JAVASCRIPT dos aplicativos de bisseção, por exemplo, executa (resumidamente):

```
var k = 0;  var xk = (a + b) / 2;
while (F(xk) !== 0 && (Math.abs(b - a) > tol1 || Math.abs(F(xk)) > tol2) && k < 200) {
    if (F(a) * F(xk) > 0) { a = xk; } else { b = xk; }   // escolhe o novo intervalo
    k++;
    xk = (a + b) / 2;                                    // novo ponto medio
}
```

A condição `k < 200` é o número máximo de iterações, que impede um laço infinito.

Leitura complementar: laços de repetição e fluxogramas (4 páginas) [abrir o texto]

Introdução aos laços `for` e `while`, com exemplos em Python e fluxogramas: variável de controle, condição lógica, contador e acumulador, laço infinito, `break` e `continue`. É a base para ler e escrever o código dos botões JAVASCRIPT dos aplicativos.

Arquivo: `complementos/material_lacos_fluxograma.pdf`

2.4 Método da bisseção

Partindo de $[a_0, b_0]$ com $f(a_0)f(b_0) < 0$, calculamos o ponto médio

$$x_k = \frac{a_k + b_k}{2}$$

e ficamos com a metade em que há troca de sinal: se $f(a_k)f(x_k) < 0$, então $[a_{k+1}, b_{k+1}] = [a_k, x_k]$; caso contrário, $[a_{k+1}, b_{k+1}] = [x_k, b_k]$.

Proposição 2.2 (Estimativa do erro)**.** *Como o intervalo é dividido ao meio a cada passo,*

$|\bar{x} - x_k| \le \dfrac{b_k - a_k}{2} = \dfrac{b_0 - a_0}{2^{k+1}}$. *Para garantir erro menor que* ε *com o critério* $b_k - a_k < \varepsilon$, *bastam*

$$k > \log_2 \frac{b_0 - a_0}{\varepsilon}$$

iterações, número que se conhece antes *de começar.*

Exemplo: três iterações para $f(x) = x^2 - 2$ em $[1, 2]$

$f(1) = -1 < 0$ e $f(2) = 2 > 0$.

k	a_k	b_k	$x_k = \frac{a_k+b_k}{2}$	$f(x_k)$	novo intervalo
1	1	2	1,5	0,25	[1; 1,5]
2	1	1,5	1,25	−0,4375	[1,25; 1,5]
3	1,25	1,5	1,375	−0,109375	[1,375; 1,5]

Em cada linha, o novo intervalo é escolhido pelo sinal de $f(x_k)$. Para obter $b_k - a_k < 10^{-3}$, seriam necessárias $\log_2(1/10^{-3}) \approx 9{,}97$, isto é, 10 iterações.

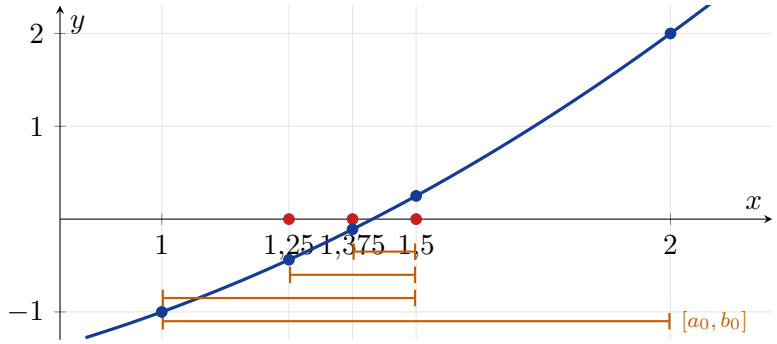


Figura 2.2: Bisseção para $f(x) = x^2 - 2$: a cada passo o intervalo (em laranja) cai pela metade.

Atividade no GeoGebra: bisseção (versão 1) **[abrir o aplicativo]**

A função é $f(x) = x \ln x - 1$. O botão INICIAR usa $[a, b] = [1{,}6;\ 1{,}8]$ e $tol_1 = tol_2 = 0{,}001$, que podem ser alteradas nas caixas tol_1 e tol_2. O botão Xk só avança enquanto $f(a)f(b) < 0$ e ($|b - a| > tol_1$ ou $|f(x_k)| > tol_2$).

1. Clique em INICIAR e depois em Xk repetidas vezes, anotando a_k, b_k, x_k e $f(x_k)$. Confira: $x_0 = 1{,}7$; $x_1 = 1{,}75$; $x_2 = 1{,}775$; $x_3 = 1{,}7625$.
2. Em que iteração o botão deixa de avançar? (Esperado: $k = 8$, com $[a, b] = [1{,}7625;\ 1{,}763281]$, $|b - a| \approx 0{,}00078$ e $|f(x_k)| \approx 0{,}00052$.) Compare com a estimativa $\log_2(0{,}2/0{,}001) \approx 7{,}6$.
3. Use o botão JAVASCRIPT para ver todas as iterações de uma vez. Ele lê a, b, tol_1 e tol_2 do aplicativo; teste com $tol_1 = tol_2 = 10^{-6}$.
4. Escolha com os controles deslizantes um intervalo sem troca de sinal, por exemplo $[2; 3]$. O que acontece?

Arquivo:
ggb/metodoBisseccao_2026_corrigido.ggb

Atividade no GeoGebra: bisseção (versão 2, intervalo maior)[abrir o aplicativo]

Mesma função, mas o botão INICIAR usa $[a, b] = [1{,}2;\ 2]$, e o texto mostra também os dados da iteração inicial (a_0, b_0, x_0). Os dois arquivos de bisseção trazem ainda uma tabela na Planilha (menu Exibir → Planilha) que executa o algoritmo célula a célula, com as colunas a, b, x_k, $f(a)$, $f(x_k)$, $f(a)f(x_k)$, a_k, b_k e $|b_k - a_k|$.

1. Quantas iterações são necessárias agora? (Esperado: $k = 10$.) Por que são duas a mais que na versão 1? (Sugestão: compare $b_0 - a_0$ nos dois casos.)
2. Na Planilha, a primeira linha da tabela usa as células $B22$ (a) e $C22$ (b). Digite nelas 1 e 2 e acompanhe linha a linha: como cada linha obtém a_k e b_k a partir da anterior? A coluna $|b_k - a_k|$ é sempre dividida por 2?

Arquivo:
ggb/metodoBisseccao_2026_correto_and.ggb

2.5 Método da posição falsa

Em vez do ponto médio, usamos o ponto em que a reta que liga $(a, f(a))$ a $(b, f(b))$ corta o eixo x:

$$x_k = \frac{a_k\, f(b_k) - b_k\, f(a_k)}{f(b_k) - f(a_k)}.$$

A escolha do novo intervalo é igual à da bisseção. Quando $|f(a)|$ e $|f(b)|$ são muito diferentes, x_k tende a ficar mais perto da raiz do que o ponto médio.

Exemplo: três iterações para $f(x) = x^2 - 2$ em $[1, 2]$

k	a_k	b_k	x_k	$f(x_k)$	novo intervalo
1	1	2	$4/3 \approx 1{,}333333$	$-0{,}222222$	[1,333333; 2]
2	1,333333	2	1,400000	$-0{,}040000$	[1,4; 2]
3	1,4	2	1,411765	$-0{,}006920$	[1,411765; 2]

Por exemplo, $x_1 = \frac{1\cdot 2 - 2\cdot(-1)}{2-(-1)} = \frac{4}{3}$. Repare que a extremidade $b = 2$ *nunca muda*: como f é convexa, todas as aproximações ficam do mesmo lado da raiz. Assim, $b_k - a_k$ não tende a zero, e o critério de parada deve usar $|f(x_k)|$ ou $|x_k - x_{k-1}|$.

Atividade no GeoGebra: posição falsa (versão 1) [abrir o aplicativo]

A função é $f(x) = x^3 - 5x^2 + 8x - 4 = (x-1)(x-2)^2$, com $[a, b] = [0{,}5;\ 1{,}7]$ no botão INICIAR. O gráfico mostra a reta secante g que define cada x_k.

1. Confira $x_1 \approx 1{,}636364$, $x_2 \approx 1{,}557282$, $x_3 \approx 1{,}463714$.
2. Qual extremidade fica fixa? Avance 10 iterações: $x_{10} \approx 1{,}022$, ainda longe de $\bar{x} = 1$. Por que a convergência é tão lenta aqui? (Observe o formato do gráfico perto de $x = 1$ e o valor de $f(a)$.)
3. Tente um intervalo que contenha $x = 2$, como [1,5; 2,5]. O aplicativo avisa "$f(a)f(b) > 0$". Explique usando a raiz dupla.
4. O botão JAVASCRIPT resolve outro exemplo, $f(x) = x^2 - 2$ em [0,5; 2] com $\varepsilon = 10^{-4}$. Compare a velocidade com a da função do gráfico.

Arquivo:
ggb/metodoposicaofalsa_2026_correto.ggb

Atividade no GeoGebra: posição falsa (versão 2, com tolerâncias) [abrir o aplicativo]

Mesma função, agora com $[a, b] = [0{,}2;\ 1{,}5]$ e as tolerâncias $tol_1 = tol_2 = 0{,}001$; o texto mostra a_0, b_0, x_0 e os erros a cada passo.

1. Faça 5 iterações e confira $x_5 \approx 1{,}199928$ (com $a = 0{,}2$ fixo).
2. Compare $|b_k - a_k|$ e $|f(x_k)|$ ao longo das iterações. Qual dos dois critérios seria atingido primeiro?

Arquivo:
ggb/metodoposicaofalsa_2026_correto_and.ggb

2.6 Método do ponto fixo

Reescrevemos $f(x) = 0$ numa forma equivalente $x = \varphi(x)$ e iteramos

$$x_{k+1} = \varphi(x_k).$$

Um ponto com $\bar{x} = \varphi(\bar{x})$ é um *ponto fixo* de φ e, portanto, um zero de f. Graficamente, é a interseção de $y = \varphi(x)$ com a reta $y = x$, e as iterações formam o diagrama em "teia" ou "escada" (Figura 2.3).

Teorema 2.3 (Convergência do ponto fixo)**.** *Se φ e φ' são contínuas num intervalo I que contém $\bar{x}$, $\varphi(I) \subset I$ e $|\varphi'(x)| \le L < 1$ para todo $x \in I$, então, para qualquer $x_0 \in I$, a sequência $x_{k+1} = \varphi(x_k)$ converge para o único ponto fixo $\bar{x}$ em I, e $|x_{k+1} - \bar{x}| \le L\,|x_k - \bar{x}|$. Se $|\varphi'(\bar{x})| > 1$, as iterações se afastam de $\bar{x}$.*

Se $\varphi' > 0$ perto da raiz, as aproximações se aproximam de um só lado (escada); se $\varphi' < 0$, elas alternam em torno da raiz (teia). Quanto menor $|\varphi'(\bar{x})|$, mais rápida a convergência.

Exemplo: $f(x) = x^2 - 2$ com $\varphi(x) = \frac{x+2}{x+1}$ e $x_0 = 1$

De $x^2 = 2$ vem $x^2 + x = x + 2$, isto é, $x = \frac{x+2}{x+1}$. Temos $\varphi'(x) = -\frac{1}{(x+1)^2}$, e em $[1, 2]$ vale $|\varphi'(x)| \le \frac{1}{4} < 1$; além disso, $\varphi([1, 2]) = [\frac{4}{3}, \frac{3}{2}] \subset [1, 2]$. Logo, há convergência.

k	x_k	$x_{k+1} = \varphi(x_k)$	$f(x_{k+1})$	$\lvert x_{k+1} - x_k\rvert$
0	1	1,5	0,25	0,5
1	1,5	1,4	−0,04	0,1
2	1,4	$17/12 \approx 1{,}416667$	0,006944	0,016667

Como $\varphi' < 0$, os iterados alternam em torno de $\sqrt{2}$, e o erro cai cerca de $|\varphi'(\sqrt{2})| \approx 0{,}17$ a cada passo.

Nem toda φ serve. A mesma equação pode ser escrita como $x = \frac{2}{x}$. Agora $|\varphi'(\sqrt{2})| = 1$, e com $x_0 = 1$ obtemos $2, 1, 2, 1, \ldots$: a sequência nunca se aproxima de $\sqrt{2}$.

Atividade no GeoGebra: ponto fixo com $\varphi(x) = \frac{2(1+x)}{x+2}$ [abrir o aplicativo]

Aqui $f(x) = x^2 - 2$ e $\varphi(x) = \frac{2(1+x)}{x+2}$ (verifique que $x = \varphi(x) \iff x^2 = 2$). O botão INICIAR usa $[a, b] = [1; 3]$ e $x_0 = b - 0{,}3 = 2{,}7$, e o gráfico mostra a escada (vetores), φ

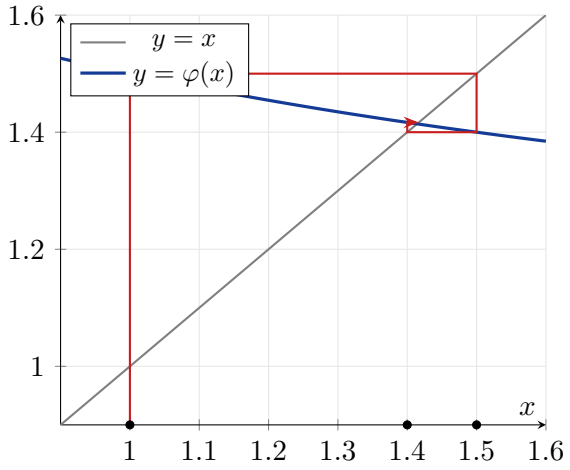


Figura 2.3: Diagrama em teia para $\varphi(x) = \frac{x+2}{x+1}$ a partir de $x_0 = 1$: os iterados alternam em torno de $\sqrt{2}$.

e $|\varphi'|$. O texto indica "Continue" ou "Pare" conforme os critérios $|x_{k+1} - x_k| > 10^{-5}$ e $|f(x_{k+1})| > 10^{-4}$.

1. Confira $x_1 \approx 1{,}574468$, $x_2 \approx 1{,}440476$, $x_3 \approx 1{,}418685$.
2. Calcule $\varphi'(x) = \frac{2}{(x+2)^2}$. Por que a convergência é monótona (escada) e não alternada? Quanto vale $|\varphi'(\sqrt{2})|$?
3. Use os botões "Apaga/Mostrar o Graf $f(x)$ e $\varphi'(x)$" e verifique que $|\varphi'(x)| < 1$ em todo o intervalo $[1, 3]$.
4. O botão JAVASCRIPT resolve outro exemplo: $x \ln x - 1 = 0$ com $\varphi(x) = e^{1/x}$ e $x_0 = 1{,}3$. Mostre que $\varphi'(\bar{x}) = -1/\bar{x} \approx -0{,}57$ e explique por que essa convergência é alternada e bem mais lenta.

Arquivo:
ggb/metodopontofixoJAVASCRIPT_2026_final_corrigido.ggb

Atividade no GeoGebra: ponto fixo que converge e ponto fixo que diverge [abrir o aplicativo]

Os dois aplicativos tratam $f(x) = x^2 - x - 2 = (x-2)(x+1)$, com $x_0 = 2{,}7$, mas com funções de iteração diferentes:

- versão que converge: $\varphi(x) = x - \dfrac{x^2 - x - 2}{2x - 1}$;
- versão que diverge: $\varphi(x) = x^2 - 2$.

1. Na versão que converge, confira $x_1 \approx 2{,}111364$, $x_2 \approx 2{,}003848$, $x_3 \approx 2{,}000005$. Que método é esse? (Compare φ com a fórmula de Newton.)
2. Na versão que diverge, confira $x_1 = 5{,}29$ e $x_2 \approx 25{,}98$. Calcule $\varphi'(2) = 4$ e explique a divergência pelo teorema.
3. Nas duas versões, ligue o gráfico de $|\varphi'|$ e compare-o com a reta $y = 1$ perto de $x = 2$.

Arquivo da versão que diverge:
ggb/metodopontofixoJAVASCRIPT_2026_CORRIGIDO_ex02_DIVERGINDO.ggb

Arquivo:
ggb/metodopontofixoJAVASCRIPT_2026_CORRIGIDO_ex02_CONVERGINDO.ggb

2.7 Método de Newton-Raphson

Aproximamos f pela reta tangente em x_k e tomamos o ponto em que ela corta o eixo x:

$$x_{k+1} = x_k - \frac{f(x_k)}{f'(x_k)}, \qquad f'(x_k) \neq 0.$$

É o método do ponto fixo com $\varphi(x) = x - \frac{f(x)}{f'(x)}$. Como $\varphi'(\bar{x}) = 0$ quando $f'(\bar{x}) \neq 0$, a convergência perto de uma raiz simples é *quadrática*: grosso modo, o número de algarismos corretos dobra a cada iteração.

Exemplo: três iterações para $f(x) = x^2 - 2$ com $x_0 = 2$

$f'(x) = 2x$, e então $x_{k+1} = x_k - \frac{x_k^2 - 2}{2x_k}$.

k	x_k	$f(x_k)$	$f'(x_k)$	x_{k+1}	$f(x_{k+1})$
0	2	2	4	1,5	0,25
1	1,5	0,25	3	1,416667	0,006944
2	1,416667	0,006944	2,833333	1,414216	6×10^{-6}

Em três iterações já temos $\sqrt{2}$ com 5 casas corretas.

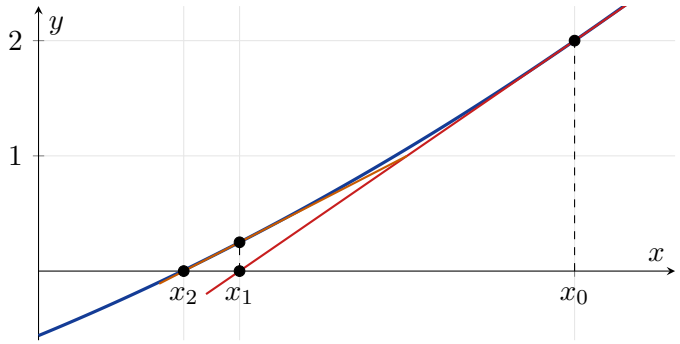


Figura 2.4: Newton para $f(x) = x^2 - 2$: cada nova aproximação é o zero da reta tangente.

Cuidados. Newton exige f' e um bom chute inicial. Se $f'(x_k) \approx 0$, o passo $f(x_k)/f'(x_k)$ fica enorme e a sequência pode "saltar" para longe, convergir para outra raiz ou nem convergir.

Atividade no GeoGebra: Newton-Raphson [abrir o aplicativo]

A função é $f(x) = x^5 - x^3 + x^2 - 3$, e o aplicativo calcula f' e desenha a reta tangente h em cada passo. O botão INICIAR usa $x_0 = 1$; o chute também pode ser digitado na caixa x_0.

1. Confira $x_1 = 1{,}5$, $x_2 \approx 1{,}339130$, $x_3 \approx 1{,}286935$, $x_4 \approx 1{,}282090$, $x_5 \approx 1{,}282051$. Quantas casas corretas cada iteração acrescenta?
2. Note que $x_1 = 1{,}5$ passou do outro lado da raiz. Por que, depois disso, todas as aproximações se aproximam pela direita? (Observe a concavidade de f.)
3. Experimente $x_0 = 0$: a tangente é horizontal ($f'(0) = 0$) e o método não pode ser aplicado. Com $x_0 = 0{,}3$, $f'(0{,}3) \approx 0{,}34$ é pequeno e $x_1 \approx 8{,}22$; quantas iterações são necessárias para voltar perto da raiz?

4. O botão JAVASCRIPT resolve $f(x) = x^3 - x^2 - x = 0$ com $x_0 = 0{,}9$ e $\varepsilon = 10^{-3}$. Como $f'(0{,}9) = -0{,}37$ é pequeno, $x_1 \approx -1{,}751$, e o método converge para a raiz $\frac{1-\sqrt{5}}{2} \approx -0{,}618$, e não para a raiz mais próxima, $\frac{1+\sqrt{5}}{2} \approx 1{,}618$. Explique o salto com a tangente.

Arquivo:
ggb/metodoNewtonRaphson_2026_corrigido.ggb

2.8 Método da secante

Para evitar o cálculo de f', substituímos a tangente pela secante que passa pelos dois últimos pontos:

$$x_{k+1} = x_k - \frac{f(x_k)\,(x_k - x_{k-1})}{f(x_k) - f(x_{k-1})}.$$

São necessários dois valores iniciais x_0, x_1. A fórmula lembra a da posição falsa, mas aqui *não* se mantém um intervalo com troca de sinal: usam-se sempre os dois últimos pontos. A convergência é superlinear (ordem $\approx 1{,}618$), mais rápida que a da posição falsa e um pouco mais lenta que a de Newton, sem precisar de derivada.

Exemplo: três iterações para $f(x) = x^2 - 2$ com $x_0 = 1$, $x_1 = 2$

iteração	x_{k-1}	x_k	$f(x_{k-1})$	$f(x_k)$	x_{k+1}
1	1	2	-1	2	$x_2 = 4/3 \approx 1{,}333333$
2	2	1,333333	2	$-0{,}222222$	$x_3 = 1{,}4$
3	1,333333	1,4	$-0{,}222222$	$-0{,}04$	$x_4 \approx 1{,}414634$

Na terceira iteração, $f(x_3)$ e $f(x_4)$ têm o mesmo sinal, e mesmo assim o método continua: não há intervalo a manter.

Atividade no GeoGebra: secante [abrir o aplicativo]

A função é $f(x) = x^2 - 2$, com $x_0 = a = 0{,}5$ e $x_1 = b = 2$ no botão INICIAR. A cada clique em Xk, o aplicativo traça a secante e substitui (a, b) por (b, x_{novo}).

1. Confira $x_2 = 1{,}2$, $x_3 = 1{,}375$, $x_4 \approx 1{,}417476$, $x_5 \approx 1{,}414168$, $x_6 \approx 1{,}414214$.
2. Em $x_2 = 1{,}2$ e $x_3 = 1{,}375$, os dois valores de f são negativos. A posição falsa aceitaria esse par? O que isso mostra sobre a diferença entre os dois métodos?
3. O botão JAVASCRIPT executa o mesmo exemplo com $\varepsilon = 10^{-4}$. Compare o número de iterações com o da posição falsa no mesmo intervalo (botão JAVASCRIPT do aplicativo de posição falsa).

Arquivo:
ggb/metododasecanteJAVASCRIPT_2026_CORRIGIDO.ggb

2.9 Comparação dos métodos

Para $f(x) = x^2 - 2$, com o critério $|x_k - x_{k-1}| < 10^{-6}$ (ou $b_k - a_k < 10^{-6}$ na bisseção):

Método	Dados iniciais	Iterações	Ordem	Exige
Bisseção	$[1, 2]$	20	linear (fator $\frac{1}{2}$)	troca de sinal
Posição falsa	$[1, 2]$	9	linear	troca de sinal
Ponto fixo	$x_0 = 1$, $\varphi = \frac{x+2}{x+1}$	9	linear (fator $\lvert\varphi'(\bar{x})\rvert$)	$\lvert\varphi'\rvert < 1$ perto da raiz
Newton	$x_0 = 2$	5	quadrática	f' e bom chute
Secante	$x_0 = 1$, $x_1 = 2$	6	$\approx 1{,}618$	dois chutes

- **Bisseção**: sempre converge (com troca de sinal) e o número de iterações é previsível, mas é lenta. Boa para obter um bom chute inicial.
- **Posição falsa**: em geral mais rápida que a bisseção, mas pode ficar lenta quando uma extremidade fica fixa (como no aplicativo com $(x-1)(x-2)^2$).
- **Ponto fixo**: simples, mas a convergência depende da escolha de φ.
- **Newton**: o mais rápido perto de raízes simples; exige a derivada e pode falhar com um chute ruim.
- **Secante**: quase tão rápida quanto Newton, sem derivada; também pode falhar longe da raiz.

Na prática, é comum combinar: alguns passos de bisseção para chegar perto da raiz e depois Newton ou secante para refinar.

2.10 Exercícios

1. Isole as raízes de $f(x) = x^3 - 9x + 3$ por uma tabela de sinais e justifique que há exatamente uma raiz em cada intervalo encontrado.

2. Para $f(x) = e^{-x} - x$ em $[0, 1]$:

(a) faça três iterações da bisseção, justificando a escolha de cada intervalo;
(b) quantas iterações garantem $b_k - a_k < 10^{-4}$?
(c) faça três iterações da posição falsa e compare.

3. Aplique o método de Newton a $f(x) = \cos x - x$ com $x_0 = 1$ até que $\lvert x_{k+1} - x_k\rvert < 10^{-6}$.

4. Aplique o método da secante a $f(x) = e^{-x} - x$ com $x_0 = 0$ e $x_1 = 1$ (quatro iterações).

5. A equação $x^3 - x - 1 = 0$ tem uma raiz em $[1, 2]$. Considere $\varphi_1(x) = \sqrt[3]{x+1}$ e $\varphi_2(x) = x^3 - 1$.

(a) mostre que as duas são funções de iteração para essa equação;
(b) calcule $\lvert\varphi_1'\rvert$ e $\lvert\varphi_2'\rvert$ perto da raiz e decida qual converge;
(c) faça cinco iterações com a função adequada, a partir de $x_0 = 1$.

6. Escreva, em Python, um laço `while` para o método de Newton aplicado a $f(x) = x^2 - 2$, que pare quando $\lvert x_{k+1} - x_k\rvert < 10^{-8}$ ou após 50 iterações. Desenhe o fluxograma correspondente.

7. (GeoGebra) No aplicativo de bisseção (versão 1), troque o critério de parada: use $tol_1 = 0{,}1$ e $tol_2 = 10^{-6}$. Em que iteração o método para? Qual dos dois critérios foi decisivo? Explique a diferença entre parar quando *os dois* critérios são satisfeitos e quando *um* deles é satisfeito.

8. (GeoGebra) Usando os aplicativos de ponto fixo, proponha uma terceira função de iteração para $x^2 - x - 2 = 0$, por exemplo $\varphi(x) = \sqrt{x+2}$, e preveja, calculando $\varphi'(2)$, se ela converge e se a convergência é monótona ou alternada.

Respostas

1. Trocas de sinal em $[-4,-3]$, $[0,1]$ e $[2,3]$; como f tem grau 3, cada intervalo tem exatamente uma raiz (também se verifica pelo sinal de $f'(x) = 3x^2 - 9$ em cada um).

2. (a) $x_1 = 0{,}5$ ($f > 0$, novo intervalo $[0{,}5; 1]$); $x_2 = 0{,}75$ ($f < 0$, $[0{,}5; 0{,}75]$); $x_3 = 0{,}625$ ($f < 0$, $[0{,}5; 0{,}625]$). (b) $k > \log_2 10^4 \approx 13{,}3$: 14 iterações. (c) $x_1 \approx 0{,}612700$, $x_2 \approx 0{,}572181$, $x_3 \approx 0{,}567703$ (com $a = 0$ fixo); a raiz é $\bar{x} \approx 0{,}567143$.

3. $x_1 \approx 0{,}750364$, $x_2 \approx 0{,}739113$, $x_3 \approx 0{,}739085133$, $x_4 \approx 0{,}739085133$.

4. $x_2 \approx 0{,}612700$, $x_3 \approx 0{,}563838$, $x_4 \approx 0{,}567170$, $x_5 \approx 0{,}567143$.

5. (b) Na raiz $\bar{x} \approx 1{,}3247$: $|\varphi_1'(\bar{x})| \approx 0{,}19 < 1$ (converge) e $|\varphi_2'(\bar{x})| = 3\bar{x}^2 \approx 5{,}3 > 1$ (diverge). (c) 1,259921; 1,312294; 1,322354; 1,324269; 1,324633.

6. Uma solução:

```
x, k = 2.0, 0
while k < 50:
    x_novo = x - (x**2 - 2) / (2*x)
    k = k + 1
    if abs(x_novo - x) < 1e-8:
        break
    x = x_novo
print(k, x_novo)
```

7. Para em $k = 15$ ($x_k \approx 1{,}7632233$, $|f(x_k)| \approx 7 \times 10^{-7}$). O critério do intervalo ($|b - a| \leq 0{,}1$) é atingido já em $k = 1$; o método só para quando também $|f(x_k)| \leq 10^{-6}$, portanto é o segundo critério que decide. Parar com *um* critério economiza iterações, mas pode parar cedo demais.

8. $\varphi'(x) = \frac{1}{2\sqrt{x+2}}$, $\varphi'(2) = \frac{1}{4}$: converge, de forma monótona (pois $\varphi' > 0$).

Capítulo 3

Sistemas lineares: métodos diretos e iterativos

Como usar os aplicativos e os textos deste capítulo

Os quadros laranja *Atividade no GeoGebra* trazem o link **[abrir o aplicativo]**, que abre o arquivo correspondente no GeoGebra Classic:

- Eliminação de Gauss, sistema 4×4;
- Fatoração $PA = LU$, matriz 3×3 e Fatoração $PA = LU$, matriz 4×4;
- Método de Gauss-Jacobi, sistema 3×3;
- Método de Gauss-Seidel, sistema 3×3.

Os quadros verdes *Leitura complementar* abrem dois textos de apoio sobre custo computacional: Custo computacional na resolução de sistemas lineares e Comparação computacional dos métodos diretos.

Para que os links funcionem, mantenha este PDF e as pastas `ggb` e `complementos` juntos, na mesma pasta, e abra o PDF num leitor que permita abrir arquivos externos (Adobe Acrobat Reader, Okular, SumatraPDF, Foxit). Os leitores de PDF dos navegadores costumam bloquear esses links; nesse caso, abra os arquivos diretamente das pastas.

Em todos os aplicativos, o aluno digita os valores pedidos (multiplicadores ou componentes da iteração) e recebe a correção imediata (✓/✗); cada etapa só é liberada quando a anterior está correta. Digite frações como `4/3`, sem arredondar.

3.1 Introdução

Um *sistema linear* de n equações e n incógnitas é

$$\begin{cases} a_{11}x_1 + a_{12}x_2 + \cdots + a_{1n}x_n = b_1 \\ a_{21}x_1 + a_{22}x_2 + \cdots + a_{2n}x_n = b_2 \\ \quad\vdots \\ a_{n1}x_1 + a_{n2}x_2 + \cdots + a_{nn}x_n = b_n \end{cases} \qquad \text{ou} \qquad A\mathbf{x} = \mathbf{b},$$

com $A = (a_{ij})$ a *matriz dos coeficientes*, $\mathbf{x}$ o vetor das incógnitas e $\mathbf{b}$ o vetor dos termos independentes. A matriz $[A \,|\, \mathbf{b}]$ é a *matriz aumentada*.

Sistemas lineares aparecem em quase todos os problemas de Cálculo Numérico: interpolação, ajuste de curvas, discretização de equações diferenciais, circuitos, estruturas, economia. Eles podem ser enormes (milhões de incógnitas), por isso importa não apenas *resolver*, mas resolver com poucas operações e com controle dos erros de arredondamento.

Definição 3.1. Um sistema linear é *possível e determinado* (SPD) se tem uma única solução, *possível e indeterminado* (SPI) se tem infinitas soluções e *impossível* (SI) se não tem solução. Para A quadrada, o sistema é SPD se, e somente se, $\det A \neq 0$.

Estudaremos duas famílias de métodos:

- **métodos diretos**, que, em aritmética exata, fornecem a solução exata após um número finito de operações: eliminação de Gauss e fatoração LU;
- **métodos iterativos**, que geram uma sequência $\mathbf{x}^{(0)}, \mathbf{x}^{(1)}, \mathbf{x}^{(2)}, \ldots$ que converge para a solução: Gauss-Jacobi e Gauss-Seidel.

3.2 Sistemas triangulares

Os métodos diretos reduzem o problema a sistemas triangulares, que são resolvidos facilmente. Se U é triangular superior com $u_{ii} \neq 0$, o sistema $U\mathbf{x} = \mathbf{y}$ é resolvido de baixo para cima (*retrossubstituição*):

$$x_n = \frac{y_n}{u_{nn}}, \qquad x_i = \frac{1}{u_{ii}}\Big(y_i - \sum_{j=i+1}^{n} u_{ij} x_j\Big), \quad i = n-1, \ldots, 1.$$

Se L é triangular inferior, $L\mathbf{y} = \mathbf{b}$ é resolvido de cima para baixo (*substituição progressiva*):

$$y_1 = \frac{b_1}{l_{11}}, \qquad y_i = \frac{1}{l_{ii}}\Big(b_i - \sum_{j=1}^{i-1} l_{ij} y_j\Big), \quad i = 2, \ldots, n.$$

Cada uma custa cerca de n^2 operações, muito menos que a eliminação ($\approx \frac{2}{3}n^3$).

3.3 Eliminação de Gauss

A eliminação de Gauss transforma $[A \,|\, \mathbf{b}]$ numa matriz triangular superior equivalente usando operações elementares sobre as linhas, que não alteram a solução:

- trocar duas linhas: $L_i \leftrightarrow L_j$;
- substituir uma linha por ela menos um múltiplo de outra: $L_i \leftarrow L_i - m\,L_k$.

O algoritmo. Na etapa k ($k = 1, \ldots, n-1$), o elemento $a_{kk}^{(k-1)}$ é o *pivô*. Se ele for nulo, troca-se a linha k com uma linha abaixo que tenha elemento não nulo na coluna k. Depois, para cada linha $i > k$, calcula-se o *multiplicador*

$$m_{ik} = \frac{a_{ik}^{(k-1)}}{a_{kk}^{(k-1)}} \qquad \text{e faz-se} \qquad L_i \leftarrow L_i - m_{ik} L_k,$$

o que zera a coluna k abaixo do pivô. Ao final, resolve-se o sistema triangular por retrossubstituição.

Exemplo: eliminação com trocas de linhas (exemplo inicial do aplicativo)

Resolva

$$[A\,|\,\mathbf{b}] = \left(\begin{array}{cccc|c} 0 & 1 & 2 & 1 & 4 \\ 1 & 1 & 1 & 0 & 2 \\ 2 & 1 & 0 & 1 & 2 \\ 1 & 0 & 1 & 1 & 4 \end{array}\right).$$

Etapa 1. O pivô $a_{11} = 0$; trocamos $L_1 \leftrightarrow L_2$. Agora o pivô é 1 e $m_{21} = 0$, $m_{31} = 2$, $m_{41} = 1$:

$$B_1 = \left(\begin{array}{cccc|c} 1 & 1 & 1 & 0 & 2 \\ 0 & 1 & 2 & 1 & 4 \\ 0 & -1 & -2 & 1 & -2 \\ 0 & -1 & 0 & 1 & 2 \end{array}\right).$$

Etapa 2. Pivô 1; $m_{32} = -1$, $m_{42} = -1$:

$$B_2 = \left(\begin{array}{cccc|c} 1 & 1 & 1 & 0 & 2 \\ 0 & 1 & 2 & 1 & 4 \\ 0 & 0 & 0 & 2 & 2 \\ 0 & 0 & 2 & 2 & 6 \end{array}\right).$$

Etapa 3. O pivô $(3,3)$ é zero; trocamos $L_3 \leftrightarrow L_4$, e então $m_{43} = 0$:

$$B_3 = \left(\begin{array}{cccc|c} 1 & 1 & 1 & 0 & 2 \\ 0 & 1 & 2 & 1 & 4 \\ 0 & 0 & 2 & 2 & 6 \\ 0 & 0 & 0 & 2 & 2 \end{array}\right).$$

Retrossubstituição: $x_4 = 1$, $x_3 = \frac{6-2}{2} = 2$, $x_2 = 4 - 2\cdot 2 - 1 = -1$, $x_1 = 2 - (-1) - 2 = 1$. Logo $\mathbf{x} = (1, -1, 2, 1)$, e o sistema é SPD.

Classificação pela forma escalonada. Se, ao final, aparece uma linha $(0\ \cdots\ 0\,|\,c)$ com $c \neq 0$, o sistema é *impossível*; se aparece $(0\ \cdots\ 0\,|\,0)$ e não há contradição, sobram variáveis livres e o sistema é *possível e indeterminado*.

Atividade no GeoGebra: eliminação de Gauss 4×4 [abrir o aplicativo]

O aplicativo começa com o sistema do exemplo acima. Em cada etapa, informe a linha do pivô (trocando linhas quando o pivô for zero) e os multiplicadores; as matrizes B_1, B_2, B_3 mostram o pivô em azul e, em vermelho, os elementos que ainda deveriam ser zero.

1. Refaça o exemplo no aplicativo e confira a solução com "Mostrar solução".
2. Clique em *Exemplo: troca + SPI*. Em que etapa é necessária a troca? Qual linha da matriz final mostra que o sistema é indeterminado? Qual variável fica livre?
3. Clique em *Exemplo: sistema impossível (SI)*. Qual linha da matriz final contém a contradição?
4. Gere sistemas com *Novo sistema aleatório (SPD)* até conseguir resolver três deles sem erros.

Arquivo:
ggb/EliminacaoGauss_sistema4x5_compacto.ggb

Pivoteamento parcial. Na aritmética do computador, um pivô muito pequeno gera multiplicadores enormes, que amplificam os erros de arredondamento. Por isso, na prática, escolhe-se como pivô o elemento de *maior módulo* da coluna (a partir da linha k) e trocam-se as linhas. Assim $|m_{ik}| \le 1$.

Exemplo: por que pivotear

Para $A = \begin{pmatrix} 10^{-17} & 1 \\ 1 & 1 \end{pmatrix}$ e $\mathbf{b} = (1, 2)$, a solução é $\mathbf{x} \approx (1, 1)$. Sem pivoteamento, $m_{21} = 10^{17}$ e a segunda equação vira $(1 - 10^{17})x_2 = 2 - 10^{17}$; em dupla precisão, $1 - 10^{17}$ e $2 - 10^{17}$ são arredondados para -10^{17}, e o programa obtém $x_2 = 1$ e $x_1 = 0$, totalmente errado. Com pivoteamento parcial, as linhas são trocadas, $m_{21} = 10^{-17}$, e obtém-se $\mathbf{x} = (1, 1)$.

3.4 Fatoração LU

Na eliminação de Gauss, os multiplicadores são usados e depois descartados. A fatoração LU os guarda numa matriz triangular inferior L; a matriz final escalonada é U.

Teorema 3.2 (Fatoração LU)**.** *Se a eliminação de Gauss pode ser feita sem trocas de linhas (todos os pivôs não nulos), então*

$$A = LU, \qquad L = \begin{pmatrix} 1 & & & \\ m_{21} & 1 & & \\ \vdots & & \ddots & \\ m_{n1} & m_{n2} & \cdots & 1 \end{pmatrix}, \qquad U = \text{matriz escalonada final.}$$

Em geral (com trocas), existe uma matriz de permutação P tal que $PA = LU$.

Para resolver $A\mathbf{x} = \mathbf{b}$, escrevemos $PA\mathbf{x} = P\mathbf{b}$, isto é, $LU\mathbf{x} = P\mathbf{b}$, e resolvemos dois sistemas triangulares:

$$L\mathbf{y} = P\mathbf{b} \quad \text{(substituição progressiva)}, \qquad U\mathbf{x} = \mathbf{y} \quad \text{(retrossubstituição)}.$$

Além disso, $\det A = (-1)^t \, u_{11} u_{22} \cdots u_{nn}$, onde t é o número de trocas.

Exemplo: fatoração sem trocas ($P = I$)

Para $A = \begin{pmatrix} 2 & 1 & 1 \\ 4 & 3 & 3 \\ 8 & 7 & 9 \end{pmatrix}$ e $\mathbf{b} = (4, 10, 24)$: etapa 1, $m_{21} = 2$ e $m_{31} = 4$; etapa 2, $m_{32} = 3$. Então

$$L = \begin{pmatrix} 1 & 0 & 0 \\ 2 & 1 & 0 \\ 4 & 3 & 1 \end{pmatrix}, \qquad U = \begin{pmatrix} 2 & 1 & 1 \\ 0 & 1 & 1 \\ 0 & 0 & 2 \end{pmatrix}.$$

$L\mathbf{y} = \mathbf{b}$: $y_1 = 4$, $y_2 = 10 - 2 \cdot 4 = 2$, $y_3 = 24 - 4 \cdot 4 - 3 \cdot 2 = 2$. $U\mathbf{x} = \mathbf{y}$: $x_3 = 1$, $x_2 = 2 - 1 = 1$, $x_1 = \frac{4 - 1 - 1}{2} = 1$. Logo $\mathbf{x} = (1, 1, 1)$ e $\det A = 2 \cdot 1 \cdot 2 = 4$.

Exemplo: fatoração com troca ($PA = LU$)

Para $A = \begin{pmatrix} 0 & 1 & 2 \\ 1 & 1 & 1 \\ 2 & 1 & 3 \end{pmatrix}$ e $\mathbf{b} = (8, 6, 13)$, o pivô $a_{11} = 0$ obriga a trocar $L_1 \leftrightarrow L_2$. Então

$$P = \begin{pmatrix} 0 & 1 & 0 \\ 1 & 0 & 0 \\ 0 & 0 & 1 \end{pmatrix}, \quad L = \begin{pmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 2 & -1 & 1 \end{pmatrix}, \quad U = \begin{pmatrix} 1 & 1 & 1 \\ 0 & 1 & 2 \\ 0 & 0 & 3 \end{pmatrix}, \quad P\mathbf{b} = \begin{pmatrix} 6 \\ 8 \\ 13 \end{pmatrix}.$$

$L\mathbf{y} = P\mathbf{b}$ dá $\mathbf{y} = (6, 8, 9)$ e $U\mathbf{x} = \mathbf{y}$ dá $\mathbf{x} = (1, 2, 3)$. Como houve uma troca, $\det A = -(1 \cdot 1 \cdot 3) = -3$.

Atividade no GeoGebra: fatoração $PA = LU$, matriz 3×3 [abrir o aplicativo]

Em cada etapa, confira o pivô, troque linhas se ele for zero e informe os multiplicadores; eles aparecem em verde na matriz L. Ao final, a caixa "Resolver $A\mathbf{x} = \mathbf{b}$ usando LU" mostra $P\mathbf{b}$, $\mathbf{y}$ e $\mathbf{x}$.

1. Clique em *Exemplo: sem troca* e refaça o primeiro exemplo acima.
2. Clique em *Exemplo: troca na etapa 1* e refaça o segundo exemplo. Observe como a troca de linhas também troca os multiplicadores já guardados em L.
3. Clique em *Exemplo: troca só na etapa 2*. Quem é P neste caso?
4. Clique em *Exemplo: A singular*. Qual elemento de U se anula? O que isso diz sobre $\det A$ e sobre o sistema?

Arquivo:
ggb/FatoracaoLU_3x3.ggb

Atividade no GeoGebra: fatoração $PA = LU$, matriz 4×4 [abrir o aplicativo]

1. No *Exemplo: sem troca*, obtenha $L = \begin{pmatrix} 1&0&0&0 \\ 2&1&0&0 \\ 4&3&1&0 \\ 3&4&1&1 \end{pmatrix}$, $U = \begin{pmatrix} 2&1&1&0 \\ 0&1&1&1 \\ 0&0&2&2 \\ 0&0&0&2 \end{pmatrix}$, $\mathbf{y} = (4, 3, 4, 2)$ e $\mathbf{x} = (1, 1, 1, 1)$. Calcule $\det A$.
2. No *Exemplo: trocas nas etapas 1 e 3* (é a matriz do exemplo de eliminação de Gauss), compare a matriz U com a matriz B_3 obtida no aplicativo de Gauss.
3. Usando a fatoração do item 1, resolva à mão $A\mathbf{x} = \mathbf{b}$ com outro vetor, por exemplo $\mathbf{b} = (3, 8, 24, 24)$, sem refazer a eliminação. (Resposta: $\mathbf{y} = (3, 2, 6, 1)$ e $\mathbf{x} = (\frac{3}{4}, -1, \frac{5}{2}, \frac{1}{2})$.)

Arquivo:
ggb/FatoracaoLU_4x4.ggb

Por que fatorar? Para um único sistema, a fatoração LU mais as duas substituições custa exatamente o mesmo que a eliminação de Gauss. A vantagem aparece quando a *mesma* matriz A é usada com vários vetores $\mathbf{b}$ (por exemplo, em processos iterativos ou em problemas com várias cargas): a parte cara, de ordem n^3, é feita uma única vez, e cada novo sistema custa só $2n^2$ operações.

3.5 Custo computacional dos métodos diretos

Contamos as operações de ponto flutuante: multiplicações e divisões (M/D) e adições e subtrações (A/S). Para n grande, só o termo de maior grau importa.

Método	M/D	A/S	Ordem
Eliminação de Gauss (com retrossubstituição)	$\frac{n^3}{3} + n^2 - \frac{n}{3}$	$\frac{n^3}{3} + \frac{n^2}{2} - \frac{5n}{6}$	$\frac{2}{3}n^3$
LU: fatoração	$\frac{n^3-n}{3}$	$\frac{n^3}{3} - \frac{n^2}{2} + \frac{n}{6}$	$\frac{2}{3}n^3$
LU: resolução ($L\mathbf{y} = P\mathbf{b}$, $U\mathbf{x} = \mathbf{y}$)	n^2	$n^2 - n$	$2n^2$
Matriz inversa e produto $A^{-1}\mathbf{b}$	$n^3 + n^2$	$n^3 - n^2$	$2n^3$
Cramer, determinantes por eliminação	$(n+1)$ determinantes de custo $\approx \frac{2}{3}n^3$		$\frac{2}{3}n^4$
Cramer, determinantes por cofatores	$M_n = nM_{n-1} + n$, $S_n = nS_{n-1} + n - 1$		$e\,(n+1)!$

Método	$n = 4$	$n = 10$	$n = 20$	$n = 100$
Eliminação de Gauss / LU	62	805	5 910	681 550
Matriz inversa	128	2 000	16 000	2 000 000
Cramer (eliminação)	189	6 874	108 149	$6{,}7 \times 10^7$
Cramer (cofatores)	319	$1{,}1 \times 10^8$	$1{,}4 \times 10^{20}$	$2{,}6 \times 10^{160}$

Num computador de 10^{12} operações por segundo, com $n = 20$, a eliminação de Gauss leva alguns nanossegundos, enquanto a regra de Cramer por cofatores levaria cerca de quatro anos e meio. No tamanho dos aplicativos ($n = 4$), Cramer por cofatores já custa cerca de cinco vezes a eliminação.

Conclusões.

- Em ordem de custo, para um sistema: Gauss $\approx LU <$ inversa $<$ Cramer.
- Nunca se calcula A^{-1} para resolver $A\mathbf{x} = \mathbf{b}$: custa cerca de três vezes mais e é menos estável; mesmo com muitos vetores $\mathbf{b}$, a LU é melhor.
- A regra de Cramer tem grande valor teórico, mas não é usada no cálculo numérico.
- Aproveitar a estrutura da matriz muda tudo: para matrizes tridiagonais, o algoritmo de Thomas custa $\approx 8n$ operações, em vez de $\frac{2}{3}n^3$.
- Nenhum método direto corrige um problema *mal condicionado*: o erro relativo é da ordem de $\varepsilon\,\kappa(A)$, com $\varepsilon \approx 10^{-16}$ e $\kappa(A)$ o número de condição. Para a matriz de Hilbert 13×13, $\kappa \approx 5 \times 10^{17}$ e a solução calculada não tem nenhum algarismo correto, qualquer que seja o método.

Leitura complementar: custo computacional (3 páginas) [abrir o texto]

Dedução das contagens de operações da eliminação de Gauss, da fatoração LU, da matriz inversa e da regra de Cramer (por cofatores e por eliminação), com a tabela comparativa e o caso $n = 4$ dos aplicativos.

Arquivo: `complementos/CustoComputacional_SistemasLineares.pdf`

Leitura complementar: comparação computacional dos métodos diretos (10 páginas) **[abrir o texto]**

Comparação ampliada (Gauss com e sem pivoteamento, Gauss-Jordan, LU, Cholesky, LDL^T, QR, inversa, Cramer e Thomas): contagem exata de operações, memória, tempos medidos em Python/NumPy e precisão numérica em matrizes bem e mal condicionadas (matriz de Hilbert).

Arquivo: `complementos/ComparacaoMetodosDiretos.pdf`

3.6 Métodos iterativos: a ideia

Para sistemas muito grandes e esparsos (com a maioria dos coeficientes nulos), os métodos diretos podem ser caros e destruir a esparsidade (a eliminação preenche posições que eram zero). Os métodos iterativos partem de um *chute inicial* $\mathbf{x}^{(0)}$ e geram uma sequência $\mathbf{x}^{(1)}, \mathbf{x}^{(2)}, \ldots$ que, sob certas condições, converge para a solução.

A ideia é reescrever $A\mathbf{x} = \mathbf{b}$ na forma equivalente $\mathbf{x} = C\mathbf{x} + \mathbf{g}$ e iterar

$$\mathbf{x}^{(k+1)} = C\mathbf{x}^{(k)} + \mathbf{g}, \qquad k = 0, 1, 2, \ldots$$

Cada iteração custa da ordem de $2n^2$ operações para matriz cheia (bem menos para matriz esparsa). Se forem necessárias k iterações, o custo total $\approx 2kn^2$ é menor que o de Gauss ($\frac{2}{3}n^3$) sempre que $k < n/3$.

Critério de parada. Interrompemos as iterações quando

$$d^{(k)} = \max_{1 \le i \le n} \left| x_i^{(k)} - x_i^{(k-1)} \right| < \varepsilon$$

(tolerância ε dada) ou quando se atinge um número máximo N de iterações. Também é comum usar o erro relativo $d^{(k)} / \max_i |x_i^{(k)}|$. Os aplicativos usam $d^{(k)} < \varepsilon$ com $\varepsilon = 0{,}001$.

3.7 Método de Gauss-Jacobi

Supondo $a_{ii} \neq 0$, isolamos x_i na i-ésima equação e usamos, no lado direito, os valores da iteração anterior:

$$x_i^{(k+1)} = \frac{1}{a_{ii}} \Big(b_i - \sum_{j \neq i} a_{ij}\, x_j^{(k)} \Big), \qquad i = 1, \ldots, n.$$

Para $n = 3$:

$$\begin{cases} x_1^{(k+1)} = \dfrac{b_1 - a_{12}x_2^{(k)} - a_{13}x_3^{(k)}}{a_{11}} \\ x_2^{(k+1)} = \dfrac{b_2 - a_{21}x_1^{(k)} - a_{23}x_3^{(k)}}{a_{22}} \\ x_3^{(k+1)} = \dfrac{b_3 - a_{31}x_1^{(k)} - a_{32}x_2^{(k)}}{a_{33}} \end{cases}$$

Se algum $a_{ii} = 0$, é preciso reordenar as equações.

Teorema 3.3 (Critério das linhas)**.** *Seja*

$$\alpha_i = \frac{1}{|a_{ii}|}\sum_{j\neq i}|a_{ij}|, \qquad i = 1,\ldots,n.$$

Se $\max_i \alpha_i < 1$ *(isto é, A é* estritamente diagonalmente dominante *por linhas), o método de Gauss-Jacobi converge para a solução, qualquer que seja* $\mathbf{x}^{(0)}$.

O critério é apenas *suficiente*: o método pode convergir mesmo quando ele falha. Trocar a ordem das equações pode fazer o critério passar a valer.

Exemplo: Gauss-Jacobi (exemplo inicial do aplicativo)

Resolva com $\mathbf{x}^{(0)} = (0,0,0)$ e $\varepsilon = 0{,}001$:

$$\begin{cases} 5x_1 + 2x_2 + x_3 = 4 \\ -x_1 - 6x_2 - 3x_3 = 16 \\ -3x_1 + 2x_2 + 7x_3 = -12 \end{cases} \qquad \alpha_1 = \tfrac{2+1}{5} = \tfrac{3}{5}, \quad \alpha_2 = \tfrac{1+3}{6} = \tfrac{2}{3}, \quad \alpha_3 = \tfrac{3+2}{7} = \tfrac{5}{7}.$$

Como $\max \alpha_i = \frac{5}{7} < 1$, há convergência. As iterações são

$$x_1^{(k+1)} = \frac{4 - 2x_2^{(k)} - x_3^{(k)}}{5}, \quad x_2^{(k+1)} = \frac{16 + x_1^{(k)} + 3x_3^{(k)}}{-6}, \quad x_3^{(k+1)} = \frac{-12 + 3x_1^{(k)} - 2x_2^{(k)}}{7}.$$

k	$x_1^{(k)}$	$x_2^{(k)}$	$x_3^{(k)}$	$d^{(k)}$
0	0	0	0	–
1	0,8000	−2,6667	−1,7143	2,6667
2	2,2095	−1,9429	−0,6095	1,4095
3	1,6990	−2,7302	−0,2122	0,7873
4	1,9345	−2,8437	−0,2061	0,2355
5	1,9787	−2,8860	−0,0727	0,1334
6	1,9690	−2,9601	−0,0417	0,0740
7	1,9924	−2,9740	−0,0247	0,0234
8	1,9945	−2,9864	−0,0107	0,0140
9	1,9967	−2,9937	−0,0062	0,0074
10	1,9987	−2,9963	−0,0032	0,0030
11	1,9992	−2,9982	−0,0016	0,0019
12	**1,9996**	**−2,9991**	**−0,0009**	**0,0009**

A parada ocorre em $k = 12$. A solução exata é $\mathbf{x} = (2,-3,0)$.

Atividade no GeoGebra: método de Gauss-Jacobi **[abrir o aplicativo]**

Nas etapas 1 e 2, calcule $\mathbf{x}^{(1)}$ e $\mathbf{x}^{(2)}$ (as fórmulas mostram em azul os valores da iteração anterior). Depois veja o critério das linhas e marque "Continuar as iterações no GeoGebra" para ver a tabela completa. Use as barras de rolagem para percorrer a tela.

1. Confira as duas primeiras linhas da tabela do exemplo.

2. Com $N = 10$, o aplicativo avisa que o erro ainda é $\geq \varepsilon$. Aumente N para 12 e confira a parada em $k = 12$.
3. Mude o chute inicial para $(1, 1, 1)$ e depois para $(10, -10, 10)$. O número de iterações muda? A solução muda? Por quê?
4. Troque a ordem das duas primeiras equações e observe o critério das linhas e a tabela.
5. Diminua ε para 10^{-6} e observe quantas iterações a mais são necessárias.

Arquivo:
ggb/GaussJacobi_sistema3x3_rolagem.ggb

3.8 Método de Gauss-Seidel

O método de Gauss-Seidel é uma modificação simples: ao calcular $x_i^{(k+1)}$, usamos os valores *já atualizados* $x_1^{(k+1)}, \ldots, x_{i-1}^{(k+1)}$:

$$x_i^{(k+1)} = \frac{1}{a_{ii}}\Big(b_i - \sum_{j<i} a_{ij}\, x_j^{(k+1)} - \sum_{j>i} a_{ij}\, x_j^{(k)}\Big), \qquad i = 1, \ldots, n.$$

Para $n = 3$:

$$\begin{cases} x_1^{(k+1)} = \dfrac{b_1 - a_{12}x_2^{(k)} - a_{13}x_3^{(k)}}{a_{11}} \\[2ex] x_2^{(k+1)} = \dfrac{b_2 - a_{21}x_1^{(k+1)} - a_{23}x_3^{(k)}}{a_{22}} \\[2ex] x_3^{(k+1)} = \dfrac{b_3 - a_{31}x_1^{(k+1)} - a_{32}x_2^{(k+1)}}{a_{33}} \end{cases}$$

Além de, em geral, convergir mais depressa, o método só precisa guardar um vetor.

Teorema 3.4 (Critério de Sassenfeld)**.** *Sejam*

$$\beta_1 = \frac{1}{|a_{11}|}\sum_{j=2}^{n} |a_{1j}|, \qquad \beta_i = \frac{1}{|a_{ii}|}\Big(\sum_{j<i} |a_{ij}|\,\beta_j + \sum_{j>i} |a_{ij}|\Big), \quad i = 2, \ldots, n.$$

Se $\max_i \beta_i < 1$*, o método de Gauss-Seidel converge para a solução, qualquer que seja* $\mathbf{x}^{(0)}$*. Se o critério das linhas vale, o de Sassenfeld também vale.*

Exemplo: Gauss-Seidel (exemplo inicial do aplicativo)

Resolva com $\mathbf{x}^{(0)} = (0, 0, 0)$ e $\varepsilon = 0{,}001$:

$$\begin{cases} 6x_1 - 2x_2 = 14 \\ 3x_1 + 9x_2 - 2x_3 = 31 \\ x_1 + 2x_2 - 6x_3 = 19 \end{cases} \qquad \beta_1 = \tfrac{2}{6} = \tfrac{1}{3}, \quad \beta_2 = \tfrac{3\cdot\frac{1}{3}+2}{9} = \tfrac{1}{3}, \quad \beta_3 = \tfrac{1\cdot\frac{1}{3}+2\cdot\frac{1}{3}}{6} = \tfrac{1}{6}.$$

Como $\max \beta_i = \tfrac{1}{3} < 1$, há convergência.

k	$x_1^{(k)}$	$x_2^{(k)}$	$x_3^{(k)}$	$d^{(k)}$	$d^{(k)}$ com Jacobi
0	0	0	0	–	–
1	2,3333	2,6667	−1,8889	2,6667	3,4444
2	3,2222	1,9506	−1,9794	0,8889	1,5370
3	2,9835	2,0101	−1,9994	0,2387	0,4938
4	3,0034	1,9990	−1,9998	0,0198	0,0974
5	2,9997	2,0002	−2,0000	0,0037	0,0325
6	**3,0001**	**2,0000**	**−2,0000**	**0,0004**	0,0056

Gauss-Seidel para em $k = 6$; Gauss-Jacobi, no mesmo sistema, precisaria de $k = 8$. A solução exata é $\mathbf{x} = (3, 2, -2)$.

Atividade no GeoGebra: método de Gauss-Seidel **[abrir o aplicativo]**

Nas etapas 1 e 2, calcule x_1, x_2, x_3 *nessa ordem*, usando sempre os valores já atualizados (em vermelho nas fórmulas). Depois veja o critério de Sassenfeld, a tabela completa e a comparação com Gauss-Jacobi.

1. Confira as duas primeiras linhas da tabela do exemplo.
2. O aplicativo informa em que iteração Gauss-Jacobi pararia. Confira que é $k = 8$.
3. Digite no aplicativo de Gauss-Seidel o sistema do exemplo de Gauss-Jacobi. Em quantas iterações Gauss-Seidel para? (Resposta esperada: $k = 8$, contra $k = 12$ de Jacobi.)
4. Gere sistemas com *Novo sistema aleatório* e compare $\max \alpha_i$ (Jacobi) e $\max \beta_i$ (Sassenfeld). Qual costuma ser menor?

Arquivo:
ggb/GaussSeidel_sistema3x3_rolagem.ggb

3.9 Métodos diretos ou iterativos?

	Diretos (Gauss, LU)	Iterativos (Jacobi, Seidel)
Resultado	exato em aritmética exata (a menos de arredondamentos)	aproximação com tolerância ε
Custo	$\approx \frac{2}{3}n^3$, previsível	$\approx 2n^2$ por iteração (menos se esparsa)
Convergência	sempre termina (se $\det A \neq 0$)	depende de A (critérios das linhas e de Sassenfeld)
Memória	preenche a matriz (perde a esparsidade)	preserva a esparsidade
Erros de arredondamento	acumulam ao longo da eliminação	cada iteração “corrige” a anterior
Indicados para	sistemas pequenos e médios, matrizes cheias, vários $\mathbf{b}$ (LU)	sistemas grandes e esparsos, diagonalmente dominantes

3.10 Exercícios

1. Resolva por eliminação de Gauss: $\begin{cases} x_1 + x_2 + x_3 = 6 \\ 2x_1 + x_2 - x_3 = 1 \\ x_1 - x_2 + 2x_3 = 5 \end{cases}$.

2. No aplicativo de eliminação de Gauss, resolva os exemplos *troca + SPI* e *sistema impossível*. Para o SPI, escreva a solução geral.

3. Obtenha a fatoração $PA = LU$ de $A = \begin{pmatrix} 1 & 2 & 1 \\ 2 & 4 & 3 \\ 1 & 3 & 2 \end{pmatrix}$ e use-a para resolver $A\mathbf{x} = (4, 9, 6)$. Confira no aplicativo 3×3 (*Exemplo: troca só na etapa 2*).

4. Use a fatoração do primeiro exemplo de LU ($A = \left(\begin{smallmatrix} 2 & 1 & 1 \\ 4 & 3 & 3 \\ 8 & 7 & 9 \end{smallmatrix}\right)$) para resolver $A\mathbf{x} = (1, 2, 6)$ sem refazer a eliminação.

5. Calcule $\det A$ para as matrizes dos dois exemplos de LU usando U e o número de trocas, e confira pela regra de Sarrus.

6. Um computador faz 10^9 operações por segundo. Estime o tempo para resolver um sistema com $n = 1000$ por eliminação de Gauss e pela matriz inversa. Quantos sistemas com a mesma matriz podem ser resolvidos pela LU no tempo de uma única inversão?

7. Para o sistema $\begin{cases} 10x_1 + 2x_2 + x_3 = 7 \\ x_1 + 5x_2 + x_3 = -8 \\ 2x_1 + 3x_2 + 10x_3 = 6 \end{cases}$, com $\mathbf{x}^{(0)} = (0, 0, 0)$ e $\varepsilon = 0{,}001$:

(a) verifique os critérios das linhas e de Sassenfeld;
(b) faça duas iterações de Gauss-Jacobi e duas de Gauss-Seidel à mão;
(c) use os aplicativos para obter o número de iterações de cada método até a parada.

8. O sistema $\begin{cases} 2x_1 + 10x_2 = 12 \\ 8x_1 + x_2 = 9 \end{cases}$ não satisfaz o critério das linhas. Reordene as equações para que satisfaça e resolva por Gauss-Seidel com $\mathbf{x}^{(0)} = (0, 0)$ e duas iterações.

9. (GeoGebra) No aplicativo de Gauss-Jacobi, construa um sistema 3×3 em que o critério das linhas falhe mas o método ainda convirja (sugestão: um único α_i ligeiramente maior que 1). O que isso mostra sobre o critério?

Respostas

1. $m_{21} = 2$, $m_{31} = 1$, $m_{32} = 2$; U com diagonal $1, -1, 7$; $\mathbf{x} = (1, 2, 3)$.
2. SPI: após a troca $L_2 \leftrightarrow L_3$ na etapa 2, a última linha fica $(0\ 0\ 0\ 0 \,|\, 0)$. Restam $x_1 + 2x_2 - x_3 + x_4 = 3$, $-x_2 + 2x_3 = 1$ e $3x_3 - 3x_4 = 0$; com $x_4 = t$ livre, $\mathbf{x} = (5 - 4t,\ 2t - 1,\ t,\ t)$, $t \in \mathbb{R}$. SI: aparece a linha $(0\ 0\ 0\ 0 \,|\, -2)$, que vem de $L_2 - L_1$.
3. P troca as linhas 2 e 3; $L = \left(\begin{smallmatrix} 1 & 0 & 0 \\ 1 & 1 & 0 \\ 2 & 0 & 1 \end{smallmatrix}\right)$, $U = \left(\begin{smallmatrix} 1 & 2 & 1 \\ 0 & 1 & 1 \\ 0 & 0 & 1 \end{smallmatrix}\right)$, $P\mathbf{b} = (4, 6, 9)$, $\mathbf{y} = (4, 2, 1)$, $\mathbf{x} = (1, 1, 1)$.
4. $\mathbf{y} = (1, 0, 2)$ e $\mathbf{x} = (\frac{1}{2}, -1, 1)$.
5. 4 e -3.
6. Gauss: $\approx \frac{2}{3} \cdot 10^9$ operações, cerca de 0,67 s; inversa: $\approx 2 \cdot 10^9$, cerca de 2 s. Com a LU já feita, cada sistema custa $2 \cdot 10^6$ operações (2 ms): no tempo da inversão, fatora-se e resolvem-se cerca de 660 sistemas.

7. (a) $\alpha = (0{,}3;\ 0{,}4;\ 0{,}5)$; $\beta = (0{,}3;\ 0{,}26;\ 0{,}138)$. (b) Jacobi: $\mathbf{x}^{(1)} = (0{,}7;\ -1{,}6;\ 0{,}6)$, $\mathbf{x}^{(2)} = (0{,}96;\ -1{,}86;\ 0{,}94)$; Seidel: $\mathbf{x}^{(1)} = (0{,}7;\ -1{,}74;\ 0{,}982)$, $\mathbf{x}^{(2)} = (0{,}9498;\ -1{,}9864;\ 1{,}0059)$. (c) Jacobi para em $k = 8$ e Seidel em $k = 5$; a solução é $\mathbf{x} = (1, -2, 1)$.

8. Trocando as equações: $8x_1 + x_2 = 9$, $2x_1 + 10x_2 = 12$; $\alpha = (\frac{1}{8}, \frac{1}{5})$. Seidel: $\mathbf{x}^{(1)} = (1{,}125;\ 0{,}975)$, $\mathbf{x}^{(2)} = (1{,}0031;\ 0{,}9994)$; solução $(1, 1)$.

9. O critério das linhas é apenas suficiente: sua falha não implica divergência.

Capítulo 4

Interpolação polinomial

Como usar os aplicativos deste capítulo

Ao longo do capítulo, os quadros laranja *Atividade no GeoGebra* trazem um link [**abrir o aplicativo**] que abre o arquivo correspondente no GeoGebra Classic:

- Interpolação via sistema linear e eliminação de Gauss;
- Interpolação de Lagrange;
- Interpolação de Newton (diferenças divididas).

Para que os links funcionem, mantenha este PDF e a pasta `ggb` juntos, na mesma pasta, e abra o PDF num leitor que permita abrir arquivos externos (Adobe Acrobat Reader, Okular, SumatraPDF, Foxit). Os leitores de PDF embutidos nos navegadores costumam bloquear esse tipo de link; nesse caso, abra os arquivos da pasta `ggb` diretamente no GeoGebra.

Os três aplicativos começam com os mesmos quatro pontos $A(-4,2)$, $B(-2,-2)$, $C(4,3)$ e $D(8,0)$, que são os pontos do exemplo desenvolvido no texto. Ao arrastar qualquer ponto, todas as contas são refeitas. Nos aplicativos, cada janela da direita tem barras de rolagem (vertical e horizontal) para percorrer as contas.

4.1 O problema da interpolação

Em muitas situações conhecemos uma função apenas em alguns pontos: uma tabela de temperaturas medidas de hora em hora, valores tabelados de uma função especial, resultados de um experimento ou de uma simulação cara. Interpolar é construir uma função simples que *passe exatamente* pelos pontos conhecidos e usá-la para estimar valores intermediários, derivar, integrar ou simplesmente desenhar a curva.

Definição 4.1. Dados n pontos (x_1, y_1), (x_2, y_2), …, (x_n, y_n) com abscissas $x_1, \ldots, x_n$ *distintas* (os *nós*), um *polinômio interpolador* desses pontos é um polinômio p de grau menor ou igual a $n-1$ tal que

$$p(x_i) = y_i, \qquad i = 1, 2, \ldots, n.$$

Quando $y_i = f(x_i)$ para alguma função f, dizemos que p *interpola* f *nos nós* $x_1, \ldots, x_n$.

Usamos polinômios porque são fáceis de avaliar (só somas e produtos), de derivar e de integrar, e porque, como veremos, o problema sempre tem uma única solução. Neste capítulo estudamos três maneiras de obter esse mesmo polinômio:

1. resolvendo um **sistema linear** (matriz de Vandermonde), por eliminação de Gauss;
2. pela **forma de Lagrange**;
3. pela **forma de Newton**, com diferenças divididas.

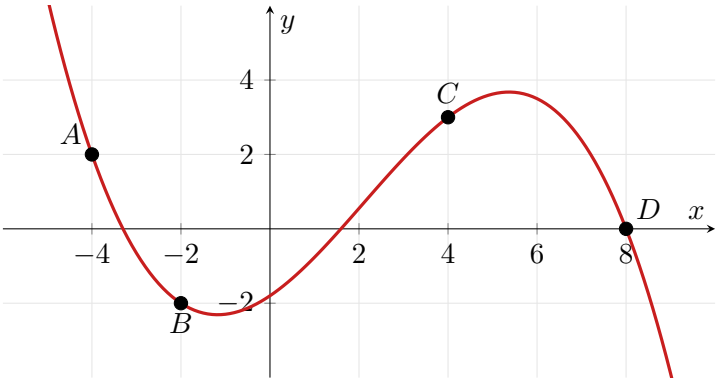


Figura 4.1: O polinômio de grau 3 que passa pelos pontos A, B, C e D do exemplo do capítulo.

4.2 Existência e unicidade

Escrevendo $p(x) = a_0 + a_1 x + \cdots + a_{n-1}x^{n-1}$, as condições $p(x_i) = y_i$ formam um sistema linear de n equações nas n incógnitas $a_0, \ldots, a_{n-1}$:

$$\begin{cases} a_0 + a_1 x_1 + a_2 x_1^2 + \cdots + a_{n-1}x_1^{n-1} = y_1 \\ a_0 + a_1 x_2 + a_2 x_2^2 + \cdots + a_{n-1}x_2^{n-1} = y_2 \\ \qquad \vdots \\ a_0 + a_1 x_n + a_2 x_n^2 + \cdots + a_{n-1}x_n^{n-1} = y_n \end{cases}$$

ou, na forma matricial,

$$\underbrace{\begin{pmatrix} 1 & x_1 & x_1^2 & \cdots & x_1^{n-1} \\ 1 & x_2 & x_2^2 & \cdots & x_2^{n-1} \\ \vdots & \vdots & \vdots & & \vdots \\ 1 & x_n & x_n^2 & \cdots & x_n^{n-1} \end{pmatrix}}_{V} \begin{pmatrix} a_0 \\ a_1 \\ \vdots \\ a_{n-1} \end{pmatrix} = \begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{pmatrix}.$$

A matriz V é a *matriz de Vandermonde* dos nós.

Teorema 4.2 (Existência e unicidade)**.** *Se os nós $x_1, \ldots, x_n$ são distintos, existe um único polinômio p de grau menor ou igual a $n-1$ tal que $p(x_i) = y_i$ para $i = 1, \ldots, n$.*

Demonstração. Unicidade. Se p e q são dois polinômios interpoladores, então $r = p - q$ tem grau no máximo $n-1$ e se anula nos n pontos distintos $x_1, \ldots, x_n$. Um polinômio não nulo de grau no máximo $n-1$ tem no máximo $n-1$ raízes; logo $r \equiv 0$ e $p = q$.

Existência. A unicidade diz que o sistema homogêneo $V\mathbf{a} = \mathbf{0}$ só tem a solução nula (ela corresponde ao polinômio que interpola os valores $y_i = 0$). Então V é invertível e $V\mathbf{a} = \mathbf{y}$ tem solução para qualquer $\mathbf{y}$. ∎

Observação

Pode-se mostrar que $\det V = \prod_{1 \le i < j \le n} (x_j - x_i)$, que é diferente de zero exatamente quando os nós são distintos (Exercício **6.**). Se dois nós coincidem e os valores y são diferentes, nenhuma função $y = p(x)$ passa pelos dois pontos. Nos três aplicativos, colocar dois pontos na mesma vertical faz aparecer um aviso.

Como o polinômio interpolador é único, os três métodos deste capítulo produzem *o mesmo polinômio*, apenas escrito de formas diferentes e calculado com custos diferentes.

4.3 Método 1: sistema linear e eliminação de Gauss

A forma mais direta é montar o sistema de Vandermonde e resolvê-lo por eliminação de Gauss seguida de retrossubstituição, como em qualquer sistema linear.

Exemplo: os pontos A, B, C, D pelo sistema linear

Vamos interpolar $A(-4,2)$, $B(-2,-2)$, $C(4,3)$, $D(8,0)$ por $p(x) = a_0 + a_1 x + a_2 x^2 + a_3 x^3$. Cada linha da matriz aumentada é $\left(\begin{array}{cccc|c} 1 & x_i & x_i^2 & x_i^3 & y_i \end{array}\right)$:

$$B = \left(\begin{array}{cccc|c} 1 & -4 & 16 & -64 & 2 \\ 1 & -2 & 4 & -8 & -2 \\ 1 & 4 & 16 & 64 & 3 \\ 1 & 8 & 64 & 512 & 0 \end{array}\right).$$

Etapa 1 (pivô $a_{11} = 1$): $m_{21} = m_{31} = m_{41} = 1$, e $L_i \leftarrow L_i - m_{i1} L_1$ para $i = 2, 3, 4$:

$$B_1 = \left(\begin{array}{cccc|c} 1 & -4 & 16 & -64 & 2 \\ 0 & 2 & -12 & 56 & -4 \\ 0 & 8 & 0 & 128 & 1 \\ 0 & 12 & 48 & 576 & -2 \end{array}\right).$$

Etapa 2 (pivô 2): $m_{32} = \frac{8}{2} = 4$, $m_{42} = \frac{12}{2} = 6$:

$$B_2 = \left(\begin{array}{cccc|c} 1 & -4 & 16 & -64 & 2 \\ 0 & 2 & -12 & 56 & -4 \\ 0 & 0 & 48 & -96 & 17 \\ 0 & 0 & 120 & 240 & 22 \end{array}\right).$$

Etapa 3 (pivô 48): $m_{43} = \frac{120}{48} = \frac{5}{2}$:

$$B_3 = \left(\begin{array}{cccc|c} 1 & -4 & 16 & -64 & 2 \\ 0 & 2 & -12 & 56 & -4 \\ 0 & 0 & 48 & -96 & 17 \\ 0 & 0 & 0 & 480 & -\frac{41}{2} \end{array}\right).$$

Retrossubstituição:

$$a_3 = \frac{-41/2}{480} = -\frac{41}{960}, \qquad a_2 = \frac{17 + 96 a_3}{48} = \frac{43}{160},$$
$$a_1 = \frac{-4 + 12 a_2 - 56 a_3}{2} = \frac{97}{120}, \qquad a_0 = 2 + 4 a_1 - 16 a_2 + 64 a_3 = -\frac{9}{5}.$$

Portanto

$$\boxed{p(x) = -\frac{9}{5} + \frac{97}{120}\,x + \frac{43}{160}\,x^2 - \frac{41}{960}\,x^3}$$

(Figura 4.1). Confira, por exemplo, que $p(4) = 3$.

Observação

Na eliminação da matriz de Vandermonde, a primeira coluna é toda de 1, por isso $m_{21} = m_{31} = \cdots = 1$ e o primeiro pivô nunca é zero. Mais ainda, o k-ésimo pivô é $\prod_{j<k}(x_k - x_j)$ (no exemplo: 1, $x_2 - x_1 = 2$, $(x_3 - x_1)(x_3 - x_2) = 48$ e $(x_4 - x_1)(x_4 - x_2)(x_4 - x_3) = 480$). Assim, com nós distintos, a eliminação nunca precisa de troca de linhas.

Atividade no GeoGebra: eliminação de Gauss automática [abrir o aplicativo]

Abra o aplicativo. À esquerda ficam os pontos A, B, C, D e a cúbica; à direita, a matriz aumentada, os multiplicadores de cada etapa (com a conta m_{ik} = elemento/pivô), as matrizes B_1, B_2, B_3 e a retrossubstituição.

1. Confira, no aplicativo, todos os números do exemplo acima.
2. Arraste os pontos. Os multiplicadores m_{21}, m_{31} e m_{41} mudam? Explique usando a observação anterior.
3. Verifique, para outras posições, que o pivô da etapa 2 é $x_B - x_A$ e o da etapa 3 é $(x_C - x_A)(x_C - x_B)$.
4. Alinhe três dos pontos numa reta (por exemplo, todos com $y = 0$). O que acontece com a_3? E se os quatro pontos estiverem alinhados?
5. Coloque B na mesma vertical de A. Por que as contas desaparecem?

Arquivo:
ggb/EliminacaoGauss_Interpolacao_4pontos_automatico.ggb

Vantagens e limitações. O método é conceitualmente simples e fornece diretamente os coeficientes na base $1, x, x^2, \ldots$. Por outro lado, resolver o sistema custa da ordem de $\frac{2}{3}n^3$ operações e a matriz de Vandermonde fica muito *mal condicionada* quando n cresce (as colunas x^k ficam quase paralelas), o que amplifica os erros de arredondamento. Os métodos seguintes evitam o sistema linear.

4.4 Método 2: forma de Lagrange

A ideia de Lagrange é escrever p como combinação de polinômios que "ligam" um nó de cada vez.

Definição 4.3. Os *polinômios de Lagrange* associados aos nós distintos $x_1, \ldots, x_n$ são

$$L_i(x) = \prod_{\substack{j=1 \\ j \neq i}}^{n} \frac{x - x_j}{x_i - x_j} = \frac{(x - x_1)\cdots(x - x_{i-1})(x - x_{i+1})\cdots(x - x_n)}{(x_i - x_1)\cdots(x_i - x_{i-1})(x_i - x_{i+1})\cdots(x_i - x_n)}, \qquad i = 1, \ldots, n.$$

Cada L_i tem grau $n - 1$ e satisfaz

$$L_i(x_j) = \delta_{ij} = \begin{cases} 1, & j = i, \\ 0, & j \neq i, \end{cases}$$

pois o numerador se anula em todos os nós diferentes de x_i e, em x_i, numerador e denominador são iguais.

Teorema 4.4 (Forma de Lagrange)**.** *O polinômio interpolador dos pontos* (x_i, y_i), $i = 1, \ldots, n$, *é*

$$p(x) = \sum_{i=1}^{n} y_i\, L_i(x) = y_1 L_1(x) + y_2 L_2(x) + \cdots + y_n L_n(x).$$

Demonstração. p tem grau no máximo $n-1$ e $p(x_j) = \sum_i y_i\, \delta_{ij} = y_j$. Pelo Teorema 4.2, é o polinômio interpolador. ■

Exemplo: os mesmos pontos pela forma de Lagrange

Com $x_1 = -4$, $x_2 = -2$, $x_3 = 4$, $x_4 = 8$:

$$L_1(x) = \frac{(x+2)(x-4)(x-8)}{(-4+2)(-4-4)(-4-8)} = \frac{(x+2)(x-4)(x-8)}{-192} = -\tfrac{1}{192}x^3 + \tfrac{5}{96}x^2 - \tfrac{1}{24}x - \tfrac{1}{3},$$

$$L_2(x) = \frac{(x+4)(x-4)(x-8)}{(-2+4)(-2-4)(-2-8)} = \frac{(x+4)(x-4)(x-8)}{120} = \tfrac{1}{120}x^3 - \tfrac{1}{15}x^2 - \tfrac{2}{15}x + \tfrac{16}{15},$$

$$L_3(x) = \frac{(x+4)(x+2)(x-8)}{(4+4)(4+2)(4-8)} = \frac{(x+4)(x+2)(x-8)}{-192} = -\tfrac{1}{192}x^3 + \tfrac{1}{96}x^2 + \tfrac{5}{24}x + \tfrac{1}{3},$$

$$L_4(x) = \frac{(x+4)(x+2)(x-4)}{(8+4)(8+2)(8-4)} = \frac{(x+4)(x+2)(x-4)}{480} = \tfrac{1}{480}x^3 + \tfrac{1}{240}x^2 - \tfrac{1}{30}x - \tfrac{1}{15}.$$

Então

$$p(x) = 2L_1(x) - 2L_2(x) + 3L_3(x) + 0\,L_4(x) = -\frac{9}{5} + \frac{97}{120}x + \frac{43}{160}x^2 - \frac{41}{960}x^3,$$

exatamente o polinômio obtido pelo sistema linear. Repare que L_4 nem precisaria ser calculado, pois $y_4 = 0$.

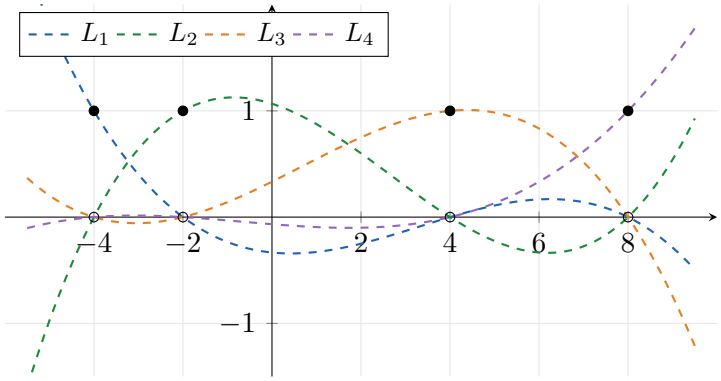


Figura 4.2: As bases de Lagrange do exemplo: cada L_i vale 1 no seu nó (pontos cheios) e 0 nos demais nós (círculos).

Atividade no GeoGebra: forma de Lagrange automática [abrir o aplicativo]

O aplicativo mostra, para cada base, a fórmula, a substituição dos nós, o denominador e a forma expandida, além do polinômio p. No gráfico, as bases aparecem tracejadas nas

mesmas cores dos quadros.

1. Com a caixa "Mostrar as bases" marcada, confira que cada L_i vale 1 em x_i e 0 nos outros nós.
2. Mova o ponto C *apenas na vertical*. Quais bases mudam? Qual parcela de p muda? Por quê?
3. Agora mova C na horizontal. Por que, desta vez, todas as bases mudam?
4. Coloque os quatro pontos com a mesma ordenada $y = c$. Qual é o polinômio p? Conclua que $L_1 + L_2 + L_3 + L_4 \equiv 1$.
5. Compare a cúbica e os coeficientes com os do aplicativo de eliminação de Gauss.

Arquivo:
ggb/Interpolacao_Lagrange_4pontos_automatico.ggb

Vantagens e limitações. A forma de Lagrange dispensa a resolução de sistemas e é muito útil em teoria (dela saem fórmulas de derivação e integração numérica). Quando os nós são fixos e só os valores y_i mudam, basta recombinar as mesmas bases. Por outro lado, se acrescentarmos um novo nó, *todas* as bases precisam ser refeitas.

4.5 Método 3: forma de Newton e diferenças divididas

A forma de Newton constrói o polinômio aos poucos, um nó de cada vez:

$$p(x) = c_1 + c_2(x - x_1) + c_3(x - x_1)(x - x_2) + \cdots + c_n(x - x_1)(x - x_2)\cdots(x - x_{n-1}).$$

Impondo $p(x_1) = y_1$, $p(x_2) = y_2$, … sucessivamente, obtemos os coeficientes c_k um a um: o sistema é triangular. Esses coeficientes são as *diferenças divididas*.

Definição 4.5. As *diferenças divididas* de f nos nós $x_1, \ldots, x_n$ são definidas recursivamente por

$$f[x_i] = f(x_i) = y_i,$$
$$f[x_i, x_{i+1}, \ldots, x_{i+k}] = \frac{f[x_{i+1}, \ldots, x_{i+k}] - f[x_i, \ldots, x_{i+k-1}]}{x_{i+k} - x_i}.$$

Teorema 4.6 (Forma de Newton)**.** *O polinômio interpolador de f nos nós distintos $x_1, \ldots, x_n$ é*

$$p(x) = f[x_1] + f[x_1, x_2](x - x_1) + f[x_1, x_2, x_3](x - x_1)(x - x_2) + \cdots + f[x_1, \ldots, x_n] \prod_{j=1}^{n-1} (x - x_j).$$

Além disso, se p_k denota o polinômio que interpola os $k + 1$ primeiros nós, vale

$$p_k(x) = p_{k-1}(x) + f[x_1, \ldots, x_{k+1}]\,(x - x_1)(x - x_2)\cdots(x - x_k).$$

A segunda fórmula é a grande vantagem do método: ao acrescentar um ponto, aproveitamos tudo o que já foi calculado e somamos apenas *um termo*. As diferenças divididas são organizadas numa tabela triangular; os coeficientes da forma de Newton ficam na primeira linha (ou na diagonal superior, conforme a disposição).

Exemplo: os mesmos pontos pela forma de Newton

Para $A(-4,2)$, $B(-2,-2)$, $C(4,3)$, $D(8,0)$:

Ordem 1:

$$f[x_1,x_2]=\frac{-2-2}{-2-(-4)}=-2,\quad f[x_2,x_3]=\frac{3-(-2)}{4-(-2)}=\frac{5}{6},\quad f[x_3,x_4]=\frac{0-3}{8-4}=-\frac{3}{4}.$$

Ordem 2:

$$f[x_1,x_2,x_3]=\frac{\frac{5}{6}-(-2)}{4-(-4)}=\frac{17}{48},\qquad f[x_2,x_3,x_4]=\frac{-\frac{3}{4}-\frac{5}{6}}{8-(-2)}=-\frac{19}{120}.$$

Ordem 3:

$$f[x_1,x_2,x_3,x_4]=\frac{-\frac{19}{120}-\frac{17}{48}}{8-(-4)}=-\frac{41}{960}.$$

x_i	$f[x_i]$	ordem 1	ordem 2	ordem 3
-4	$\boxed{2}$	$\boxed{-2}$	$\boxed{\frac{17}{48}}$	$\boxed{-\frac{41}{960}}$
-2	-2	$\frac{5}{6}$	$-\frac{19}{120}$	
4	3	$-\frac{3}{4}$		
8	0			

Logo

$$p(x)=2-2(x+4)+\frac{17}{48}(x+4)(x+2)-\frac{41}{960}(x+4)(x+2)(x-4),$$

que, expandido, é novamente $p(x)=-\frac{9}{5}+\frac{97}{120}x+\frac{43}{160}x^2-\frac{41}{960}x^3$. Repare que o coeficiente de x^3 é a diferença dividida de maior ordem.

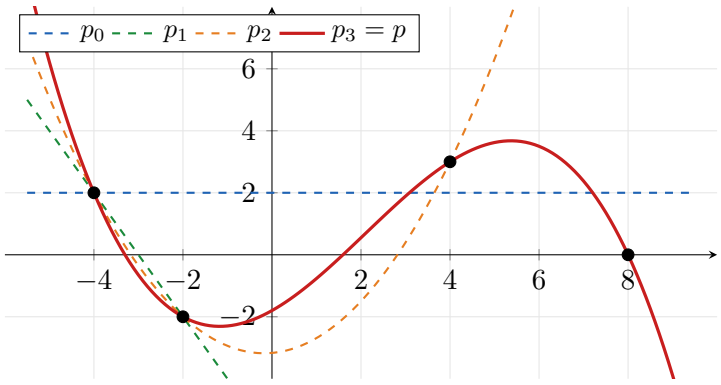


Figura 4.3: Construção incremental de Newton: p_0 passa por A; p_1 por A,B; p_2 por A,B,C; p_3 pelos quatro pontos.

Avaliação eficiente (forma aninhada). A forma de Newton pode ser avaliada como no algoritmo de Horner:

$$p(x)=c_1+(x-x_1)\Big(c_2+(x-x_2)\big(c_3+(x-x_3)\,c_4\big)\Big),$$

o que exige apenas $n-1$ multiplicações para cada valor de x.

Atividade no GeoGebra: diferenças divididas automáticas [abrir o aplicativo]

O aplicativo mostra as diferenças de cada ordem com as contas, a tabela triangular (com os coeficientes destacados em vermelho) e o polinômio nas formas de Newton e expandida. No gráfico, a caixa de seleção mostra os polinômios parciais p_0, p_1 e p_2.

1. Confira a tabela do exemplo acima.
2. Arraste apenas o ponto D. Quais entradas da tabela mudam? Os polinômios p_0, p_1, p_2 mudam? Relacione com a fórmula $p_3 = p_2 + f[x_1, \ldots, x_4](x - x_1)(x - x_2)(x - x_3)$.
3. Arraste agora o ponto A. Por que, desta vez, toda a primeira linha da tabela muda?
4. Posicione D sobre a parábola p_2. Quanto vale $f[x_1, x_2, x_3, x_4]$? Interprete.
5. Compare com os aplicativos de Gauss e de Lagrange e verifique que os três chegam ao mesmo polinômio.

Arquivo:
ggb/Interpolacao_Newton_4pontos_automatico.ggb

4.6 Comparação dos três métodos

	Sistema linear (Vandermonde)	Lagrange	Newton
Base usada	$1, x, \ldots, x^{n-1}$	$L_1, \ldots, L_n$	$1, (x - x_1), (x - x_1)(x - x_2), \ldots$
Custo para obter p	$\approx \frac{2}{3}n^3$ (eliminação)	nenhum cálculo prévio, além dos denominadores	$\approx \frac{n^2}{2}$ divisões (tabela)
Avaliar $p(x)$	$n - 1$ mult. (Horner)	$\approx n^2$ operações	$n - 1$ mult. (forma aninhada)
Acrescentar um nó	refazer o sistema	refazer todas as bases	somar um termo
Estabilidade numérica	ruim para n grande	boa	boa

Em resumo: o sistema linear é o caminho mais intuitivo e mostra a ligação com a Álgebra Linear; a forma de Lagrange é a mais elegante e a mais usada na teoria; a forma de Newton é, em geral, a mais conveniente no computador.

4.7 O erro da interpolação

Quando os dados vêm de uma função f, queremos saber quão perto $p(x)$ está de $f(x)$ fora dos nós.

Teorema 4.7 (Erro da interpolação)**.** *Seja f com derivadas contínuas até a ordem n num intervalo $[a, b]$ que contém os nós distintos $x_1, \ldots, x_n$, e seja p o polinômio que interpola f nesses nós. Para cada $x \in [a, b]$ existe $\xi = \xi(x) \in (a, b)$ tal que*

$$f(x) - p(x) = \frac{f^{(n)}(\xi)}{n!}(x - x_1)(x - x_2)\cdots(x - x_n).$$

Em particular, se $|f^{(n)}(t)| \le M_n$ *em* $[a,b]$,

$$|f(x) - p(x)| \le \frac{M_n}{n!}\,\big|(x-x_1)(x-x_2)\cdots(x-x_n)\big|.$$

Ideia da demonstração. Fixado x diferente dos nós, considere $g(t) = f(t) - p(t) - K\prod_i (t-x_i)$, com K escolhido para que $g(x)=0$. Então g tem $n+1$ zeros em $[a,b]$ (os nós e x). Aplicando o Teorema de Rolle repetidamente, $g^{(n)}$ tem um zero ξ. Como $p^{(n)} \equiv 0$ e a derivada de ordem n de $\prod_i (t-x_i)$ é $n!$, obtemos $0 = f^{(n)}(\xi) - K\,n!$, isto é, $K = f^{(n)}(\xi)/n!$. ∎

Exemplo: estimativa de erro

Interpolando $f(x) = e^x$ nos nós 0; 0,5; 1 e avaliando em $x = 0{,}25$, obtemos $p(0{,}25) \approx 1{,}27176$, enquanto $e^{0{,}25} \approx 1{,}28403$. O erro real é $\approx 0{,}01227$. Pelo Teorema 4.7, com $n=3$ e $M_3 = \max_{[0,1]} e^x = e$,

$$|f(0{,}25) - p(0{,}25)| \le \frac{e}{3!}\,|0{,}25\cdot(-0{,}25)\cdot(-0{,}75)| \approx 0{,}02124,$$

uma cota coerente com o erro observado.

Mais pontos nem sempre é melhor: o fenômeno de Runge. O produto $\prod(x-x_i)$ pode ficar grande perto das extremidades do intervalo quando os nós são igualmente espaçados. Para $f(x) = \dfrac{1}{1+25x^2}$ em $[-1,1]$ com 11 nós igualmente espaçados, o polinômio interpolador de grau 10 oscila fortemente perto de ± 1, com erro máximo próximo de 1,9 (Figura 4.4). Nesses casos usam-se nós de Chebyshev (mais concentrados nas extremidades) ou interpolação por partes (*splines*), assuntos que aparecem mais adiante.

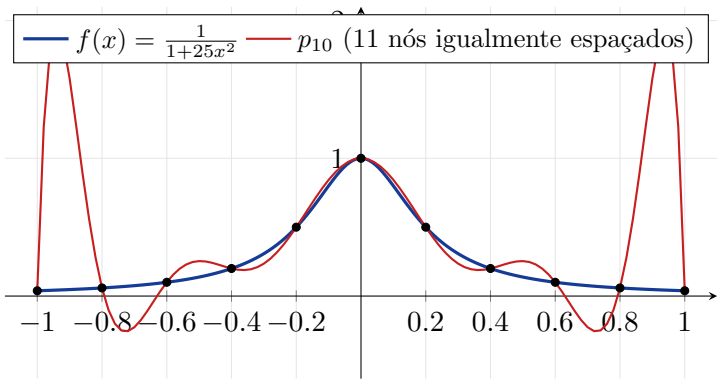


Figura 4.4: Fenômeno de Runge: aumentar o número de nós igualmente espaçados pode piorar a aproximação perto das extremidades.

4.8 Exercícios

1. Encontre o polinômio que interpola $(0,1)$, $(1,3)$, $(2,7)$ pelos três métodos: sistema linear, Lagrange e Newton. Confira que os resultados coincidem.

2. Considere os pontos $(-1,4)$, $(0,1)$, $(1,0)$, $(2,1)$.

(a) Monte a tabela de diferenças divididas e escreva p na forma de Newton.

(b) Qual é o grau de p? Por que ele é menor que 3?
(c) Acrescente o ponto $(3, 4)$. Quantos termos novos aparecem na forma de Newton?

3. A temperatura de um forno foi medida em três instantes:

t (min)	1	3	4
T (°C)	21,2	24,8	25,6

Use interpolação quadrática para estimar a temperatura em $t = 2$ min.

4. Interpole $f(x) = \operatorname{sen} x$ nos nós 0, $\pi/4$ e $\pi/2$. Estime $\operatorname{sen}(\pi/8)$, calcule o erro real e compare com a cota do Teorema 4.7.

5. Mostre que, para quaisquer nós distintos, $\displaystyle\sum_{i=1}^{n} L_i(x) = 1$ para todo x. (Sugestão: qual polinômio interpola a função constante $f(x) = 1$?)

6. Mostre que, para três nós, $\det \begin{pmatrix} 1 & x_1 & x_1^2 \\ 1 & x_2 & x_2^2 \\ 1 & x_3 & x_3^2 \end{pmatrix} = (x_2 - x_1)(x_3 - x_1)(x_3 - x_2)$.

7. (GeoGebra) Em cada um dos três aplicativos, coloque os quatro pontos sobre a reta $y = 2x+2$ (por exemplo, $(0, 2)$, $(1, 4)$, $(2, 6)$, $(3, 8)$). Descreva o que acontece com: (a) a última linha da matriz escalonada; (b) a combinação das bases de Lagrange; (c) as diferenças divididas de ordem 2 e 3.

8. (GeoGebra) No aplicativo de Newton, mova somente o ponto D e anote quais números mudam na tabela. Faça o mesmo no aplicativo de Lagrange. Qual dos dois métodos reaproveita mais contas quando um único dado muda?

Respostas

1. $p(x) = x^2 + x + 1$. Na forma de Newton: $p(x) = 1 + 2x + x(x - 1)$.
2. (a) $f[x_i]$: $4, 1, 0, 1$; ordem 1: $-3, -1, 1$; ordem 2: $1, 1$; ordem 3: 0. Logo $p(x) = 4 - 3(x + 1) + (x + 1)x = x^2 - 2x + 1 = (x - 1)^2$. (b) Grau 2, pois $f[x_1, \ldots, x_4] = 0$: os quatro pontos estão sobre uma mesma parábola. (c) Um termo, com coeficiente $f[x_1, \ldots, x_5] = 0$; o ponto $(3, 4)$ também está sobre a parábola.
3. $T(t) = \frac{92}{5} + \frac{47}{15}t - \frac{1}{3}t^2$, e $T(2) = \frac{70}{3} \approx 23{,}3\,^\circ\text{C}$.
4. $p(\pi/8) \approx 0{,}40533$, $\operatorname{sen}(\pi/8) \approx 0{,}38268$, erro $\approx 0{,}02265$; cota $\frac{1}{6}\left|\frac{\pi}{8}(\frac{\pi}{8} - \frac{\pi}{4})(\frac{\pi}{8} - \frac{\pi}{2})\right| \approx 0{,}03028$.
5. O polinômio que interpola $f \equiv 1$ é $p \equiv 1$; pela forma de Lagrange, $p = \sum 1 \cdot L_i$.
6. Escalone (ou desenvolva o determinante) e fatore.
7. (a) na matriz escalonada, os termos independentes das linhas 3 e 4 ficam iguais a 0, logo $a_3 = a_2 = 0$; (b) $p(x) = 2x + 2$; (c) todas nulas.
8. Em Newton mudam apenas as entradas que envolvem x_4 (a última "diagonal" da tabela, de $f[x_4]$ até $f[x_1, \ldots, x_4]$) e só o último termo do polinômio; p_0, p_1, p_2 não mudam. Em Lagrange, como x_4 aparece em todos os denominadores e numeradores, todas as bases mudam. Newton reaproveita mais contas.

Capítulo 5

Ajuste de curvas: método dos mínimos quadrados e gradiente descendente

Como usar os aplicativos deste capítulo

Os quadros laranja *Atividade no GeoGebra* trazem o link **[abrir o aplicativo]**. São nove aplicativos, em dois grupos.

Método direto (sistema normal).

- reta com 4 pontos, parábola com 11 pontos e parábola com os pontos $A, \ldots, K$: as contas aparecem passo a passo, com barras de rolagem, e o gráfico fica na segunda janela;
- reta com 5 pontos e combinação de $\operatorname{sen} x$, $\cos x$, x^2, x e 1, montados na planilha.

Método iterativo (gradiente descendente).

- reta com 5 pontos, com as curvas de nível do erro;
- combinação de funções sem padronizar, com as funções padronizadas e padronizadas, com volta aos coeficientes originais.

Nos aplicativos iterativos, o botão de iteração faz um passo do método e o botão *Limpar* recomeça; o *passo* (taxa de aprendizagem) pode ser alterado na caixa de texto.

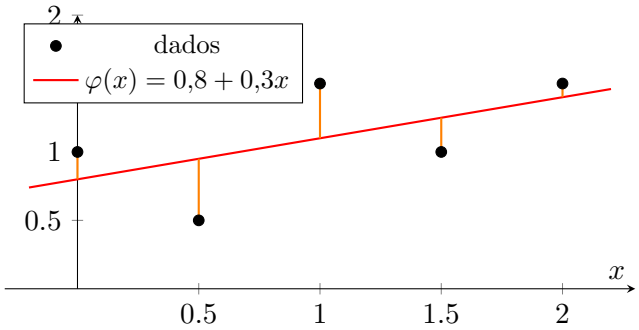
Para que os links funcionem, mantenha este PDF e a pasta `ggb` juntos e abra o PDF num leitor que permita abrir arquivos externos (Adobe Acrobat Reader, Okular, SumatraPDF, Foxit).

5.1 Interpolar ou ajustar?

No capítulo de interpolação, procurávamos um polinômio que passasse *exatamente* pelos pontos dados. Isso nem sempre é desejável:

- os dados experimentais vêm com erros de medida, e forçar a curva a passar por todos eles reproduz também esses erros;
- com muitos pontos, o polinômio interpolador tem grau alto e oscila entre os nós;
- muitas vezes já se sabe que tipo de função descreve o fenômeno (uma reta, uma parábola, uma exponencial) e o que se quer são os seus parâmetros.

No **ajuste de curvas**, escolhemos uma família de funções e procuramos, dentro dela, a que fica "mais perto" dos pontos, sem exigir que passe por eles.



Os segmentos laranja são os resíduos $r_k = f(x_k) - \varphi(x_k)$.

5.2 O método dos mínimos quadrados (caso discreto)

São dados m pontos $(x_1, f(x_1)), \ldots, (x_m, f(x_m))$ e n funções $g_1(x), \ldots, g_n(x)$, escolhidas conforme o problema. Procuramos

$$\varphi(x) = \alpha_1 g_1(x) + \alpha_2 g_2(x) + \cdots + \alpha_n g_n(x)$$

de modo que os *resíduos* $r_k = f(x_k) - \varphi(x_k)$ sejam pequenos. Como resíduos positivos e negativos se cancelariam numa soma simples, minimizamos a soma dos seus quadrados:

$$D(\alpha_1, \ldots, \alpha_n) = \sum_{k=1}^{m} \big[f(x_k) - \varphi(x_k)\big]^2 = \sum_{k=1}^{m} \Big[f(x_k) - \sum_{j=1}^{n} \alpha_j g_j(x_k)\Big]^2.$$

Exemplos de famílias: a reta ($g_1 = 1$, $g_2 = x$), a parábola ($g_1 = 1$, $g_2 = x$, $g_3 = x^2$) e a combinação $\alpha_1 \operatorname{sen} x + \alpha_2 \cos x + \alpha_3 x^2 + \alpha_4 x + \alpha_5$.

5.2.1 O sistema normal

D é uma função quadrática dos α_j, limitada inferiormente por zero. No ponto de mínimo, todas as derivadas parciais se anulam:

$$\frac{\partial D}{\partial \alpha_i} = -2 \sum_{k=1}^{m} \Big[f(x_k) - \sum_{j=1}^{n} \alpha_j g_j(x_k)\Big] g_i(x_k) = 0, \qquad i = 1, \ldots, n,$$

ou seja,

$$\sum_{j=1}^{n} \Big(\sum_{k=1}^{m} g_i(x_k) g_j(x_k) \Big) \alpha_j = \sum_{k=1}^{m} f(x_k) g_i(x_k), \qquad i = 1, \ldots, n.$$

Definição 5.1 (sistema normal)**.** Com $a_{ij} = \sum_{k=1}^{m} g_i(x_k) g_j(x_k)$ e $b_i = \sum_{k=1}^{m} f(x_k) g_i(x_k)$, os coeficientes do ajuste são a solução do sistema linear $n \times n$

$$\begin{bmatrix} a_{11} & \cdots & a_{1n} \\ \vdots & & \vdots \\ a_{n1} & \cdots & a_{nn} \end{bmatrix} \begin{bmatrix} \alpha_1 \\ \vdots \\ \alpha_n \end{bmatrix} = \begin{bmatrix} b_1 \\ \vdots \\ b_n \end{bmatrix}.$$

A matriz é simétrica ($a_{ij} = a_{ji}$). Se os vetores $(g_j(x_1), \ldots, g_j(x_m))$ forem linearmente independentes, ela é definida positiva, o sistema tem solução única e essa solução é o ponto de mínimo de D.

Em notação matricial, com G a matriz $m \times n$ de entradas $G_{kj} = g_j(x_k)$ e $\mathbf{f} = (f(x_1), \ldots, f(x_m))^T$, o sistema normal é $G^T G\,\boldsymbol{\alpha} = G^T \mathbf{f}$. É o **método direto**: monta-se e resolve-se um sistema linear, por exemplo por eliminação de Gauss (Capítulo 3).

5.2.2 Ajuste por uma reta

Para $\varphi(x) = \alpha_1 + \alpha_2 x$ ($g_1 = 1$, $g_2 = x$), o sistema normal fica

$$\begin{bmatrix} m & \sum x_k \\ \sum x_k & \sum x_k^2 \end{bmatrix} \begin{bmatrix} \alpha_1 \\ \alpha_2 \end{bmatrix} = \begin{bmatrix} \sum f(x_k) \\ \sum x_k f(x_k) \end{bmatrix}.$$

Exemplo: reta por 5 pontos

Os pontos são (0; 1), (0,5; 0,5), (1; 1,5), (1,5; 1) e (2; 1,5).

k	x_k	$f(x_k)$	$g_1 g_2 = x_k$	$g_2 g_2 = x_k^2$	$f g_2 = x_k f(x_k)$
1	0	1	0	0	0
2	0,5	0,5	0,5	0,25	0,25
3	1	1,5	1	1	1,5
4	1,5	1	1,5	2,25	1,5
5	2	1,5	2	4	3
$\sum$	5	5,5	5	7,5	6,25

Como $g_1 g_1 = 1$, $a_{11} = 5$. O sistema e a eliminação de Gauss são

$$\left[\begin{array}{cc|c} 5 & 5 & 5{,}5 \\ 5 & 7{,}5 & 6{,}25 \end{array}\right] \xrightarrow{m_{21}=1} \left[\begin{array}{cc|c} 5 & 5 & 5{,}5 \\ 0 & 2{,}5 & 0{,}75 \end{array}\right],$$

logo $\alpha_2 = 0{,}75/2{,}5 = 0{,}3$ e $\alpha_1 = (5{,}5 - 5 \cdot 0{,}3)/5 = 0{,}8$. Então $\varphi(x) = 0{,}8 + 0{,}3x$, com $D = \sum r_k^2 = 0{,}475$.

Atividade no GeoGebra: reta pelo método dos mínimos quadrados [abrir o aplicativo]

O aplicativo monta na planilha a tabela de x_k, $f(x_k)$, $g_1(x_k) = 1$, $g_2(x_k) = x_k$, dos produtos $g_i g_j$ e $f g_i$ e das somas, e resolve o sistema normal por eliminação de Gauss (m_{21}, α_2, α_1). A reta φ aparece no gráfico com os pontos $A_0, \ldots, A_4$.

Tarefas. (a) Confira a tabela e a reta do exemplo. (b) Mova um ponto para longe dos demais (um *dado discrepante*) e observe quanto a reta se desloca. (c) Alinhe os cinco pontos numa reta: qual é então o valor de D?

Arquivo:
`ggb/01_metodo_dos_minimos_quadrados_linear_simples_TCC_2026.ggb`

Atividade no GeoGebra: reta com rolagem (4 pontos) [abrir o aplicativo]

Todas as etapas aparecem em textos na janela da esquerda, com barras de rolagem: tabela dos produtos, sistema normal, eliminação de Gauss, substituição regressiva, tabela de resíduos e comparação com a parábola. Na janela da direita estão os pontos (que podem ser arrastados), a reta, os resíduos e a conferência com o comando `FitPoly` do GeoGebra.

Com os pontos iniciais, $\varphi(x) = 1{,}0735 + 0{,}2941x$.
Tarefas. (a) Gere pontos aleatórios e compare D para a reta e para a parábola. (b) Explique por que o D da parábola nunca é maior que o da reta.
Arquivo:
ggb/metodo_dos_minimos_quadrados_reta_rolagem.ggb

5.2.3 Ajuste por uma parábola

Para $\varphi(x) = \alpha_1 + \alpha_2 x + \alpha_3 x^2$ ($g_1 = 1$, $g_2 = x$, $g_3 = x^2$):

$$\begin{bmatrix} m & \sum x_k & \sum x_k^2 \\ \sum x_k & \sum x_k^2 & \sum x_k^3 \\ \sum x_k^2 & \sum x_k^3 & \sum x_k^4 \end{bmatrix} \begin{bmatrix} \alpha_1 \\ \alpha_2 \\ \alpha_3 \end{bmatrix} = \begin{bmatrix} \sum f(x_k) \\ \sum x_k f(x_k) \\ \sum x_k^2 f(x_k) \end{bmatrix}.$$

Atividade no GeoGebra: parábola com 11 pontos [abrir o aplicativo]

Mesmo formato do aplicativo da reta, agora com $g_3(x) = x^2$, três multiplicadores (m_{21}, m_{31}, m_{32}) e os pontos $A_0, \ldots, A_{10}$, dispostos em forma de "U". O resultado inicial é $\varphi(x) = 0{,}2144 + 0{,}4555x + 1{,}8492x^2$.
Tarefas. (a) Compare o R^2 da parábola e o da reta: qual modelo descreve melhor esses dados? (b) Use o campo "avaliar φ em x" para estimar o valor em $x = 1{,}2$, fora do intervalo dos dados (extrapolação). Que cuidado se deve ter?
Arquivo:
ggb/metodo_dos_minimos_quadrados_exemplo02_parabola_rolagem.ggb

Atividade no GeoGebra: parábola com os pontos $A, \ldots, K$ [abrir o aplicativo]

Outro conjunto de 11 pontos, agora mais espalhados. O ajuste é $\varphi(x) = 0{,}7873 - 0{,}1454x + 0{,}2068x^2$, com $D \approx 2{,}06$ e $R^2 \approx 0{,}77$, contra $D \approx 7{,}86$ e $R^2 \approx 0{,}11$ da reta.
Tarefa. Mostre os resíduos e identifique o ponto que mais contribui para D.
Arquivo:
ggb/aproximacao_funcao_mmq_rolagem.ggb

5.2.4 Combinação de outras funções

O método não exige polinômios. Basta que φ seja *linear nos parâmetros*.

Exemplo: $\varphi(x) = \alpha_1 \operatorname{sen} x + \alpha_2 \cos x + \alpha_3 x^2 + \alpha_4 x + \alpha_5$

Os 8 pontos são

$$(-2;2),\ (0;0),\ (4;2),\ (8;0),\ (10;5),\ (14;4),\ (16;8),\ (20;10).$$

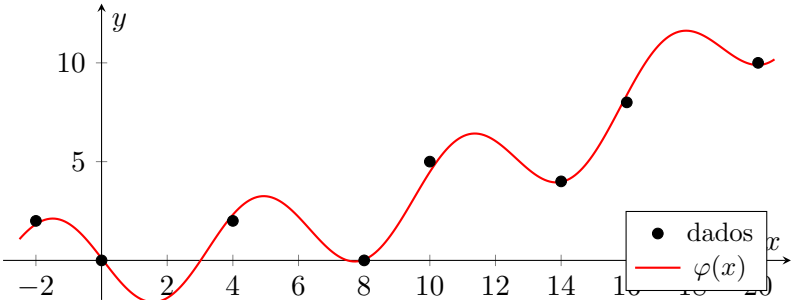
O sistema normal é 5×5, com $g_1 = \operatorname{sen} x$, $g_2 = \cos x$, $g_3 = x^2$, $g_4 = x$ e $g_5 = 1$:

$$\begin{bmatrix} 4{,}572 & 1{,}969 & 478{,}80 & 28{,}787 & 0{,}395 \\ 1{,}969 & 3{,}428 & -160{,}47 & -16{,}584 & -1{,}467 \\ 478{,}80 & -160{,}47 & 278\,320 & 16\,408 & 1\,036 \\ 28{,}787 & -16{,}584 & 16\,408 & 1\,036 & 70 \\ 0{,}395 & -1{,}467 & 1\,036 & 70 & 8 \end{bmatrix} \begin{bmatrix} \alpha_1 \\ \alpha_2 \\ \alpha_3 \\ \alpha_4 \\ \alpha_5 \end{bmatrix} = \begin{bmatrix} 4{,}736 \\ -9{,}368 \\ 7\,372 \\ 438 \\ 31 \end{bmatrix}.$$

A solução é

$$\varphi(x) \approx -2{,}2594\,\operatorname{sen} x + 0{,}1701\cos x + 0{,}02518x^2 + 0{,}09374x - 0{,}06376, \qquad D \approx 0{,}5606.$$

Repare na diferença de escala entre as entradas: 4,6 na diagonal para $\operatorname{sen} x$ e 278 320 para x^2. Ela não atrapalha o método direto, mas, como veremos, prejudica muito o gradiente descendente.



Atividade no GeoGebra: combinação de funções pelo método direto [abrir o aplicativo]

A planilha calcula os produtos $g_i g_j$ e $f g_i$ para as cinco funções, as somas que formam o sistema normal 5×5, os multiplicadores da eliminação de Gauss e os coeficientes $\alpha_1, \ldots, \alpha_5$ por substituição regressiva.

Tarefas. (a) Confira os valores do Exemplo 5.2.4. (b) Retire a função $\operatorname{sen} x$ (isto é, ajuste só com $\cos x$, x^2, x e 1). O ajuste piora muito? Por quê?

Arquivo:
ggb/03_metodo_dos_minimos_quadrados_linear_combinada_TCC_2026.ggb

5.2.5 Casos não lineares: linearização

Se φ não é linear nos parâmetros, às vezes uma mudança de variáveis resolve. Para $\varphi(x) = a\,e^{bx}$, tomando logaritmos:

$$z = \ln \varphi(x) = \ln a + bx = \alpha_1 + \alpha_2 x,$$

e ajustamos uma reta aos pontos $(x_k, \ln f(x_k))$. Com os dados

x_k	-1	$-0{,}7$	$-0{,}4$	$-0{,}1$	$0{,}2$	$0{,}5$	$0{,}8$	1
$f(x_k)$	36,547	17,264	8,155	3,852	1,820	0,860	0,406	0,246

obtemos $\alpha_1 \approx 1{,}0986$ e $\alpha_2 \approx -2{,}5002$, logo $a = e^{\alpha_1} \approx 3{,}0$ e $\varphi(x) \approx 3{,}0\,e^{-2{,}5x}$.

Observação

O ajuste linearizado minimiza os quadrados dos resíduos de $\ln f$, e não os de f. O resultado é bom, mas não é exatamente o mínimo de $\sum[f(x_k) - ae^{bx_k}]^2$. Para esse mínimo, é preciso um método iterativo, como o gradiente descendente da próxima seção.

5.3 O método iterativo: gradiente descendente

Em vez de igualar o gradiente a zero e resolver um sistema, podemos *caminhar* em direção ao mínimo. O gradiente de uma função aponta na direção de maior crescimento; andando no sentido

oposto, a função diminui. É a ideia do **gradiente descendente**, o método usado para treinar modelos de regressão e redes neurais em aprendizado de máquina.

5.3.1 A função custo e o seu gradiente

Nos aplicativos, o erro é escrito com os resíduos no sentido do modelo, $e_k = \varphi(x_k) - f(x_k)$, e dividido por $2m$, como é costume em aprendizado de máquina:

$$J(\boldsymbol{\alpha}) = \frac{1}{2m}\sum_{k=1}^{m} e_k^2 = \frac{1}{2m}\sum_{k=1}^{m}\Big[\sum_{j=1}^{n}\alpha_j g_j(x_k) - f(x_k)\Big]^2 = \frac{D(\boldsymbol{\alpha})}{2m}.$$

Como J é um múltiplo positivo de D, os dois têm o mesmo ponto de mínimo. As derivadas parciais são

$$\frac{\partial J}{\partial \alpha_j} = \frac{1}{m}\sum_{k=1}^{m} e_k\, g_j(x_k), \qquad j = 1, \ldots, n.$$

Algoritmo: gradiente descendente

Passo 0: escolha $\boldsymbol{\alpha}^{(0)}$ (por exemplo, zero), o passo $\eta > 0$, a tolerância e o número máximo de iterações.
Passo 1: calcule os resíduos $e_k = \varphi(x_k) - f(x_k)$ com os coeficientes atuais.
Passo 2: calcule o gradiente $d_j = \frac{1}{m}\sum_k e_k\, g_j(x_k)$, $j = 1, \ldots, n$.
Passo 3: atualize todos os coeficientes *simultaneamente*: $\alpha_j^{(i+1)} = \alpha_j^{(i)} - \eta\, d_j$.
Passo 4: se $\|\mathbf{d}\|$ (ou a variação de J) for menor que a tolerância, pare; caso contrário, volte ao passo 1.

O passo η é chamado *taxa de aprendizagem*. Nos aplicativos, a atualização simultânea é feita guardando os valores antigos (`a1_antigo`, `d1_antigo`, ...) antes de alterar os coeficientes.

5.3.2 Gradiente descendente para a reta

No aplicativo da reta, o modelo é $\varphi(x) = \alpha_1 x + \alpha_2$ (aqui α_1 é a inclinação e α_2 o termo independente) e

$$\frac{\partial J}{\partial \alpha_1} = \frac{1}{m}\sum e_k x_k, \qquad \frac{\partial J}{\partial \alpha_2} = \frac{1}{m}\sum e_k.$$

Exemplo: as primeiras iterações, com $\eta = 0{,}1$ e os 5 pontos do exemplo anterior

Começando de $\alpha_1 = \alpha_2 = 0$, os resíduos são $e = (-1;\ -0{,}5;\ -1{,}5;\ -1;\ -1{,}5)$, e então

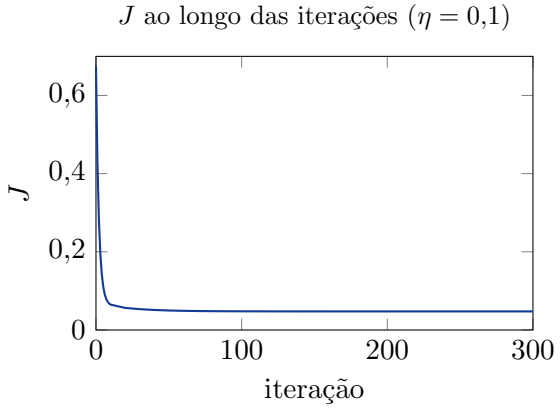
$$\frac{\partial J}{\partial \alpha_1} = \frac{0 - 0{,}25 - 1{,}5 - 1{,}5 - 3}{5} = -1{,}25, \qquad \frac{\partial J}{\partial \alpha_2} = \frac{-5{,}5}{5} = -1{,}1,$$

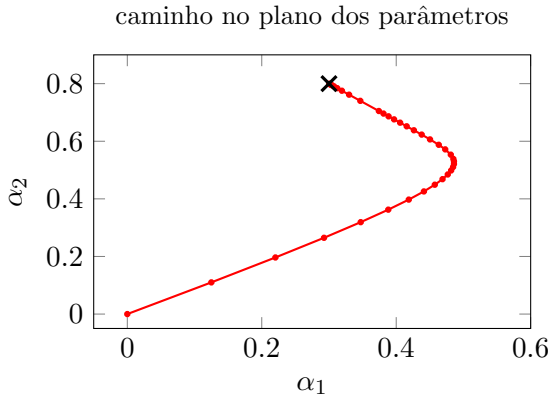
$$\alpha_1^{(1)} = 0 - 0{,}1(-1{,}25) = 0{,}125, \qquad \alpha_2^{(1)} = 0 - 0{,}1(-1{,}1) = 0{,}11.$$

Continuando:

iteração	α_1 (inclinação)	α_2 (termo indep.)	$D = \sum e_k^2$
0	0	0	6,75
1	0,125	0,11	4,2927
2	0,22025	0,1965	2,8251
3	0,29256	0,26483	1,9473
10	0,47673	0,48470	0,6491
50	0,39059	0,68397	0,4988
100	0,32991	0,76170	0,4776
500	0,30000	0,79999	0,4750

O método converge para $\alpha_1 = 0{,}3$ e $\alpha_2 = 0{,}8$, a mesma reta $\varphi(x) = 0{,}3x + 0{,}8$ do método direto, mas precisou de algumas centenas de iterações.





Atividade no GeoGebra: regressão linear por gradiente descendente [abrir o aplicativo]

Os pontos são J, K, L, M e T, os mesmos do exemplo. O botão **Iteração** faz um passo do método; **Limpar os Dados** volta a $\alpha_1 = \alpha_2 = 0$. O aplicativo mostra:

- a reta φ, os resíduos e o erro SSE $= \sum e_k^2$;
- as tabelas de x_k, y_k e $\hat{y}_k = \varphi(x_k)$;
- as curvas de nível do erro no plano (α_1, α_2) (elipses), com o ponto (α_1, α_2) caminhando em direção ao centro.

Tarefas. (a) Faça 10 iterações e confira a tabela do exemplo ($\alpha_1 \approx 0{,}4767$, $\alpha_2 \approx 0{,}4847$). (b) Observe que o caminho é sempre perpendicular às curvas de nível. (c) Repita com $\eta = 0{,}5$ e $\eta = 0{,}85$. (d) Tente $\eta = 0{,}9$: o que acontece?

Arquivo:
ggb/02_RegressaoLinearUsandoGradienteDescendente_junho.ggb

5.3.3 A escolha do passo e a convergência

Como J é quadrática, $J(\boldsymbol{\alpha}) = J(\boldsymbol{\alpha}^*) + \frac{1}{2}(\boldsymbol{\alpha} - \boldsymbol{\alpha}^*)^T H (\boldsymbol{\alpha} - \boldsymbol{\alpha}^*)$, com $H = \frac{1}{m} G^T G$ (a matriz do sistema normal dividida por m). A iteração fica

$$\boldsymbol{\alpha}^{(i+1)} - \boldsymbol{\alpha}^* = (I - \eta H)\,(\boldsymbol{\alpha}^{(i)} - \boldsymbol{\alpha}^*).$$

É uma iteração de ponto fixo, como as do Capítulo 2 e os métodos iterativos do Capítulo 3. Se $\lambda_{\min}$ e $\lambda_{\max}$ são o menor e o maior autovalor de H:

- o método converge se, e somente se, $0 < \eta < 2/\lambda_{\max}$;
- mesmo com o melhor passo, o erro cai por um fator próximo de $\dfrac{\kappa - 1}{\kappa + 1}$ por iteração, onde $\kappa = \lambda_{\max}/\lambda_{\min}$ é o *número de condição* de H. Quanto maior κ, mais lenta a convergência.

No exemplo da reta, os autovalores de H são 0,219 e 2,281. O passo máximo é $2/2{,}281 \approx 0{,}877$ (por isso $\eta = 0{,}9$ diverge) e $\kappa \approx 10{,}4$.

5.3.4 Padronização das variáveis

No Exemplo 5.2.4, os autovalores de H vão de 0,051 a 34 912, e $\kappa \approx 6{,}8 \times 10^5$. O passo máximo é $2/34\,912 \approx 5{,}7 \times 10^{-5}$. Com um passo tão pequeno, os coeficientes de $\operatorname{sen} x$, $\cos x$ e 1 quase não se movem: a função x^2, com valores até 400, domina o gradiente.

A solução é **padronizar** cada função: subtrair a média e dividir pelo desvio padrão dos seus valores nos pontos,

$$\tilde{g}_j(x) = \frac{g_j(x) - \mu_j}{\sigma_j}, \qquad \mu_j = \frac{1}{m}\sum_k g_j(x_k), \quad \sigma_j = \sqrt{\frac{1}{m}\sum_k \big(g_j(x_k) - \mu_j\big)^2},$$

e ajustar $\varphi(x) = \beta_1\tilde{g}_1(x) + \cdots + \beta_4\tilde{g}_4(x) + \beta_5$. Agora todas as funções têm média 0 e desvio 1 nos pontos. O número de condição cai para $\kappa \approx 102$, e o passo pode ser $\eta = 0{,}1$. Como as $\tilde{g}_j$ têm média zero, a derivada em relação a β_5 fica $\frac{1}{m}\sum e_k = 0$ quando $\beta_5 = \bar{f}$: por isso os aplicativos começam com β_5 igual à média dos y_k.

Os coeficientes originais são recuperados por

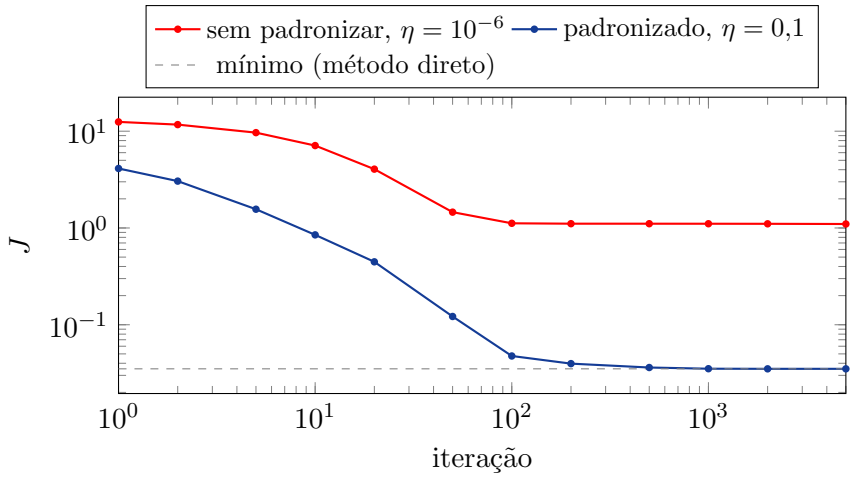
$$\alpha_j = \frac{\beta_j}{\sigma_j} \quad (j = 1, \ldots, 4), \qquad \alpha_5 = \beta_5 - \sum_{j=1}^{4} \frac{\beta_j \mu_j}{\sigma_j}.$$

Exemplo: sem e com padronização

Para os dados do Exemplo 5.2.4, partindo de coeficientes nulos ($\beta_5 = \bar{f} = 3{,}875$ no caso padronizado):

iteração	J sem padronizar ($\eta = 10^{-6}$)	J padronizado ($\eta = 0{,}1$)
0	13,3125	5,8047
10	7,1039	0,8488
50	1,4570	0,1217
100	1,1176	0,0476
500	1,1069	0,0361
1000	1,1060	0,0351
5000	1,0990	0,03504

O mínimo é $J = D/16 \approx 0{,}03504$. Sem padronizar, depois de 5000 iterações o erro ainda é 30 vezes maior; com padronização, o método chega ao mínimo e os β_j convertidos dão os mesmos α_j do método direto.



Atividade no GeoGebra: combinação de funções sem padronizar [abrir o aplicativo]

Funções $\varphi_1 = \operatorname{sen} x$, $\varphi_2 = \cos x$, $\varphi_3 = x^2$, $\varphi_4 = x$ e $\varphi_5 = 1$, os mesmos 8 pontos do Exemplo 5.2.4 e o passo 10^{-6}. O botão de iteração aplica um passo; o campo `iter` conta as iterações e o texto mostra o erro J e os parâmetros.
Tarefas. (a) Faça 50 iterações e confira $J \approx 1{,}457$. (b) Aumente o passo para 10^{-4} e observe a divergência ($10^{-4} > 5{,}7 \times 10^{-5}$). (c) Compare os parâmetros com os do método direto.

Arquivo:
`ggb/05_aproximacaoGDescCombFuncao.ggb`

Atividade no GeoGebra: combinação de funções padronizadas [abrir o aplicativo]

As funções são padronizadas pela média e pelo desvio padrão dos seus valores nos pontos (`medsen`, `desvsen`, ...), e β_5 começa igual à média dos y_k. O passo é 0,1.
Tarefas. (a) Com 9 iterações, confira $J \approx 0{,}931$. (b) Continue até J estabilizar perto de 0,035. (c) Verifique que a derivada em relação a β_5 fica praticamente nula.

Arquivo:
`ggb/06_aproximacaoGDescCombFuncao_Escalonada.ggb`

Atividade no GeoGebra: padronizado, com volta aos coeficientes originais[abrir o aplicativo]

Mesmo ajuste, com passo 0,01 e controles deslizantes para $\beta_1, \ldots, \beta_4$ (também se pode procurar o mínimo "à mão"). O aplicativo calcula $\alpha_j = \beta_j/\sigma_j$ e $\alpha_5 = \beta_5 - \sum \beta_j \mu_j/\sigma_j$.
Tarefa. Depois de convergir, compare os α_j com os do aplicativo do método direto (combinação de funções).

Arquivo:
`ggb/04_aproximacaoGDescCombFuncoespadronizada_03_07.ggb`

5.4 Método direto × método iterativo

	método direto (sistema normal)	gradiente descendente
ideia	igualar o gradiente a zero e resolver $G^T G\boldsymbol{\alpha} = G^T \mathbf{f}$	caminhar contra o gradiente: $\boldsymbol{\alpha} \leftarrow \boldsymbol{\alpha} - \eta \nabla J$
resultado	exato (a menos de arredondamento) em número finito de operações	aproximação que melhora a cada iteração
custo	montar $G^T G$ e resolver um sistema $n \times n$ (cerca de $n^3/3$ operações)	cada iteração custa da ordem de mn operações
parâmetros	nenhum	passo η, chute inicial, critério de parada
sensibilidade	mal condicionamento de $G^T G$ afeta a precisão	mal condicionamento deixa a convergência lenta; padronizar ajuda
quando usar	poucos parâmetros, modelo linear nos parâmetros	muitos dados ou parâmetros, modelos não lineares, redes neurais

Observação

Os dois métodos minimizam a mesma função. Para modelos lineares nos parâmetros e poucos coeficientes, o método direto é o mais simples e preciso. O gradiente descendente mostra a sua força quando o sistema normal é grande demais para ser montado, ou quando o modelo não é linear nos parâmetros (por exemplo, $a\,e^{bx}$ sem linearizar, ou uma rede neural). Nesses casos não há sistema linear a resolver, mas o gradiente continua disponível.

5.5 Exercícios

1. Ajuste uma reta aos pontos (1; 2), (2; 3), (3; 5) e (4; 6) pelo sistema normal e calcule D.
2. Para os mesmos pontos, faça duas iterações do gradiente descendente com $\varphi(x) = \alpha_1 x + \alpha_2$, $\eta = 0{,}05$, partindo de $\alpha_1 = \alpha_2 = 0$.
3. Mostre que, para a reta, a primeira equação do sistema normal equivale a $\bar{f} = \alpha_1 + \alpha_2 \bar{x}$: a reta de mínimos quadrados passa pelo ponto médio $(\bar{x}, \bar{f})$.
4. Escreva o sistema normal para $\varphi(x) = \alpha_1 + \alpha_2 \cos x$.
5. Linearize $\varphi(x) = a\,x^b$ e $\varphi(x) = \dfrac{1}{a + bx}$.
6. No exemplo da Seção 5.3.2, os autovalores de H são 0,219 e 2,281. Qual o maior passo que garante convergência? Que passo dá a convergência mais rápida?
7. Explique por que, depois de padronizar as funções $g_1, \ldots, g_4$, a derivada de J em relação ao termo constante β_5 se anula quando $\beta_5 = \bar{f}$, quaisquer que sejam $\beta_1, \ldots, \beta_4$.

Respostas

1. $\sum x = 10$, $\sum x^2 = 30$, $\sum f = 16$, $\sum xf = 47$. O sistema é $4\alpha_1 + 10\alpha_2 = 16$, $10\alpha_1 + 30\alpha_2 = 47$, com solução $\alpha_1 = 0{,}5$, $\alpha_2 = 1{,}4$, logo $\varphi(x) = 0{,}5 + 1{,}4x$ e $D = 0{,}2$.

2. Iteração 1: $e = (-2, -3, -5, -6)$, gradientes $-11{,}75$ e -4, logo $\alpha_1 = 0{,}5875$, $\alpha_2 = 0{,}2$. Iteração 2: $e = (-1{,}2125;\ -1{,}625;\ -3{,}0375;\ -3{,}45)$, gradientes $-6{,}84375$ e $-2{,}33125$, logo $\alpha_1 \approx 0{,}92969$, $\alpha_2 \approx 0{,}31656$.
3. Dividindo $m\alpha_1 + \alpha_2 \sum x_k = \sum f(x_k)$ por m.
4. $\begin{bmatrix} m & \sum \cos x_k \\ \sum \cos x_k & \sum \cos^2 x_k \end{bmatrix} \begin{bmatrix} \alpha_1 \\ \alpha_2 \end{bmatrix} = \begin{bmatrix} \sum f(x_k) \\ \sum f(x_k) \cos x_k \end{bmatrix}$.
5. $\ln \varphi = \ln a + b \ln x$ (reta nos pontos $(\ln x_k, \ln f(x_k))$); $1/\varphi = a + bx$ (reta nos pontos $(x_k, 1/f(x_k))$).
6. $\eta < 2/2{,}281 \approx 0{,}877$. O passo ótimo é $2/(\lambda_{\min} + \lambda_{\max}) = 2/2{,}5 = 0{,}8$.
7. $\partial J/\partial \beta_5 = \frac{1}{m} \sum e_k = \frac{1}{m} \sum_k \big(\sum_j \beta_j \tilde{g}_j(x_k) + \beta_5 - f(x_k) \big) = \sum_j \beta_j \overline{\tilde{g}_j} + \beta_5 - \bar{f} = \beta_5 - \bar{f}$, pois cada $\tilde{g}_j$ tem média zero.

Referências

- M. A. G. Ruggiero e V. L. R. Lopes, *Cálculo Numérico: aspectos teóricos e computacionais*, 2.ª ed., Makron Books (cap. 6, ajuste de curvas).
- A. Géron, *Mãos à obra: aprendizado de máquina com Scikit-Learn, Keras e TensorFlow*, Alta Books (gradiente descendente e padronização).

Capítulo 6

Integração numérica

Como usar os aplicativos deste capítulo

Ao longo do capítulo, os quadros laranja *Atividade no GeoGebra* trazem um link [**abrir o aplicativo**] que abre o arquivo correspondente no GeoGebra Classic:

- Regra dos trapézios repetida;
- Regra 1/3 de Simpson repetida;
- Regra 3/8 de Simpson repetida;
- Método de Romberg;
- Quadratura de Gauss-Legendre.

Para que os links funcionem, mantenha este PDF e a pasta `ggb` juntos, na mesma pasta, e abra o PDF num leitor que permita abrir arquivos externos (Adobe Acrobat Reader, Okular, SumatraPDF, Foxit). Os leitores de PDF embutidos nos navegadores costumam bloquear esse tipo de link; nesse caso, abra os arquivos da pasta `ggb` diretamente no GeoGebra.

Os cinco aplicativos começam com a integral $\int_0^1 e^{-x^2}\,dx$, que é o exemplo desenvolvido no texto. Em todos eles é possível digitar outra função no campo $f(x) =$, mudar o intervalo $[a, b]$ nos controles deslizantes e usar o botão *Enquadrar o gráfico* para ajustar a janela. A janela da direita mostra as contas e tem barras de rolagem (vertical e horizontal). O valor de referência da integral é calculado pelo próprio GeoGebra, com precisão bem maior que a dos métodos estudados.

6.1 O problema da integração numérica

O Teorema Fundamental do Cálculo resolve a integral definida quando conhecemos uma primitiva: $\int_a^b f(x)\,dx = F(b) - F(a)$, com $F' = f$. Na prática, esse caminho falha com frequência:

- muitas funções simples não têm primitiva expressa por funções elementares, como e^{-x^2}, $\dfrac{\operatorname{sen} x}{x}$, $\sqrt{1+\cos^2 x}$ (comprimento de arco de uma senoide) ou $\dfrac{1}{\ln x}$;
- às vezes a primitiva existe, mas é tão complicada que avaliá-la custa mais (e acumula mais erros de arredondamento) do que aproximar a integral diretamente;
- muitas vezes f só é conhecida numa tabela de valores medidos (velocidades, vazões, temperaturas) e não há fórmula para integrar.

A ideia central deste capítulo vem do Capítulo 4: *trocamos f por um polinômio interpolador p e integramos p*, o que é sempre fácil. Como p é uma combinação dos valores $f(x_i)$ nos nós, a

integral aproximada também é:

$$\int_a^b f(x)\,dx \;\approx\; \int_a^b p(x)\,dx \;=\; \sum_{i=0}^{n} w_i\, f(x_i).$$

Uma expressão desse tipo chama-se *fórmula de quadratura*; os x_i são os *nós* e os w_i são os *pesos*. Os pesos dependem só dos nós, não de f.

Definição 6.1. Uma fórmula de quadratura tem *grau de exatidão* m se é exata (erro zero) para todos os polinômios de grau menor ou igual a m e não é exata para algum polinômio de grau $m+1$. Como a fórmula e a integral são lineares, basta testar $1, x, x^2, \ldots, x^{m+1}$.

Usaremos ao longo de todo o capítulo o mesmo exemplo,

$$I = \int_0^1 e^{-x^2}\,dx = 0{,}746824132812\ldots,$$

uma integral sem primitiva elementar (ela aparece na distribuição normal da Estatística, por meio da função erro erf). O valor acima foi obtido com alta precisão e serve para medir o erro de cada método.

Dividimos os métodos em dois grupos:

1. **Fórmulas de Newton-Cotes**: nós igualmente espaçados, $x_i = a + ih$. São as regras dos trapézios, 1/3 de Simpson e 3/8 de Simpson, quase sempre usadas na forma *repetida* (composta). A extrapolação de Richardson e o método de Romberg melhoram os trapézios sem novos tipos de fórmula.
2. **Quadratura de Gauss**: os nós também são escolhidos, de modo a obter o maior grau de exatidão possível com poucos pontos.

6.2 Regra dos trapézios

6.2.1 Regra simples

Interpolando f nos dois extremos, $x_0 = a$ e $x_1 = b$, obtemos a reta $p_1(x) = f(x_0) + \dfrac{f(x_1)-f(x_0)}{h}(x-x_0)$, com $h = b-a$. A área sob essa reta é a área de um trapézio:

$$\int_{x_0}^{x_1} f(x)\,dx \approx T = \frac{h}{2}\big[f(x_0)+f(x_1)\big].$$

Teorema 6.2 (Erro da regra dos trapézios simples)**.** *Se f'' é contínua em $[x_0, x_1]$ e $h = x_1 - x_0$, existe $\eta \in (x_0, x_1)$ tal que*

$$\int_{x_0}^{x_1} f(x)\,dx - \frac{h}{2}\big[f(x_0)+f(x_1)\big] = -\frac{h^3}{12}\,f''(\eta).$$

Demonstração. Pelo Teorema 4.7 (erro da interpolação) com dois nós, $f(x)-p_1(x) = \dfrac{f''(\xi(x))}{2}(x-x_0)(x-x_1)$. O produto $(x-x_0)(x-x_1)$ não muda de sinal em $[x_0, x_1]$ (é ≤ 0), então o Teorema do Valor Médio para integrais permite tirar f'' de dentro da integral:

$$\int_{x_0}^{x_1} \big(f - p_1\big)\,dx = \frac{f''(\eta)}{2}\int_{x_0}^{x_1}(x-x_0)(x-x_1)\,dx = \frac{f''(\eta)}{2}\cdot\Big(-\frac{h^3}{6}\Big) = -\frac{h^3}{12}f''(\eta). \qquad \blacksquare$$

O erro depende de f'': a regra é exata para retas (grau de exatidão 1). Se f é côncava para cima ($f'' > 0$), o trapézio fica acima do gráfico e a regra superestima a integral; se $f'' < 0$, subestima.

6.2.2 Regra repetida

Com um único trapézio, $h = b - a$ é grande e o erro também. A solução é dividir $[a, b]$ em n subintervalos iguais, de comprimento $h = \dfrac{b-a}{n}$, com nós $x_i = a + ih$ $(i = 0, 1, \ldots, n)$, e somar as áreas dos n trapézios. Cada nó interno pertence a dois trapézios, por isso aparece com peso 2:

$$\boxed{T_n = \frac{h}{2}\Big[f(x_0) + 2f(x_1) + 2f(x_2) + \cdots + 2f(x_{n-1}) + f(x_n)\Big]}$$

Teorema 6.3 (Erro da regra dos trapézios repetida)**.** *Se f'' é contínua em $[a, b]$, existe $\eta \in (a, b)$ tal que*

$$\int_a^b f(x)\,dx - T_n = -\frac{(b-a)\,h^2}{12}\,f''(\eta).$$

Em particular, se $|f''(x)| \le M_2$ em $[a, b]$, então $\left|\int_a^b f(x)\,dx - T_n\right| \le \dfrac{(b-a)\,h^2}{12}\,M_2$.

Demonstração. Somando os erros dos n trapézios (Teorema 6.2), o erro total é $-\dfrac{h^3}{12}\sum_{i=1}^{n} f''(\eta_i)$. A média $\frac{1}{n}\sum f''(\eta_i)$ está entre o mínimo e o máximo de f''; pelo Teorema do Valor Intermediário, ela é igual a $f''(\eta)$ para algum η. Assim, o erro é $-\dfrac{h^3}{12}\,n\,f''(\eta)$, e $nh = b - a$. ∎

O erro é proporcional a h^2: dobrar n (dividir h por 2) divide o erro por aproximadamente 4.

Exemplo: $\int_0^1 e^{-x^2}\,dx$ pela regra dos trapézios

Com $n = 4$, $h = 0{,}25$ e os nós 0; 0,25; 0,5; 0,75; 1:

i	0	1	2	3	4
x_i	0	0,25	0,5	0,75	1
$f(x_i)$	1	0,93941307	0,77880078	0,56978282	0,36787944
peso	1	2	2	2	1

$$\begin{aligned} T_4 &= \frac{0{,}25}{2}\big[1 + 2(0{,}93941307 + 0{,}77880078 + 0{,}56978282) + 0{,}36787944\big] \\ &= \frac{0{,}25}{2} \cdot 5{,}94387278 = 0{,}74298410. \end{aligned}$$

O erro real é $|I - T_4| \approx 3{,}84 \times 10^{-3}$. Para a cota, $f''(x) = (4x^2 - 2)e^{-x^2}$ e $M_2 = \max_{[0,1]} |f''(x)| = 2$ (em $x = 0$), logo $\dfrac{(b-a)h^2}{12}M_2 = \dfrac{0{,}0625}{12} \cdot 2 \approx 1{,}04 \times 10^{-2}$, coerente com o erro observado. Dobrando n sucessivamente:

n	T_n	$\lvert I - T_n\rvert$	razão entre erros consecutivos
1	0,6839397206	$6{,}29 \times 10^{-2}$	
2	0,7313702518	$1{,}55 \times 10^{-2}$	4,07
4	0,7429840978	$3{,}84 \times 10^{-3}$	4,02
8	0,7458656148	$9{,}59 \times 10^{-4}$	4,01
16	0,7465845968	$2{,}40 \times 10^{-4}$	4,00

A razão se aproxima de $4 = 2^2$, como previsto.

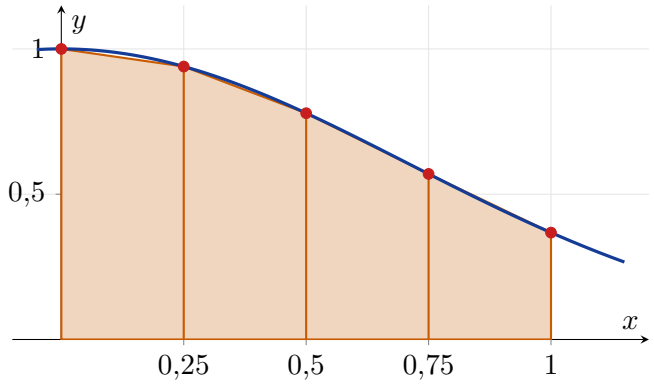


Figura 6.1: Regra dos trapézios repetida para $\int_0^1 e^{-x^2}\,dx$ com $n = 4$.

Atividade no GeoGebra: regra dos trapézios repetida [abrir o aplicativo]

Abra o aplicativo. À esquerda ficam o gráfico de f, os trapézios e os controles; à direita, o passo h, a tabela com os nós, os valores $f(x_i)$, os pesos c_i e os produtos $c_i\,f(x_i)$, a soma S, o valor $T_n = \frac{h}{2}S$ e o quadro do erro.

1. Confira, com $n = 4$, todos os números do exemplo acima.
2. Faça $n = 2, 4, 8, 16$ e anote o erro $\lvert I - T_n\rvert$. Calcule as razões entre erros consecutivos.
3. Marque *Mostrar a área exata*. Em que partes do intervalo os trapézios ficam acima do gráfico? Relacione com o sinal de $f''(x) = (4x^2 - 2)e^{-x^2}$.
4. Digite $f(x) = 3x + 1$ e depois $f(x) = x^2$. Para qual das duas a regra é exata? Por quê?
5. Digite $f(x) = x^2$ em $[0, 1]$ e confira que o erro real é *igual* à cota. O que há de especial com f'' nesse caso?

Arquivo:
ggb/RegraTrapezios_repetida.ggb

6.3 Regra 1/3 de Simpson

6.3.1 Regra simples

Agora interpolamos f por uma parábola em três nós igualmente espaçados x_0, $x_1 = x_0 + h$, $x_2 = x_0 + 2h$. Pela forma de Lagrange, $p_2(x) = f(x_0)L_0(x) + f(x_1)L_1(x) + f(x_2)L_2(x)$, e basta

integrar as bases. Com a mudança de variável $x = x_0 + sh$ ($dx = h\,ds$, $s \in [0,2]$):

$$\int_{x_0}^{x_2} L_0(x)\,dx = h\int_0^2 \frac{(s-1)(s-2)}{2}\,ds = \frac{h}{3}, \qquad \int_{x_0}^{x_2} L_1(x)\,dx = h\int_0^2 \frac{s(s-2)}{-1}\,ds = \frac{4h}{3},$$
$$\int_{x_0}^{x_2} L_2(x)\,dx = h\int_0^2 \frac{s(s-1)}{2}\,ds = \frac{h}{3}.$$

Portanto

$$\int_{x_0}^{x_2} f(x)\,dx \approx \frac{h}{3}\big[f(x_0) + 4f(x_1) + f(x_2)\big].$$

O nome vem do fator $h/3$. Os pesos somam $2h$, que é o comprimento do intervalo, como deve ser para que a fórmula integre exatamente $f \equiv 1$.

Teorema 6.4 (Erro da regra 1/3 de Simpson simples)**.** *Se $f^{(4)}$ é contínua em $[x_0, x_2]$, existe $\eta \in (x_0, x_2)$ tal que*

$$\int_{x_0}^{x_2} f(x)\,dx - \frac{h}{3}\big[f(x_0) + 4f(x_1) + f(x_2)\big] = -\frac{h^5}{90} f^{(4)}(\eta).$$

Observação

Esperaríamos um erro com f''', pois interpolamos por um polinômio de grau 2. Mas a fórmula é exata também para x^3: por simetria, para $f(x) = (x - x_1)^3$ a integral em $[x_0, x_2]$ é zero e a fórmula também dá $\frac{h}{3}[(-h)^3 + 0 + h^3] = 0$. Assim, a regra 1/3 tem grau de exatidão 3, e o erro depende de $f^{(4)}$. Esse "ganho grátis" acontece em todas as fórmulas de Newton-Cotes com número ímpar de nós.

6.3.2 Regra repetida

Dividimos $[a, b]$ em um número **par** n de subintervalos, $h = \dfrac{b-a}{n}$, e aplicamos a regra simples em cada par $[x_0, x_2]$, $[x_2, x_4]$, …, $[x_{n-2}, x_n]$. Os nós de índice ímpar são meios de pares (peso 4); os de índice par interno são extremos de dois pares (peso 2):

$$\boxed{S_n = \frac{h}{3}\Big[f(x_0) + 4f(x_1) + 2f(x_2) + 4f(x_3) + \cdots + 2f(x_{n-2}) + 4f(x_{n-1}) + f(x_n)\Big]}$$

Teorema 6.5 (Erro da regra 1/3 de Simpson repetida)**.** *Se $f^{(4)}$ é contínua em $[a, b]$ e n é par, existe $\eta \in (a, b)$ tal que*

$$\int_a^b f(x)\,dx - S_n = -\frac{(b-a)\,h^4}{180} f^{(4)}(\eta), \qquad \textit{logo} \qquad \left|\int_a^b f(x)\,dx - S_n\right| \le \frac{(b-a)\,h^4}{180} M_4,$$

com $M_4 = \max_{[a,b]} |f^{(4)}(x)|$.

(A demonstração é a mesma do Teorema 6.3: são $n/2$ parcelas $-\frac{h^5}{90} f^{(4)}(\eta_i)$ e $\frac{n}{2} h^5 = \frac{(b-a)h^4}{2}$.) Agora dobrar n divide o erro por aproximadamente $2^4 = 16$.

Exemplo: $\int_0^1 e^{-x^2}\,dx$ pela regra 1/3 de Simpson

Com $n = 4$ usamos os mesmos cinco valores do exemplo dos trapézios, com pesos $1, 4, 2, 4, 1$:

$$S_4 = \frac{0{,}25}{3}\big[1 + 4(0{,}93941307) + 2(0{,}77880078) + 4(0{,}56978282) + 0{,}36787944\big]$$
$$= \frac{0{,}25}{3} \cdot 8{,}96226456 = 0{,}74685538.$$

O erro real é $|I - S_4| \approx 3{,}12 \times 10^{-5}$, cerca de 120 vezes menor que o dos trapézios com os *mesmos* cinco valores de f. Para a cota, $f^{(4)}(x) = (16x^4 - 48x^2 + 12)e^{-x^2}$ e $M_4 = 12$ (em $x = 0$): $\dfrac{1 \cdot 0{,}25^4}{180} \cdot 12 \approx 2{,}60 \times 10^{-4}$.

n	S_n	$\lvert I - S_n\rvert$	razão
2	0,7471804289	$3{,}56 \times 10^{-4}$	
4	0,7468553798	$3{,}12 \times 10^{-5}$	11,4
8	0,7468261205	$1{,}99 \times 10^{-6}$	15,7
16	0,7468242574	$1{,}25 \times 10^{-7}$	15,9

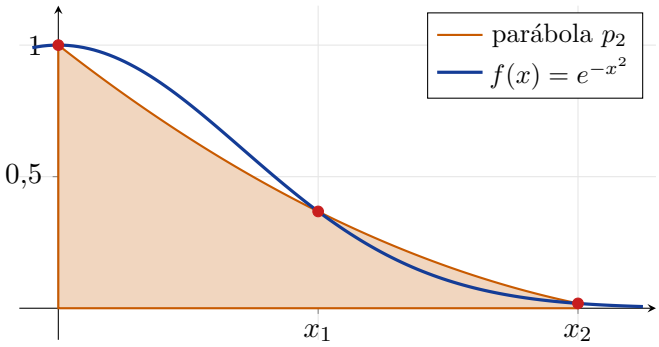


Figura 6.2: Regra 1/3 de Simpson simples: a área sob a parábola que passa pelos três nós substitui a área sob f. Aqui, $f(x) = e^{-x^2}$ em $[0, 2]$ com $h = 1$ (escolhido grande para que a diferença entre as curvas fique visível).

Atividade no GeoGebra: regra 1/3 de Simpson repetida [abrir o aplicativo]

O aplicativo desenha, em cada par de subintervalos, a região sob a parábola que passa pelos três nós. À direita aparecem a tabela com os pesos $1, 4, 2, 4, \ldots, 4, 1$, a soma, S_n e o quadro do erro.

1. Confira os números do exemplo com $n = 4$ e compare com a tabela dos trapézios (os valores $f(x_i)$ são os mesmos; só os pesos mudam).
2. Faça $n = 2, 4, 8, 16$ e verifique que as razões entre os erros se aproximam de 16.
3. Digite $f(x) = x^3 - 2x + 1$ em $[-1, 2]$ com $n = 2$. O erro é zero? Explique com o grau de exatidão. E com $f(x) = x^4$?
4. Com $f(x) = e^{-x^2}$ em $[0, 2]$ e $n = 2$, compare o gráfico com a Figura 6.2. Aumente n e observe as parábolas se confundirem com f.

Arquivo:
ggb/RegraSimpson13_repetida.ggb

6.4 Regra 3/8 de Simpson

Interpolando f por uma cúbica em quatro nós igualmente espaçados $x_0, \dots, x_3$ e integrando as bases de Lagrange (com $x = x_0 + sh$, $s \in [0,3]$), obtemos

$$\int_{x_0}^{x_3} f(x)\,dx \approx \frac{3h}{8}\big[f(x_0) + 3f(x_1) + 3f(x_2) + f(x_3)\big], \qquad \text{erro} = -\frac{3h^5}{80}\,f^{(4)}(\eta).$$

O grau de exatidão também é 3: o quarto nó não aumenta o grau, apenas melhora a constante do erro por trecho. Na forma repetida, com n **múltiplo de 3**, os nós que separam dois grupos têm peso 2 e os demais nós internos têm peso 3:

$$\boxed{S_n^{3/8} = \frac{3h}{8}\Big[f(x_0) + 3f(x_1) + 3f(x_2) + 2f(x_3) + 3f(x_4) + \cdots + 3f(x_{n-1}) + f(x_n)\Big]}$$

com erro $-\dfrac{(b-a)\,h^4}{80}\,f^{(4)}(\eta)$.

Comparando as cotas, $\frac{1}{80} > \frac{1}{180}$: com o mesmo h, a regra 1/3 costuma ser mais precisa. A regra 3/8 é útil quando o número de subintervalos é ímpar (por exemplo, numa tabela de dados com $n = 7$): aplica-se a 3/8 em três subintervalos e a 1/3 nos quatro restantes.

Exemplo: $\int_0^1 e^{-x^2}\,dx$ pela regra 3/8 de Simpson

Com $n = 3$, $h = \frac{1}{3}$ e $f(0) = 1$, $f(\frac{1}{3}) = 0{,}89483932$, $f(\frac{2}{3}) = 0{,}64118039$, $f(1) = 0{,}36787944$:

$$\begin{aligned} S_3^{3/8} &= \frac{3 \cdot \frac{1}{3}}{8}\big[1 + 3(0{,}89483932) + 3(0{,}64118039) + 0{,}36787944\big] \\ &= \frac{1}{8} \cdot 5{,}97593856 = 0{,}74699232, \end{aligned}$$

com erro $|I - S_3^{3/8}| \approx 1{,}68 \times 10^{-4}$. Com $n = 6$, $S_6^{3/8} = 0{,}7468380575$ e o erro cai para $1{,}39 \times 10^{-5}$ (razão ≈ 12). Com o mesmo $n = 6$, a regra 1/3 dá erro $\approx 6{,}3 \times 10^{-6}$ (Exercício **4.**).

Atividade no GeoGebra: regra 3/8 de Simpson repetida [abrir o aplicativo]

Aqui cada grupo de três subintervalos é substituído pela cúbica que passa pelos quatro nós.

1. Confira o exemplo com $n = 3$ e depois com $n = 6$.
2. Abra também o aplicativo da regra 1/3 e use $n = 6$ e $n = 12$ nos dois. Qual regra tem o menor erro? A razão entre os erros é próxima de $\frac{180}{80} = 2{,}25$?
3. Teste $f(x) = x^3$ e $f(x) = x^4$ em $[0,3]$ com $n = 3$. Confira que o grau de exatidão é 3.

Arquivo:
ggb/RegraSimpson38_repetida.ggb

6.5 Fórmulas de Newton-Cotes: resumo

As três regras são casos da mesma construção: nós igualmente espaçados e integração do polinômio interpolador. Na tabela, h é o espaçamento e o erro é o da fórmula simples.

fórmula (simples)	nós	grau de exatidão	erro
trapézios: $\frac{h}{2}(f_0+f_1)$	2	1	$-\frac{h^3}{12}f''(\eta)$
1/3 de Simpson: $\frac{h}{3}(f_0+4f_1+f_2)$	3	3	$-\frac{h^5}{90}f^{(4)}(\eta)$
3/8 de Simpson: $\frac{3h}{8}(f_0+3f_1+3f_2+f_3)$	4	3	$-\frac{3h^5}{80}f^{(4)}(\eta)$
Boole: $\frac{2h}{45}(7f_0+32f_1+12f_2+32f_3+7f_4)$	5	5	$-\frac{8h^7}{945}f^{(6)}(\eta)$

Observação

Por que não usar um único polinômio de grau alto em todo o intervalo? Pelo mesmo motivo do fenômeno de Runge (Figura 4.4): com muitos nós igualmente espaçados o polinômio interpolador pode oscilar, e, a partir de 9 nós, as fórmulas de Newton-Cotes passam a ter pesos negativos, o que amplifica erros de arredondamento. Na prática, usamos fórmulas de grau baixo *repetidas* em muitos subintervalos.

6.6 Quantos subintervalos usar?

As cotas de erro permitem escolher n *antes* de calcular, desde que saibamos limitar a derivada que aparece na fórmula.

Exemplo: escolha de n para $\int_1^2 \frac{dx}{x} = \ln 2$ com erro menor que 10^{-4}

Para $f(x)=\frac{1}{x}$ temos $f''(x)=\frac{2}{x^3}$ e $f^{(4)}(x)=\frac{24}{x^5}$, ambas decrescentes em $[1,2]$; logo $M_2=2$ e $M_4=24$.

Trapézios: $\dfrac{(2-1)h^2}{12}\cdot 2 \le 10^{-4} \iff h^2 \le 6\times 10^{-4} \iff h \le 0{,}02449$. Como $h=\frac{1}{n}$, precisamos de $n \ge 40{,}8$, isto é, $n=41$ subintervalos (42 valores de f).

Simpson 1/3: $\dfrac{(2-1)h^4}{180}\cdot 24 \le 10^{-4} \iff h^4 \le 7{,}5\times 10^{-4} \iff h \le 0{,}1655$, isto é, $n \ge 6{,}04$; como n deve ser par, $n=8$ (9 valores de f).

Os erros reais são $|\ln 2 - T_{41}| \approx 3{,}7\times 10^{-5}$ e $|\ln 2 - S_8| \approx 7{,}4\times 10^{-6}$. As cotas garantem a tolerância, mas são pessimistas: com S_6 o erro já seria $2{,}3\times 10^{-5}$.

Quando não conseguimos limitar a derivada (ou f vem de uma tabela), uma alternativa é comparar duas aproximações: se T_n e T_{2n} concordam em k casas, temos uma boa ideia da precisão. A próxima seção transforma essa comparação num método muito mais eficiente.

6.7 Extrapolação de Richardson e método de Romberg

6.7.1 A ideia de Richardson

Para f suficientemente derivável, a fórmula de Euler-Maclaurin garante que o erro dos trapézios tem uma expansão em potências *pares* de h:

$$T(h) = I + c_1 h^2 + c_2 h^4 + c_3 h^6 + \cdots,$$

com $c_1, c_2, \ldots$ que não dependem de h. Escrevendo a mesma expressão para $h/2$,

$$T(h/2) = I + c_1\frac{h^2}{4} + c_2\frac{h^4}{16} + \cdots,$$

e combinando as duas para eliminar o termo em h^2:

$$\frac{4\,T(h/2) - T(h)}{3} = I - \frac{c_2}{4}h^4 + \cdots = T(h/2) + \frac{T(h/2) - T(h)}{3}.$$

O resultado tem erro $O(h^4)$, muito menor, sem nenhuma nova avaliação de f. Isso é a *extrapolação de Richardson*.

Proposição 6.6. *Para todo n, $\dfrac{4\,T_{2n} - T_n}{3} = S_{2n}$: um passo de Richardson aplicado aos trapézios reproduz a regra 1/3 de Simpson.*

Demonstração. Basta verificar num par de subintervalos $[x_0, x_2]$ de comprimento $2h$: $T_1 = h\,(f_0 + f_2)$ e $T_2 = \frac{h}{2}(f_0 + 2f_1 + f_2)$. Então $\frac{4T_2 - T_1}{3} = \frac{h}{3}\big(2f_0 + 4f_1 + 2f_2 - f_0 - f_2\big) = \frac{h}{3}(f_0 + 4f_1 + f_2)$. Somando sobre os pares, obtemos S_{2n}. ∎

6.7.2 O método de Romberg

Repetindo a ideia, cada nova coluna elimina mais um termo da expansão (h^4, depois h^6, …). Organizamos tudo numa tabela triangular.

Algoritmo: método de Romberg

1. Para $k = 0, 1, \ldots, K$: calcule $R_{k,0} = T_{2^k}$ (trapézios com 2^k subintervalos). Cada T_{2^k} reaproveita todos os valores de f de $T_{2^{k-1}}$: $T_{2n} = \frac{1}{2}T_n + h_{2n}\sum f(\text{novos pontos médios})$.
2. Para $j = 1, \ldots, k$:
$$R_{k,j} = R_{k,j-1} + \frac{R_{k,j-1} - R_{k-1,j-1}}{4^j - 1}.$$
3. Pare quando $|R_{k,k} - R_{k-1,k-1}|$ for menor que a tolerância. A melhor aproximação é $R_{K,K}$.

Pela Proposição 6.6, a coluna $R_{k,1}$ é a regra 1/3 de Simpson com 2^k subintervalos; a coluna $R_{k,2}$ coincide com a regra de Boole.

Exemplo: Romberg para $\int_0^1 e^{-x^2}\,dx$ com $K = 4$

k	n	$R_{k,0} = T_n$	$R_{k,1}$	$R_{k,2}$	$R_{k,3}$	$R_{k,4}$
0	1	0,6839397206				
1	2	0,7313702518	0,7471804289			
2	4	0,7429840978	0,7468553798	0,7468337098		
3	8	0,7458656148	0,7468261205	0,7468241699	0,7468240185	
4	16	0,7465845968	0,7468242574	0,7468241332	0,7468241326	0,7468241331

Por exemplo, $R_{1,1} = 0{,}7313702518 + \frac{0{,}7313702518 - 0{,}6839397206}{3} = 0{,}7471804289$. Com os mesmos 17 valores de f usados por T_{16} (erro $2{,}4 \times 10^{-4}$), o valor $R_{4,4}$ tem erro de apenas $2{,}8 \times 10^{-10}$.

Observação

Na linha $k = 3$, $R_{3,3}$ (erro $1{,}1 \times 10^{-7}$) é um pouco pior que $R_{3,2}$ (erro $3{,}7 \times 10^{-8}$). A expansão $c_1h^2 + c_2h^4 + \cdots$ só descreve bem o erro quando h já é pequeno; com $h = \frac{1}{8}$ o termo seguinte ainda pesa. Por isso o critério de parada compara linhas sucessivas da diagonal. Se f não for suave (por exemplo, $\sqrt{x}$ perto de 0), a expansão nem vale, e o ganho do método desaparece (Exercício **11.**).

Atividade no GeoGebra: método de Romberg **[abrir o aplicativo]**

O controle K escolhe quantas linhas da tabela aparecem; o controle m escolhe quais trapézios (2^m subintervalos) são desenhados.

1. Com $K = 4$, confira a tabela do exemplo e o erro de $R_{4,4}$.
2. Compare a coluna $R_{k,1}$ com os valores S_n obtidos no aplicativo da regra 1/3.
3. Com $K = 5$, quantas avaliações de f foram usadas? Qual é o erro de $R_{5,5}$?
4. Digite $f(x) = \sqrt{x}$ em $[0, 1]$ e compare os erros dos trapézios e de Romberg com os de e^{-x^2}. O que mudou?

Arquivo:
ggb/MetodoRomberg.ggb

6.8 Quadratura de Gauss-Legendre

6.8.1 A ideia

Nas fórmulas de Newton-Cotes os nós são fixados de antemão e só os pesos são escolhidos; com n nós, o grau de exatidão é $n - 1$ ou n. Se escolhermos também os nós, teremos $2n$ parâmetros livres ($x_1, \ldots, x_n$ e $w_1, \ldots, w_n$) e poderemos exigir exatidão para $1, x, \ldots, x^{2n-1}$, ou seja, grau de exatidão $2n - 1$.

Trabalhamos no intervalo padrão $[-1, 1]$. Para $n = 2$, queremos $\int_{-1}^{1} g(t)\,dt \approx w_1 g(t_1) + w_2 g(t_2)$ exata para $g = 1, t, t^2, t^3$:

$$\begin{cases} w_1 + w_2 = 2 \\ w_1 t_1 + w_2 t_2 = 0 \\ w_1 t_1^2 + w_2 t_2^2 = \frac{2}{3} \\ w_1 t_1^3 + w_2 t_2^3 = 0 \end{cases}$$

Por simetria, procuramos $t_2 = -t_1$ e $w_1 = w_2$. A primeira equação dá $w_1 = w_2 = 1$ e a terceira, $2t_1^2 = \frac{2}{3}$, ou seja, $t_{1,2} = \mp\frac{1}{\sqrt{3}}$. Assim,

$$\int_{-1}^{1} g(t)\,dt \approx g\Big(-\tfrac{1}{\sqrt{3}}\Big) + g\Big(\tfrac{1}{\sqrt{3}}\Big),$$

exata para cúbicas com apenas *duas* avaliações (a regra 1/3 de Simpson precisa de três).

Para n qualquer, os nós são as raízes do *polinômio de Legendre* $P_n(t)$ (por isso o nome Gauss-Legendre) e os pesos são positivos. A tabela traz os primeiros casos.

n	nós t_i	pesos w_i
1	0	2
2	$\pm\frac{1}{\sqrt{3}} \approx \pm 0{,}5773502692$	1
3	$0;\quad \pm\sqrt{\frac{3}{5}} \approx \pm 0{,}7745966692$	$\frac{8}{9};\quad \frac{5}{9}$
4	$\pm 0{,}3399810436;\quad \pm 0{,}8611363116$	$0{,}6521451549;\quad 0{,}3478548451$
5	$0;\quad \pm 0{,}5384693101;\quad \pm 0{,}9061798459$	$0{,}5688888889;\quad 0{,}4786286705;\quad 0{,}2369268851$

6.8.2 Mudança de intervalo

Para integrar em $[a,b]$, usamos a mudança de variável afim $x = \dfrac{b-a}{2}\,t + \dfrac{a+b}{2}$, que leva $[-1,1]$ em $[a,b]$, com $dx = \frac{b-a}{2}\,dt$:

$$\int_a^b f(x)\,dx \approx G_n = \frac{b-a}{2}\sum_{i=1}^{n} w_i\, f(x_i), \qquad x_i = \frac{b-a}{2}\,t_i + \frac{a+b}{2}.$$

Teorema 6.7 (Erro da quadratura de Gauss-Legendre)**.** *Se $f^{(2n)}$ é contínua em $[a,b]$, existe $\eta \in (a,b)$ tal que*

$$\int_a^b f(x)\,dx - G_n = \frac{(b-a)^{2n+1}\,(n!)^4}{(2n+1)\,\big[(2n)!\big]^3}\, f^{(2n)}(\eta).$$

Exemplo: $\int_0^1 e^{-x^2}\,dx$ por Gauss-Legendre

Aqui $\frac{b-a}{2} = \frac{a+b}{2} = \frac{1}{2}$, logo $x_i = \frac{t_i+1}{2}$.
Dois pontos: $x_{1,2} = \frac{1}{2} \mp \frac{1}{2\sqrt{3}} \approx 0{,}21132487$ e $0{,}78867513$;

$$G_2 = \frac{1}{2}\big[e^{-0{,}21132487^2} + e^{-0{,}78867513^2}\big] = \frac{1}{2}\big[0{,}95632430 + 0{,}53686508\big] = 0{,}74659469,$$

com erro $2{,}29 \times 10^{-4}$. Com o mesmo número de avaliações, o trapézio simples tem erro $6{,}3 \times 10^{-2}$.
Três pontos: $x_2 = \frac{1}{2}$ e $x_{1,3} = \frac{1}{2} \mp \frac{1}{2}\sqrt{0{,}6} \approx 0{,}11270167$ e $0{,}88729833$;

$$G_3 = \frac{1}{2}\Big[\tfrac{5}{9}\, f(0{,}11270167) + \tfrac{8}{9}\, f(0{,}5) + \tfrac{5}{9}\, f(0{,}88729833)\Big] = 0{,}74681458,$$

com erro $9{,}5 \times 10^{-6}$, cerca de 37 vezes menor que o de Simpson simples (S_2, também com três avaliações). Com cinco pontos, $G_5 = 0{,}7468241268$, com erro 6×10^{-9}.

Atividade no GeoGebra: quadratura de Gauss-Legendre [abrir o aplicativo]

O aplicativo mostra os nós t_i e os pesos w_i, os nós x_i já transportados para $[a,b]$, o valor G_{np} e uma comparação com os trapézios e com Simpson. No gráfico, a curva tracejada é o polinômio que passa pelos pontos $(x_i, f(x_i))$, e a área laranja é a sua integral.

1. Confira os valores do exemplo para $np = 2$ e $np = 3$.
2. Verifique que a área laranja é igual a G_{np}. Por que isso acontece? (Pense na fórmula como integral de um polinômio interpolador.)

3. Com $np = 2$, digite $f(x) = x^3$ e depois $f(x) = x^4$ em $[0, 1]$. Em qual caso o erro é zero? Confira o erro do segundo caso com o teorema acima.
4. Digite $f(x) = 1/(1 + 25x^2)$ em $[-1, 1]$ e aumente np de 1 a 5. O polinômio tracejado oscila, mas o erro diminui (com oscilações). Para a quadratura de Gauss, sabe-se que $G_n \to I$ para toda f contínua, pois os pesos são positivos; com 20 pontos o erro já seria $3{,}6 \times 10^{-4}$.

Arquivo:
ggb/QuadraturaGaussLegendre.ggb

Observação

A quadratura de Gauss não usa os extremos a e b. Isso permite integrar funções que não estão definidas nos extremos, como $\int_0^1 \frac{\operatorname{sen} x}{x}\,dx$ ou $\int_0^1 \frac{dx}{\sqrt{x}}$ (esta última converge devagar, mas a fórmula pode ser aplicada). Por outro lado, os nós são números irracionais, o que torna o método inadequado para dados tabelados em pontos igualmente espaçados.

6.9 Comparação dos métodos

A tabela reúne os resultados do exemplo $\int_0^1 e^{-x^2}\,dx$. O custo de um método de integração numérica se mede, principalmente, pelo número de avaliações de f.

método	avaliações de f	aproximação	erro
trapézios, $n = 4$	5	0,7429840978	$3{,}8 \times 10^{-3}$
trapézios, $n = 16$	17	0,7465845968	$2{,}4 \times 10^{-4}$
Simpson 1/3, $n = 4$	5	0,7468553798	$3{,}1 \times 10^{-5}$
Simpson 3/8, $n = 6$	7	0,7468380575	$1{,}4 \times 10^{-5}$
Simpson 1/3, $n = 16$	17	0,7468242574	$1{,}2 \times 10^{-7}$
Romberg, $R_{4,4}$	17	0,7468241331	$2{,}8 \times 10^{-10}$
Gauss, 3 pontos	3	0,7468145842	$9{,}5 \times 10^{-6}$
Gauss, 5 pontos	5	0,7468241268	$6{,}0 \times 10^{-9}$

Em resumo.

- A **regra dos trapézios** é a mais simples e funciona com qualquer tabela de dados, mas converge devagar (h^2). É imbatível, porém, para funções periódicas integradas num período inteiro, caso em que a expansão de Euler-Maclaurin se anula.
- A **regra 1/3 de Simpson** custa o mesmo e converge com h^4; é a escolha padrão para dados igualmente espaçados com n par. A **3/8** completa o caso de n ímpar.
- **Romberg** aproveita as mesmas avaliações dos trapézios e atinge precisão alta quando f é suave.
- **Gauss-Legendre** dá a maior precisão por avaliação para funções suaves dadas por fórmula, mas exige calcular f em pontos irracionais.
- Para funções com singularidades ou mudanças bruscas, todos os métodos perdem desempenho; usam-se então métodos *adaptativos*, que refinam a malha só onde é necessário (é o que fazem os programas profissionais e o comando `Integral` do GeoGebra).

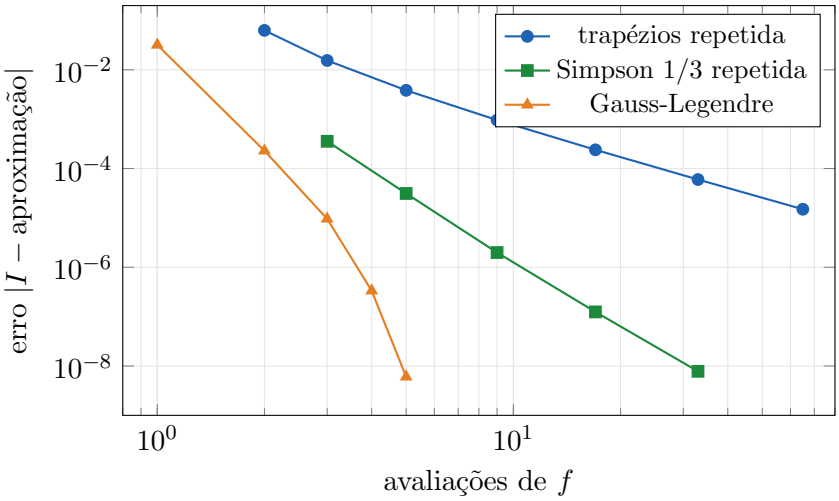


Figura 6.3: Erro em função do número de avaliações de f para $\int_0^1 e^{-x^2}\,dx$, em escala logarítmica. As retas dos trapézios e de Simpson têm inclinações -2 e -4 (erros proporcionais a h^2 e h^4).

6.10 Exercícios

1. Calcule $\int_0^{\pi} \operatorname{sen} x\,dx$ pela regra dos trapézios e pela regra 1/3 de Simpson, ambas com $n = 4$. Compare com o valor exato 2.

2. Verifique que a regra dos trapézios tem grau de exatidão 1 e que a regra 1/3 de Simpson tem grau de exatidão 3, testando-as em $1, x, x^2, x^3, x^4$ no intervalo $[0, 2]$ com a fórmula simples.

3. Quantos subintervalos são necessários para calcular $\int_0^1 e^{-x^2}\,dx$ com erro menor que 10^{-6} (a) pela regra dos trapézios; (b) pela regra 1/3 de Simpson? Use $M_2 = 2$ e $M_4 = 12$.

4. Calcule S_6 (regra 1/3, $n = 6$) para $\int_0^1 e^{-x^2}\,dx$ e compare com $S_6^{3/8} = 0{,}7468380575$.

5. A velocidade de um carro (em m/s) foi registrada a cada 10 segundos:

t (s)	0	10	20	30	40	50	60
v (m/s)	0	8,2	14,6	19,3	22,4	24,1	24,8

Estime a distância percorrida, $\int_0^{60} v(t)\,dt$, pela regra dos trapézios e pelas regras 1/3 e 3/8 de Simpson.

6. Mostre que, ao integrar as bases de Lagrange de quatro nós igualmente espaçados em $[x_0, x_3]$, obtêm-se os pesos $\frac{3h}{8}, \frac{9h}{8}, \frac{9h}{8}, \frac{3h}{8}$ da regra 3/8. (Sugestão: use $x = x_0 + sh$, $s \in [0, 3]$.)

7. Construa a tabela de Romberg com $K = 2$ para $\int_0^1 \dfrac{4}{1+x^2}\,dx = \pi$.

8. Use Gauss-Legendre com 2 e com 3 pontos para calcular $\int_0^{\pi/2} \operatorname{sen} x\,dx = 1$.

9. Deduza a fórmula de Gauss-Legendre com $n = 1$ (um nó e um peso) exigindo exatidão para 1 e t. Que regra conhecida ela é?

10. **(GeoGebra)** No aplicativo de Gauss-Legendre, use $np = 2$, $f(x) = x^4$ e $[a, b] = [0, 1]$. Calcule o erro pela fórmula do teorema e compare com o aplicativo.

11. (GeoGebra) No aplicativo de Romberg, digite $f(x) = \sqrt{x}$ em $[0, 1]$ (valor exato $\frac{2}{3}$) e use $K = 5$. As razões entre erros consecutivos dos trapézios ainda são próximas de 4? O valor $R_{5,5}$ é tão bom quanto no exemplo com e^{-x^2}? Explique.

12. (GeoGebra) No aplicativo dos trapézios, digite `sin(2pi x)^2`, isto é, $f(x) = \operatorname{sen}^2(2\pi x)$, em $[0, 1]$ (valor exato $\frac{1}{2}$). Compare os resultados com $n = 2$, 3, 4 e 8 e relacione com a observação sobre funções periódicas da seção de comparação.

Respostas

1. $T_4 \approx 1{,}896119$ (erro 0,1039); $S_4 \approx 2{,}004560$ (erro 0,0046).

2. Trapézios: exata para 1 e x (dá 2 e 2); para x^2 dá $4 \neq \frac{8}{3}$. Simpson ($h = 1$): $\frac{1}{3}(f(0)+4f(1)+f(2))$ dá 2, 2, $\frac{8}{3}$, 4, exatos, e para x^4 dá $\frac{20}{3} \neq \frac{32}{5}$.

3. (a) $\frac{h^2}{12} \cdot 2 \leq 10^{-6} \Rightarrow h \leq 0{,}002449 \Rightarrow n = 409$. (b) $\frac{h^4}{180} \cdot 12 \leq 10^{-6} \Rightarrow h \leq 0{,}06223 \Rightarrow n \geq 16{,}07$, logo $n = 18$ (par).

4. $S_6 \approx 0{,}7468303915$, com erro $\approx 6{,}3 \times 10^{-6}$, cerca de 2,2 vezes menor que o da regra 3/8 com o mesmo n (compare com $\frac{180}{80} = 2{,}25$).

5. Trapézios: 1010 m; Simpson 1/3: $\approx 1017{,}3$ m; Simpson 3/8: $\approx 1017{,}4$ m.

6. Por exemplo, $\int_{x_0}^{x_3} L_0\,dx = h\int_0^3 \frac{(s-1)(s-2)(s-3)}{-6}\,ds = \frac{3h}{8}$ e $\int_{x_0}^{x_3} L_1\,dx = h\int_0^3 \frac{s(s-2)(s-3)}{2}\,ds = \frac{9h}{8}$; os outros dois seguem por simetria.

7. $R_{0,0} = 3$; $R_{1,0} = 3{,}1$, $R_{1,1} = 3{,}1333333$; $R_{2,0} = 3{,}1311765$, $R_{2,1} = 3{,}1415686$, $R_{2,2} = 3{,}1421176$ (erro $5{,}3 \times 10^{-4}$).

8. $G_2 \approx 0{,}9984726$ (erro $1{,}5 \times 10^{-3}$); $G_3 \approx 1{,}0000081$ (erro $8{,}1 \times 10^{-6}$).

9. $w_1 = 2$ e $w_1 t_1 = 0$, logo $t_1 = 0$: $\int_a^b f\,dx \approx (b-a)\,f\big(\frac{a+b}{2}\big)$, a regra do ponto médio, com grau de exatidão 1.

10. $G_2 = 0{,}19\overline{4}$ e o valor exato é 0,2; pelo teorema, o erro é $\frac{1\cdot(2!)^4}{5\,(4!)^3}\cdot 24 = \frac{1}{180} \approx 0{,}005556$, exatamente o observado (pois $f^{(4)} \equiv 24$ é constante).

11. Não: as razões dos trapézios ficam entre 2,6 e 2,8, aproximando-se de $2^{1,5} \approx 2{,}83$ (o erro é proporcional a $h^{1,5}$), e $|I - R_{5,5}| \approx 3{,}8 \times 10^{-4}$, muito pior que no exemplo. Como $f'(x) = \frac{1}{2\sqrt{x}}$ não é limitada perto de 0, a expansão de Euler-Maclaurin não vale e a extrapolação não elimina os termos certos.

12. Com $n = 2$ todos os nós caem nos zeros de f e $T_2 = 0$ (os nós "não enxergam" a oscilação); a partir de $n = 3$ obtém-se $T_n = \frac{1}{2}$, exato. Para funções periódicas integradas num período completo, os termos da expansão de Euler-Maclaurin se anulam, e a regra dos trapézios converge muito rapidamente, desde que haja nós suficientes por período.